3. Realizácia experimentálneho plánu.
4. Kódovanie, oprava dát a prevedenie dát do počítača.
5. Porozumenie dátam.
6. Overenie validity použitých štatistických metód.
7. Analýza dát a interpretácia výsledkov.

1.2.3 Validita výskumu

Pri validite výskumu rozlišujeme medzi externou a internou validitou. **Interná validita** znamená do akej miery je preukazný vzťah medzi závislou a nezávislou premennou. Napríklad pri experimente chceme vedieť, či zlepšenie výsledkov skutočne spôsobila intervencia a nie nejaká iná príčina. **Externá validita** sa týka možnosti zovšeobecniť závery, t.j. či výsledky platia aj pre inú skupinu jedincov. Väčšiu internú validitu majú dobre realizované experimenty, naopak výberové zisťovanie založené na náhodnom výbere má vyššiu externú validitu.

1.3 Zdroje dát

V predchádzajúcich kapitolách sme sa zamerali na získavanie dát za účelom analýzy, v tejto kapitole sa zameriame na dáta, ktoré nevznikli s cieľom ich následnej analýzy a na ich potencionálne využitie.

Posledných dvadsať rokov môžeme charakterizovať trendom výrazne narastajúceho objemu elektronických dát. V súčasnosti sa zbiera a eviduje veľké množstvo údajov v rôznych oblastiach ako je priemysel, poisťovníctvo, bankovníctvo, obchod, telekomunikácie, štátna správa a pod. Okrem iného rôzne zariadenia a prístroje denne zaznamenávajú obrovské množstvo dát. Rovnako narastá aj množstvo dát publikovaných na webe. Dnešná doba je charakteristická množstvom elektronicky dostupných dát na jednej strane, ale často nedostatkom znalostí na strane druhej (Paralič, 2003). Tieto dáta nie sú zbierané cielene, tak aby odpovedali napríklad na dané hypotézy, ale sú zhromažďované primárne z iných dôvodov. Zautomatizovaním zberu dát, zaznamenávaním a publikovaním elektronických dát vznikla potreba tieto dáta používať v procese rozhodovania.

Ako príklady zdrojov dát uvádzame databázy, elektronické dokumenty a logovacie súbory. Všetky tieto a ďalšie zdroje dát môžu byť potencionálne užitočné pri tvorbe rôznych akcií, na predvídanie správania zákazníkov, zisťovanie príčin porúch, odhaľovanie podvodov a pod.

1.3.1 Databázy

Najznámejším zdrojom dát sú **produkčné databázy** v lepšom prípade **dátové sklady**, kde sú uložené dáta z produkčných databáz pre potreby rozhodovania. Dátové sklady môžu integrovať dáta aj z iných zdrojov, napr. z verejných (RegDat, databázy Eurostatu). Najčastejšie ide o dáta demografické, socioekonomické a pod. Dátový sklad je v podstate tiež databáza, len je organizovaná podľa trochu iných pravidiel, tabuľky nemusia byť normalizované a pod. Podľa Inmona je dátový sklad

- subjektovo orientovaný,
- integrovaný,
- časovo premenný a nemenný súbor dát,

ktorý slúži pre podporu rozhodovania (Inmon, 2002).

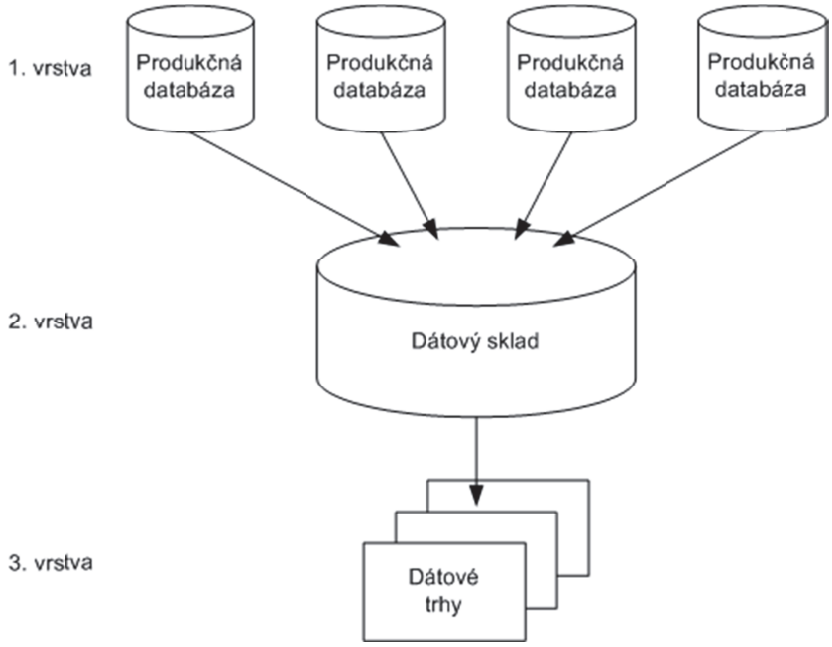
Subjektová orientácia - orientácia na to, čím sa daná spoločnosť zaoberá (klient, dodávateľ, produkt, aktivita a pod.). Produkčné databázy sú naopak orientované na operácie a transakcie (pôžičky, faktúry, vklady, výbery a pod.).

Integrovanosť - tým, že dáta vstupujú do dátového skladu z rôznych produkčných databáz treba tieto dáta integrovať - zjednocovať (zjednotenie použitých jednotiek, zjednotenie kódovania).

Časová premennosť - údaje sa ukladajú do dátového skladu ako séria snímok, z ktorých každá reprezentuje určitý časový úsek.

Nemennosť - v zásade môžeme pripustiť dva typy operácií, zavedenie dát do dátového skladu a prístup k týmto dátam.

Vytvorenie dátového skladu pozostáva z načítania dát z produkčných databáz, konverzie dát a ich následného čistenia a transformácie. Dáta uložené v dátovom sklade predstavujú neutrálny dátový priestor. Pre potreby konkrétnych analýz sa vytvárajú dátové trhy, kam sa z dátového skladu presúvajú relevantné dáta pre určitý typ analýzy (Berka, 2003).



Obrázok 6 Trojvrstvová architektúra dátového skladu (Symons, 1999; Berka, 2003)

Väčšina metód, či už štatistických alebo metód strojového učenia pracuje práve s jednou dátovou maticou. Z praktického hľadiska dátové trhy (Obrázok 6) predstavujú virtuálne tabuľky vytvorené nad dátovým skladom, kde premenné reprezentujú atribúty a prípady dátovej matice reprezentujú záznamy.

1.3.2 Elektronické dokumenty

Ďalším významným zdrojom dát je **text** – **elektronické dokumenty** (kvalifikačné práce, lekárske správy popisujúce symptómy, otvorené odpovede v dotazníkoch, obsah webu a pod.). V prípade obsahu webu sú webové stránky chápané ako dokumenty. Nevýhoda oproti databázam spočíva v neštruktúrovaných dátach. Riešením je vytvorenie takých premenných, ktoré budú vhodne reprezentovať analyzovaný text. Najčastejšie je text dokumentu reprezentovaný vektorom. Vektor má toľko zložiek koľko je kmeňových slov v slovníku, resp. v kolekcii skúmaných dokumentov. Z toho vyplývajú nevýhody ako je veľká dimenzia vektora (veľký počet premenných) a riedke vektory (chýbajúce hodnoty). Každé kmeňové slovo pre daný dokument môže byť kódované:

- *Frekvenciou* (world frequency, *wf*), jednoduchou početnosťou výskytu slova.

- *Binárnou frekvenciou* (binary frequency), binárnym indikátorom výskytu

$$f(wf) = 1, \text{ pre } wf > 0.$$

- *Logaritmickou frekvenciou* (log frequency), ktorá predstavuje transformáciu jednoduchej početnosti (*wf*)

$$f(wf) = 1 + log(wf), \text{ pre } wf > 0.$$

Funkacia logaritmu zabezpečuje „tlmenie“ početností výskytu slov, t.j. stabilizáciu rozptylu (pozri kapitolu 2).

- *Inverznou dokumentovou frekvenciou* (inverse document frequency, *idf*), ktorá predstavuje veľmi užitočnú transformáciu, zohľadňujúcu špecifickosť slov (document frequencies, *df*) ako aj celkovú frekvenciu ich výskytov (world frequencies, *wf*). Inverzná dokumentová frekvencia pre *i*-te slovo a *j*-ty dokument je populárna miera dôležitosti slova, relevantnosti vzhľadom na obsah dokumentu

$$idf(i,j) = \begin{cases} 0, ak\ wf_{i,j} = 0 \\ \left(1 + \log\left(wf_{i,j}\right)\right) log\frac{N}{df_i}, ak\ wf_{i,j} \geq 1' \end{cases}$$

kde $(1 + \log(wf_{i,j}))$ predstavuje počet výskytov kmeňového slova v dokumente, df_i je počet výskytov kmeňového slova v celej kolekcii dokumentov (počet dokumentov, ktoré obsahujú *i*-te slovo) a *N* udáva počet dokumentov v kolekcii (Salton 1971; Manning a Schütze, 2002). Súčasťou transformácie je váha, ktorá nadobúda minimálnu hodnotu 0 v prípade, ak sa slovo vyskytuje vo všetkých dokumentoch (log(N/N = 1) = 0) a maximálnu hodnotu, ak sa slovo vyskytuje práve v jednom dokumente (log(N/1) = log(N)).

1.3.3 Logovacie súbory

Iným príkladom zdroja dát sú automaticky ukladané dáta o používaní webu, rôznych informačných systémov a pod. Spravidla informačné systémy zaznamenávajú dáta o používaní (usage data) vo vlastnej štruktúre, pričom tieto dáta sú najčastejšie organizované v databáze. V prípade webových a proxy serverov sú dáta zaznamenávane v spoločnej štandardnej štruktúre v textovom formáte, v tzv. všeobecnom **logovacom súbore** (common log file).

Pri práci s webom sa vo všeobecnosti používa viacero logovacích súborov, niektoré na strane servera a iné na strane klienta (Srivastava a kol., 2000). Ak sa pozrieme na stranu servera, tak existuje niekoľko typov fyzického umiestnenia webového servera. Prvým je

jeho priame pripojenie do Internetu, pričom v tomto prípade logovací súbor si vytvára samotný webový server a tento súbor je jedinečný. Druhým spôsobom pripojenia je pripojenie prostredníctvom proxy servera. Proxy server je na jednej strane pripojený do Internetu a na druhej strane je pripojený k webovému serveru. Úlohou proxy je znižovať zaťaženie webového servera tým, že si ukladá do vyrovnávacej pamäte jednotlivé webové stránky a ak viacero klientov požaduje tú istú stránku tak im ju ponúkne z pamäte a už nepreposiela požiadavku na webový server. Logovací súbor na proxy obsahuje údaje o všetkých prístupoch, kým logovací súbor webového servera je už nekonzistentný. Tretím spôsobom pripojenia webového servera je prostredníctvom vyrovnávača záťaže (load balancer). Ten môže byť tvorený samostatným zariadením alebo len pomocou konfigurácie systému DNS (Domain Name System). V tomto prípade je zapojených niekoľko webových serverov s tým istým obsahom a klienti sa pripájajú na jeden z týchto serverov v závislosti od ich konfigurácie (buď sa požiadavky rozdeľujú postupne tak ako prichádzajú, alebo tak aby každý server bol rovnako vyťažený). V tomto prípade sa môže stať, že každý server si ukladá svoj vlastný logovací súbor a aby sme získali úplný, tak sa musia tieto súbory spojiť.

Zo strany klienta uvažujeme len o dvoch spôsoboch pripojenia. Buď má klient priame pripojenie k Internetu a teda jeho komunikácia je priamo medzi ním a serverom (aj v prípade použitia NAT zariadenia) alebo je pripojený prostredníctvom proxy. V tomto prípade je úloha proxy znižovať záťaž internetového pripojenia takým spôsobom, že ak viacerí klienti požadujú tú istú stránku, tak pripojenie k serveru sa vykoná len raz a jednotlivým klientom je poskytnutá verzia z vyrovnávacej pamäte. Toto má za následok absenciu požiadaviek v logovacích súboroch webových serverov.

Zakaždým, keď používateľ navštívi webovú stránku, posiela na server veľké množstvo informácií. Logovací súbor vo svojej štandardnej štruktúre - Common Log File (W3C, 1995) zaznamenáva informácie o IP adrese, čase a dátume návštevy, pristupovanom objekte a odkazovanom objekte. V prípade, že použijeme jeho rozšírenú podobu môžeme zaznamenávať aj údaje o verzii prehliadača používateľa, tzv. User-Agent.

Dáta logovacieho súboru väčšinou obsahujú aj množstvo nepotrebných, irelevantných, nepresných a neúplných informácií. Takéto dáta nie sú vhodné pre použitie algoritmami na analýzu webu. Dáta teda musia byť očistené a predspracované.

Riadok logovacieho súboru je zobrazený na Obrázok 7.

```
178.41.1.187 - - [16/Dec/2010:18:16:26 +0100] "GET
/studium/akreditovane-programy HTTP/1.1" 200 15364
"http://www.ukf.sk/studium" "Mozilla/5.0 (Windows; U; Windows NT 5.1;
sk; rv:1.9.2.13) Gecko/20101203 Firefox/3.6.13 BLNGBAR"
```

Obrázok 7 Ukážka jedného riadku logovacieho súboru

Z uvedeného riadku je možné vyčítať nasledovné informácie (Obrázok 8).

```
IP adresa návštevníka - - [dátum a čas prístupu na stránku] "požiadavka
na zobrazenie konktrénej časti vebu + verzia HTTP protokolu" číslo
vybavenia požiadavky "predchádzajúca stránka(referrer page)" "verzia
prehliadača návštevníka stránky"
```

Obrázok 8 Význam jedného riadku logovacieho súboru

Ak poznáme tieto informácie, tak jednoduchým zoradením logovacieho súboru podľa IP adresy a času dokážeme zobraziť napr. nasledujúce informácie.

```
178.41.1.187 - - [16/Dec/2010:18:16:26 +0100] "GET HTTP/1.1" ...
178.41.1.187 - - [16/Dec/2010:18:19:43 +0100] "GET /studium HTTP/1.1" ...
178.41.1.187 - - [16/Dec/2010:18:20:19 +0100] "GET /studium/akreditovane-
programy HTTP/1.1"...
```

Obrázok 9 Sedenie návštevníka webu

Z týchto troch riadkov (Obrázok 9) vieme napr. určiť, že návštevník pristupujúci z IP adresy 178.41.1.187 pristúpil na náš web 16. Decembra 2010 a prechádzal na webe postupne hlavnú stránku, stránku štúdium a stránku akreditované študijné programy. Tieto jeho tri prístupy na náš web zachytené v logovacom súbore označujeme ako jedno sedenie návštevníka webu.

1.4 Objavovanie znalostí

Spoločnou črtou spomínaných zdrojov dát je veľký objem dát. Zoberme si len do úvahy databázu banky, kde okrem účtov, klientov, dispozičných práv, kreditných kariet, úverov, trvalých príkazov a pod. sa zaznamenávajú aj najdôležitejšie údaje o zmenách na účtoch – dáta o realizovaných operáciách, ktoré denne môžu pribúdať rádovo v tisícoch. Podobne sú na tom portály organizácii, kde sa veľa krát, samozrejme v závislosti od ich návštevnosti, pristupuje k analýze dát o používaní len vybranej časti portálu. Napríklad v prípade portálu banky môžeme zvlášť analyzovať prístupy na časti *individuálni klienti*, *malí podnikatelia*, *stredné a veľké firmy* a pod. Ako ďalší príklad by sme mohli uviesť antiplagiátorský systém do ktorého ročne pribúda tisíce nových bakalárskych a diplomových prác.

Obrovské množstvo údajov má ale slabú vypovedajúcu hodnotu. Za týmto účelom vznikol koncept objavovania znalostí (Knowledge Discovery, KD). Objavovanie znalostí chápeme ako proces, ktorý zahrňuje výber dát, predspracovanie dát, transformáciu dát, analýzu dát a interpretáciu výsledkov (Fayyad a kol., 1996).



Obrázok 10 Princíp objavovania znalostí

Princíp objavovania znalostí si môžeme priblížiť na analýze návštevnosti webu (Obrázok 10). Dáta o používaní webu sa zaznamenávajú do logovacieho súboru webového servera. Z veľkého objemu dát môžeme získať informácie pre lepšie porozumenie dátam. Týmito informáciami môžu byť napríklad štatistiky počtu prístupov za dané časové obdobie, počet návštev - identifikovaných sekvencií (costumer's sequencies) alebo priemerná dĺžka identifikovaných sekvencií - návštev na webe a pod. Výsledkom sekvenčnej analýzy sú sekvenčné pravidlá (sequence rules), ktoré reprezentujú získané znalosti. Od nájdených pravidiel požadujeme aby boli nielen jasné ale aj užitočné. Pričom len časť objavených znalostí - vzorcov správania sa používateľov webu, je použiteľná z hľadiska aplikácie. Zvyšné pravidlá sú z hľadiska užitočnosti triviálne, resp. nevysvetliteľné, t.j. nepoužiteľné, resp. neprinášajúce nové znalosti.

1.4.1 Oblasti aplikácií objavovania znalostí

Najznámejšou aplikačnou oblasťou objavovania znalostí je **objavovanie znalostí z databáz** (Knowledge Discovery in Databases, KDD). Fayyad túto oblasť definoval ako netriviálne

získavanie implicitných, predtým neznámych a potencionálne užitočných informácií z dát (Fayyad a kol., 1996). Zdrojom dát sú v tomto prípade produkčné databázy, dátové sklady a pod. V niektorých prípadoch je možné kombinovať viaceré zdroje dát, prípadne doplniť tieto dáta údajmi z verejných zdrojov (oficiálne štatistiky, rezortné dáta, demografické údaje a pod.), respektíve údajmi získanými vlastnými prieskumami. Napríklad podnikové dáta o objeme predaja mangánových zliatin môžeme doplniť o dáta z verejných databáz (cena elektrickej energie pre priemysel, produkcia ocele, cena ropy, cena mangánovej rudy, hrubý domáci produkt Číny a pod.), ktoré by potencionálne mohli predstavovať vysvetľujúce premenné. Ďalším príkladom môže byť doplnenie dát z databázy banky o regionálne dáta z verejných databáz (počet pobočiek komerčných bánk, počet podnikov, ekonomicky aktívne obyvateľstvo, miera evidovanej nezamestnanosti a pod.), z ktorých je možné vyčítať ďalšie informácie o prostredí, v ktorom klient žije, ako aj o prostredí, v ktorom je zriadená pobočka banky. KDD má metodický základ v databázach, štatistike a strojovom učení. Cieľom KDD je objavovanie nových, zaujímavých a užitočných znalostí používaním štatistických metód a metód strojového učenia za účelom klasifikácie (Mehta, Agrawal, a Rissanen, 1996; Yu, 1999), segmentácie (Jain, Murty a Flynn, 1999), objavovania asociačných pravidiel (Agrawal, Imielinski a Swami, 1993), sekvenčných pravidiel (Han, Pei a Yan, 2005) a pod.

V prípade, že sú tieto dáta získavané z textov, nazývame tento proces text miningom, resp. **objavovaním znalostí z textov** (Knowledge Discovery in Texts, KDT). Zdrojom dát sú v tomto prípade elektronické dokumenty. V súčasnosti sa v čoraz väčšej miere uprednostňuje uchovávanie dokumentov v elektronickej forme na rozdiel od papierovej. Rovnako narastá aj objem obsahu publikovaného na webe. Cieľom objavovania znalostí z textov môže byť odhaľovanie plagiátorstva, hľadanie ustálených štruktúr, väzieb, slovných spojení za účelom automatizovaného prekladu, segmentácia webových stránok podľa obsahu a pod. Objavovanie znalostí z textov je analogické objavovaniu znalostí z databáz (Hearst, 1999). Podobne chápe objavovanie znalostí z textov aj Sullivan v zhode so všeobecnou definíciou objavovania znalostí (Sullivan, 2001). Najväčšie rozdiely sú v samotnej príprave dát, t.j. reprezentovať text tak, aby mohli byť použité niektoré analytické nástroje na analýzu dát. Objavovanie znalostí z textov zahŕňa viaceré vedné oblasti. Podobne ako v KDD aj v objavovaní znalostí z textov sú štatistické metódy a metódy strojového učenia prostriedkami k analýze dát. Naopak pri príprave dát stavia

hlavne na teoretickej a počítačovej lingvistike (Neuendorf, 2002; Titscher a kol., 2002; Hajičová, Panevová a Sgall, 2003; Weiss a kol., 2005).

V súčasnosti internet predstavuje najdynamickejšie sa rozvíjajúci zdroj informácii, čím sa stáva významným zdrojom dát. Webové stránky sú chápané predovšetkým ako zdroj informácií pre používateľov - klientov. Zatiaľ len málo spoločností si uvedomuje skutočnosť, že webové stránky môžu poskytovať informácie i v opačnom smere. Organizácia môže získať množstvo informácií o svojich klientoch, o ich správaní, o ich záujmoch a pod. Z potreby analyzovať tieto dáta vznikla príbuzná oblasť objavovania znalostí z databáz (Knowledge Discovery in Databases, ďalej KDD) – **objavovanie znalostí z webu** (web mining). Podobne ako objavovanie znalostí z textov aj objavovanie znalostí z webu je analogické objavovaniu znalostí z databáz, resp. z textov v prípade objavovania znalostí na základe obsahu webu. Web mining môžeme definovať ako extrakciu zaujímavých a potenciálne užitočných znalostí a informácií z aktivít súvisiacich s webom (Liu, 2007). Pre uplatnenie metód web miningu niekedy stačí mierne prispôsobiť existujúce postupy z oblasti KDD, inokedy je potrebné zásadnejšie zmeniť kroky predspracovania a transformácie dát. Web mining môžeme kategorizovať podľa toho, ktorá časť webu je analyzovaná (Borges a Levene, 1999; Madria a kol., 1999; Kosala a Blockeel, 2000), t.j. objavované znalosti z webu môžeme rozdeliť do troch domén (Zaiane a Han, 1998):

- objavovanie znalostí na základe obsahu webu (web content mining), ktorého úlohou je objavovanie užitočných informácií dostupných on-line (Balabanovic a Shoham, 1995; Kosala a Blockeel, 2000),
- objavovanie znalostí na základe štruktúry webu (web structure mining), ktorého úlohou je objavovanie štruktúry hyperliniek webu (Kleinberg a kol., 1999; Hou a Zhang, 2003; Han a Elmasri, 2004),
- objavovanie znalostí na základe používania webu (web usage mining), ktorého úlohou je objavovanie aktivít používateľov súvisiacich s ich prehľadávaním webu (Iváncsy a Vajk, 2006).

1.4.2 Metodiky procesu objavovania znalostí

Metodika CRISP-DM poskytuje jednotný univerzálny postup pri riešení rôznych úloh z oblasti objavovania znalostí. Metodika pozostáva z postupnosti krokov

Business Understanding⇔Data Understanding➔Data Preparation⇔Modeling

➔Evaluation➔Deployment,

t.j. porozumenie problematike, porozumenie dátam, príprava dát, analýza dát, vyhodnotenie výsledkov, využitie výsledkov.

Vznikla v polovici deväťdesiatich rokov v rámci európskeho výskumného projektu a je „softvérovo nezávislá“, na rozdiel od metodík, ktorých tvorcami sú producenti štatistických programov a data miningových nástrojov.

Príkladom takejto metodiky bola napr. metodika 5A od spoločnosti SPSS, ktorá asi najviac pripomína metodiku CRISP-DM. Metodika 5A sa skladá z krokov

Assess➔Access➔Analyze➔Act➔Automate,

t.j. posúdenie potrieb projektu, získanie potrebných dát, analýza dát, interpretácia užitočných znalostí, aplikácia znalostí do praxe.

V súčasnosti však SPSS v dokumentácii k svojim riešeniam odporúča na riadenie data miningových projektov metodiku CRISP-DM.

Ďalším príkladom je metodika SEMMA od spoločnosti SAS

Sample➔Explore➔Modify➔Modell➔Assess,

t.j. výber dát, prieskum dát, transformácia dát, analýza dát, zhodnotenie a interpretácia.

Metodika SEMMA je viac zameraná na technickú časť data miningového projektu a pripomína metodiku Six Sigma vytvorenú za účelom riadenia projektov kontroly kvality vo všetkých oblastiach výroby, manažmentu a pod. Metodiku Six Sigma tvorí sekvencia krokov

Define➔Measure➔Analyze➔Improve➔Control,

t.j. definovanie, meranie, analýza, zlepšenie, riadenie.

Väčšina data miningových nástrojov má v sebe implementovanú podporu pre niektorú zo spomínaných metodík. Ako príklad môžeme uviesť SPSS Clementine, ktorý na riadenie projektov používal metodiku 5A a od roku 2001 používa metodiku CRISP-DM. SAS Enterprise Miner pre zmenu zas používa metodiku SEMMA.

Všetky spomínane metodiky umožňujú prenášať skúsenosti z úspešných projektov. V súčasnosti najrozpracovanejšou a najpoužívanejšou je práve metodika CRISP-DM. Primárne vznikla pre riadenie projektov z oblasti objavovania znalostí z databáz, ale je použiteľná aj pre iné aplikačné oblasti ako je text, web a pod. Toto predstavuje aj jednu z priorít aktualizácie metodiky, s čím súvisia hlavne nové techniky prípravy dát, ktoré si vyžiadali nové typy dát ako je napr. text. Bez ohľadu na to sa metodika CRISP-DM úspešne uplatňuje aj v ďalších oblastiach.

Napr. Dan Sullivan vo svojej knihe (Sullivan, 2001) uvádza viaceré aplikácie objavovania znalostí z textov, pričom proces objavovania znalostí riadi metodikou CRISP-DM (Paralič a kol., 2010). Podobne aj Grobelnik v projekte pre nakladateľstvo zameranom na podpory vyhľadávania v textových databázach a na automatickú kategorizáciu dokumentov riadi proces objavovania znalostí metodikov CRISP-DM (Grobelnik, Mladenic a Jermol, 2002).

Príkladom inej oblasti a nasedenia metodiky CRISP-DM je štatistická analýza logovacieho súboru domény www.volkswagen.de (Dellmann, Wulff a Schmitz, 2003). V oblasti objavovania znalostí na základe používania webu (WUM) sa tento proces rozdeľuje do troch základných častí (Cooley, Srivastava a Mobasher, 1997)

Preprocessing➔Pattern Discovery➔Pattern Analysis,

kde tieto tri časti WUM procesu korešpondujú s fázami metodiky CRISP-DM

Data Preparation⇔Modeling➔Evaluation.

Najväčšie rozdiely medzi aplikačnými oblasťami objavovania znalostí pri riadení procesu metodikou CRISP-DM sú vo fáze prípravy dát (Data Preparation). Príprava dát predstavuje časovo najnáročnejšiu fázu v rámci celého procesu objavovania znalostí. Zložitosť prípravy dát závisí od použitého zdroja dát. Vstupom do analytických procedúr je dátový súbor o *M* premenných a *N* prípadoch. Predmetom prípravy dát nie je iba transformácia dát do podoby vyžadovanej analytickými nástrojmi, ale aj samotná kvalita dát.

Relatívne najjednoduchšia príprava dát je v prípade použitia databázy ako zdroja dát. Najčastejšie sú dáta organizované v relačnej databáze, pričom väčšina analytických metód vyžaduje organizovať dáta do jednej dátovej matice. Príprava dát pozostáva zjednodušene z výberu, čistenia, vytvárania, integrovania a formátovania dát (Chapman

a kol., 2000). V prípade dátového skladu odpadá čistenie a integrovanie dát, čo prípravu dát skracuje ešte výraznejšie.

V prípade elektronických dokumentov premennými by boli kmeňové slová a prípadmi by boli váhy jednotlivých kmeňových slov v texte každého z dokumentov, t.j. každý textový dokument reprezentuje vektor váh primárne odvodený z frekvencie výskytov kmeňových slov. Zjednodušene príprava dát pozostáva z konverzie dokumentov na čistý text a následne z identifikácie kmeňových slov. Detailnejšie o reprezentácii elektronických dokumentov a príprave dát za účelom analýzy textu sa pojednáva v knihách z oblastí text miningu, obsahovej analýzy a pod. (Neuendorf, 2002; Titscher a kol., 2002; Weiss a kol., 2005; Paralič a kol., 2010).

Medzi najnáročnejšie zdroje dát z hľadiska prípravy dát patrí logovací súbor webového servera. Väčšina portálov nevyžaduje autentifikáciu používateľov, resp. ak je dobrovoľná je v minimálnej miere používaná, t.j. najvypuklejším problémom je identifikácia používateľov portálu, resp. návštevníkov webu. Problém predstavujú aj prístupy robotov (crawlerov, spiderov) rôznych vyhľadávacích služieb. Ďalším problém súvisí s vyrovnávacou „keš“ pamäťou prehliadača. Jej používaním sa pri pohybe späť (tlačidlo dozadu) zobrazená stránka už nezaznamenáva do logovacieho súboru. V prípade dát z logovacieho súboru nie je problémom reprezentácia dát ako pri texte, ale skôr kvalita - spoľahlivosť dát.

1.5 Objavovanie znalostí verzus výskumné plány

V podstate môžeme objavovanie znalostí prirovnať k výskumným plánom (pozri kapitolu 1.2). Ale predsa je tu jeden podstatný rozdiel, kým pri výskumných plánoch sú dáta získané cielene tak, aby odpovedali na dané ciele (hypotézy), v objavovaní znalostí sú získané z dátových zdrojov, ktoré nevznikli s cieľom ich následnej analýzy, ale sú zhromaždené primárne z iných dôvodov a nemusia obsahovať požadované informácie. Samozrejme sú tu aj ďalšie rozdiely, v objavovaní znalostí sa spracovávajú a analyzujú „veľké dáta“, použitie analytických metód je formalizované, kým pri výskumných plánoch použité metódy závisia na hypotézach a ich návrh je súčasťou plánu. V tomto procese je snahou zhodnotiť všetky dáta s cieľom získania nových znalostí využiteľných pre rozhodovanie (Skalská, 2003; Biskup a Čermáková, 2005).

V literatúre sa často odlišujú tieto dva prístupy, resp. nebývajú predmetom jednej publikácie. Napriek tomu nájdeme aj spoločné body v týchto na prvý pohľad odlišných prístupoch. V prípade výskumných plánov získavame dáta z výskumnej vzorky, podobne v prípade objavovania znalostí musíme zhromaždiť validné dáta z dostupných zdrojov. Výskumné plány rovnako ako aj objavovanie znalostí predstavujú určitý proces a vznikajú k nim metodiky, ktoré nám umožňujú prenášať skúsenosti z úspešných projektov. V obidvoch prístupoch na získané a spracované dáta aplikujeme štatistické metódy, ako metódy exploračnej analýzy, tak aj metódy inferenčnej analýzy. V objavovaní znalostí okrem tradičných štatistických metód sa na analýzu dát uplatňujú aj metódy strojového učenia, ktoré však veľmi úzko súvisia s konceptom exploračnej analýzy dát.