

UNIVERZITA KONŠTANTÍNA FILOZOFA V NITRE
FAKULTA PRÍRODNÝCH VIED A INFORMATIKY

Prehľadávanie webu

doc. Mgr. Ľubomír Benko, Ph.D.

LBENKO@UKF.SK

Indexovanie webu

- Spider, bot, robot, crawler
- Automatizovaný nástroj, ktorý systematicky prehľadáva internet
- Vyhľadávače webových stránok na indexovanie

Použitie crawlerov

- Roboty vyhľadávacích služieb (Google, Bing, ...)
- Sledovanie cien
- SEO analýza
- Výskum (zbieranie datasetov, odborných článkov)

Crawling vs Scraping

- Web crawling
  - Získavanie stránok prechádzaním po odkazoch
  - Mapovanie štruktúry webu
  - Ukladá URL, metadáta, mapu webu
- Web scraping
  - Získava špecifické údaje zo stránok
  - Zameriava sa na zbieranie štruktúrovaných dát
  - Ukladá text, tabuľka, ceny

Crawlovacia politika

- Pomocou súboru robots.txt
- Výber, ktoré stránky môže stiahnuť
- Opätovné návštevy pre evidovanie zmien na webe
- Nepreťažovanie webov
- Paralelizácia prehľadávania

Postup

- Počiatočná URL adresa
- Získanie obsahu HTML súboru
- Získanie odkazov
- Pridanie odkazov do poradia – opakuj, kým sú v poradí odkazy
- Ulož text/štruktúru

Python knižnice

- Requests – jednoduchá HTTP knižnica na získavanie webových stránok
- Scrapy – plnohodnotný crawlovací framework
- Wikipedia – knižnica pripájajúca sa na API wikipédie
- BeautifulSoup – spracováva HTML/XML súbory



UNIVERZITA
KONŠTANTÍNA FAKULTA
FILOZOFA PRÍRODNÝCH VIED
V NITRE A INFORMATIKY

Ďakujem za pozornosť