Príprava dát: Sedenie návštevníka webu

$$WALS = \{\langle \boldsymbol{IP}, \boldsymbol{DTime}, Method, \boldsymbol{URL}, Version, Status, Bytes, \boldsymbol{Referrer}, \boldsymbol{Agent} \rangle\},$$

kde $WALS$ (Web Access Log Set) je množina webových prístupov zachytená v logovacom súbore a zoradená podľa položky $DTime$.
$WALS \subset U$, kde U je množina možných požiadaviek na webový server.

```
178.41.1.187 - - [16/Dec/2010:18:16:26 +0100] "GET " ...
178.41.1.187 - - [16/Dec/2010:18:19:47 +0100] "GET /studium " ...
178.41.1.187 - - [16/Dec/2010:18:52:37 +0100] "GET /studium/akreditovane-programy "...
178.41.1.187 - - [16/Dec/2010:18:54:25 +0100] "GET /prijimaciekonanie " ...
178.41.1.187 - - [16/Dec/2010:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "...
```

Identifikácia používateľov/sedení

- na základe rôznej verzie internetového prehliadača
- na základe štruktúry prehľadávaných stránok
- na základe času

Príprava dát: Časovo orientované heuristiky

Ak máme odhad dĺžky času sedenia θ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \{\langle USID, \langle URL_1, DTime_1\rangle, \dots, \langle URL_k, DTime_k\rangle\rangle\},$$

$$DTime_k - DTime_1 \leq \theta,$$

kde USS (User Session Set) je množina sedení, $DTime_k$ je časová známka posledného záznamu sedenia, $1 \leq k \leq n$ a n je počet záznamov vo $WALS$.

Všetky ďalšie záznamy logovacieho súboru, ktorých časová známka je väčšia ako $DTime_1 + \theta$ už patria do ďalšieho sedenia.

Príprava dát: Časovo orientované heuristiky

Ak máme odhad veľkosti časového okna δ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \{\langle USID, \langle URL_1, DTime_1\rangle, \ldots, \langle URL_k, DTime_k\rangle\rangle\},$$

$$DTime_i - DTime_{i-1} \leq \delta,$$

kde $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$.

Ak po dvoch po sebe nasledujúcich záznamov z $WALS$ nerovnosť neplatí, tak záznamy patria do dvoch rozdielnych sedení.

Príprava dát: Časovo orientované heuristiky

```
178.41.1.187 - - [16/Dec/2010:18:16:26 +0100] "GET " ...
178.41.1.187 - - [16/Dec/2010:18:19:47 +0100] "GET /studium " ...
178.41.1.187 - - [16/Dec/2010:18:52:37 +0100] "GET /studium/akreditovane-programy "...
178.41.1.187 - - [16/Dec/2010:18:54:25 +0100] "GET /prijimaciekonanie " ...
178.41.1.187 - - [16/Dec/2010:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "...
```

Sedenie 1

```
178.41.1.187 - - [16/Dec/2010:18:16:26 +0100] "GET " ...
178.41.1.187 - - [16/Dec/2010:18:19:47 +0100] "GET /studium " ...
```

Sedenie 2

```
178.41.1.187 - - [16/Dec/2010:18:52:37 +0100] "GET /studium/akreditovane-programy "...
178.41.1.187 - - [16/Dec/2010:18:54:25 +0100] "GET /prijimaciekonanie " ...
178.41.1.187 - - [16/Dec/2010:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "...
```

Príprava dát: h-ref heuristika

Ak máme odhad veľkosti časového okna δ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \{\langle USID, \langle URL_1, DTime_1, Referrer_1\rangle, \ldots, \langle URL_k, DTime_k, Referrer_k\rangle\rangle\},$$

$$Referrer_i = URL_{i-1} \qquad (1)$$

alebo rovnosť neplatí, resp. $Referrer_i$ nie je definovaný, ale:

$$DTime_i - DTime_{i-1} \leq \delta, \qquad (2)$$

kde $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$.

Dva po sebe nasledujúce záznamy z $WALS$ nepatria do jedného sedenia, ak neplatí (1) a zároveň (2).

Príprava dát: h-ref heuristika

IP adresa	Čas požiadavky	URL adresa	Odkazujúca (referrer)
194.160.10.10	12:00	stránka A	-
194.160.10.10	12:01	stránka B	stránka A
194.160.10.10	12:04	stránka C	stránka B
194.160.10.10	12:08	stránka D	stránka C
194.160.10.10	13:00	stránka A	-
194.160.10.10	**13:04**	**stránka E**	**stránka D**
194.160.10.10	13:09	stránka B	stránka A
194.160.10.10	13:12	stránka C	stránka B

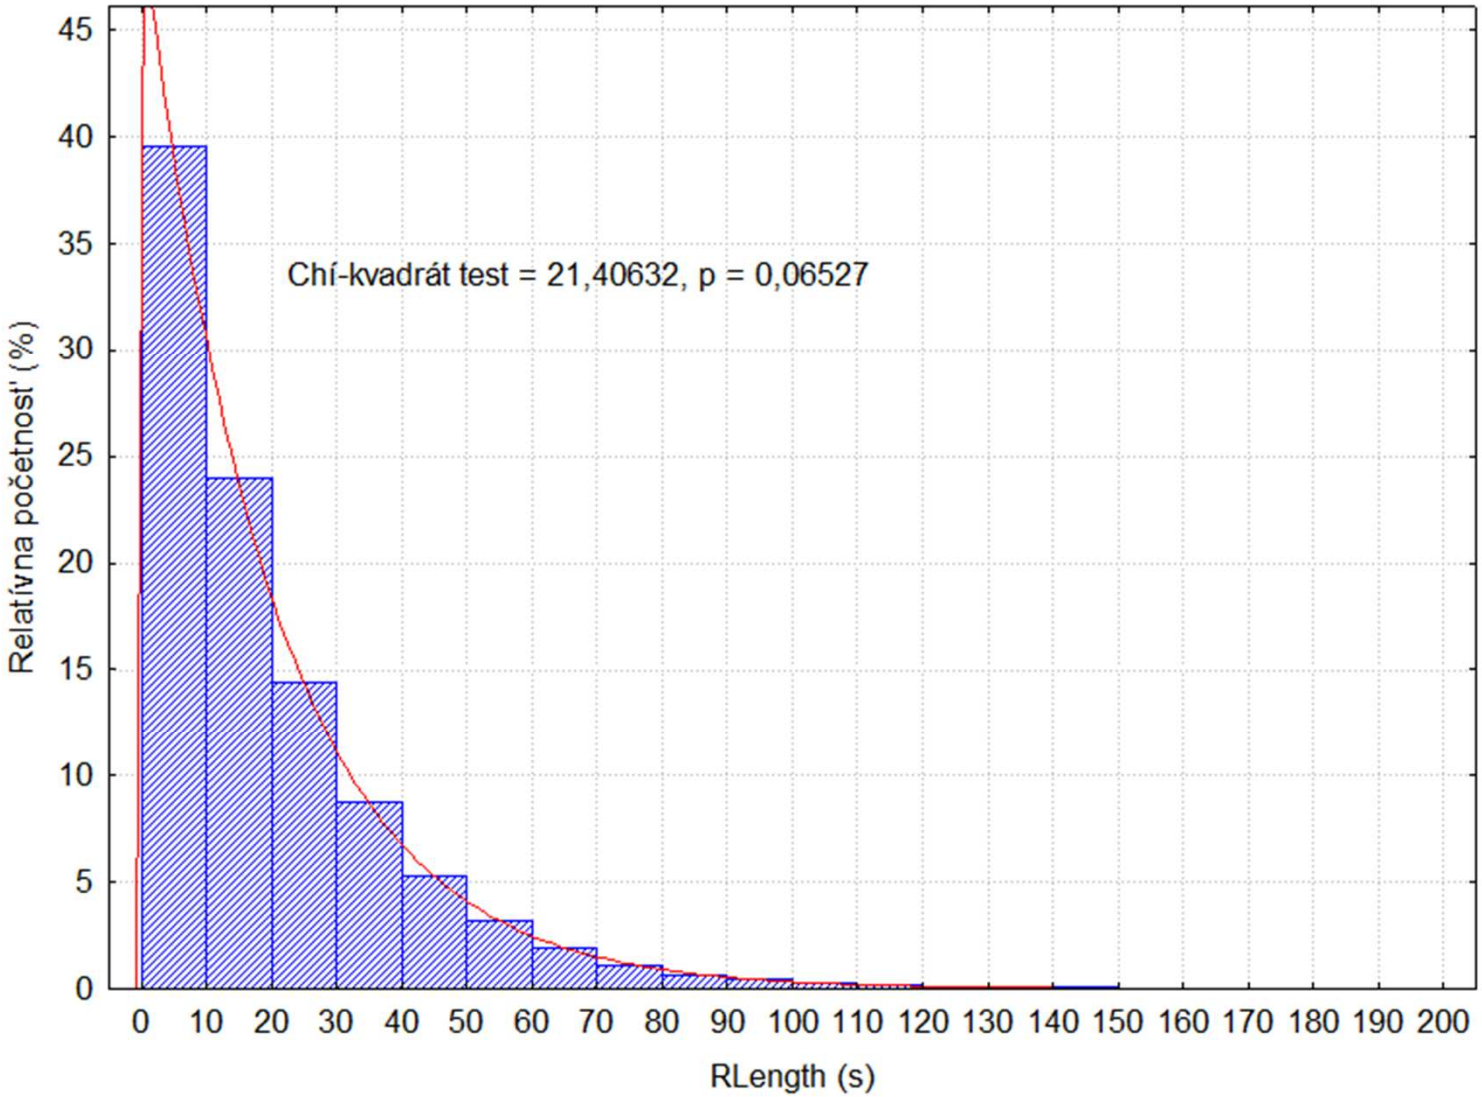
Sedenie 1

194.160.10.10	12:00	stránka A	-
194.160.10.10	12:01	stránka B	stránka A
194.160.10.10	12:04	stránka C	stránka B
194.160.10.10	12:08	stránka D	stránka C
194.160.10.10	13:04	stránka E	stránka D

Sedenie 2

194.160.10.10	13:00	stránka A	-
194.160.10.10	13:09	stránka B	stránka A
194.160.10.10	13:12	stránka C	stránka B

Príprava dát: RLength heuristika



Príprava dát: RLength heuristika

Premenná *RLength* má exponenciálne rozdelenie

$$f(RLength) = \lambda e^{-\lambda RLength},$$
$$F(RLength) = 1 - e^{-\lambda RLength},$$

kde $RLength \geq 0$.

Ak je *p* relatívna početnosť navigačných stránok, na odhad hraničného času C môžeme použiť kvantilovú funkciu

$$F^{-1}(p, \lambda) = C = \frac{-\ln(1-p)}{\lambda}$$

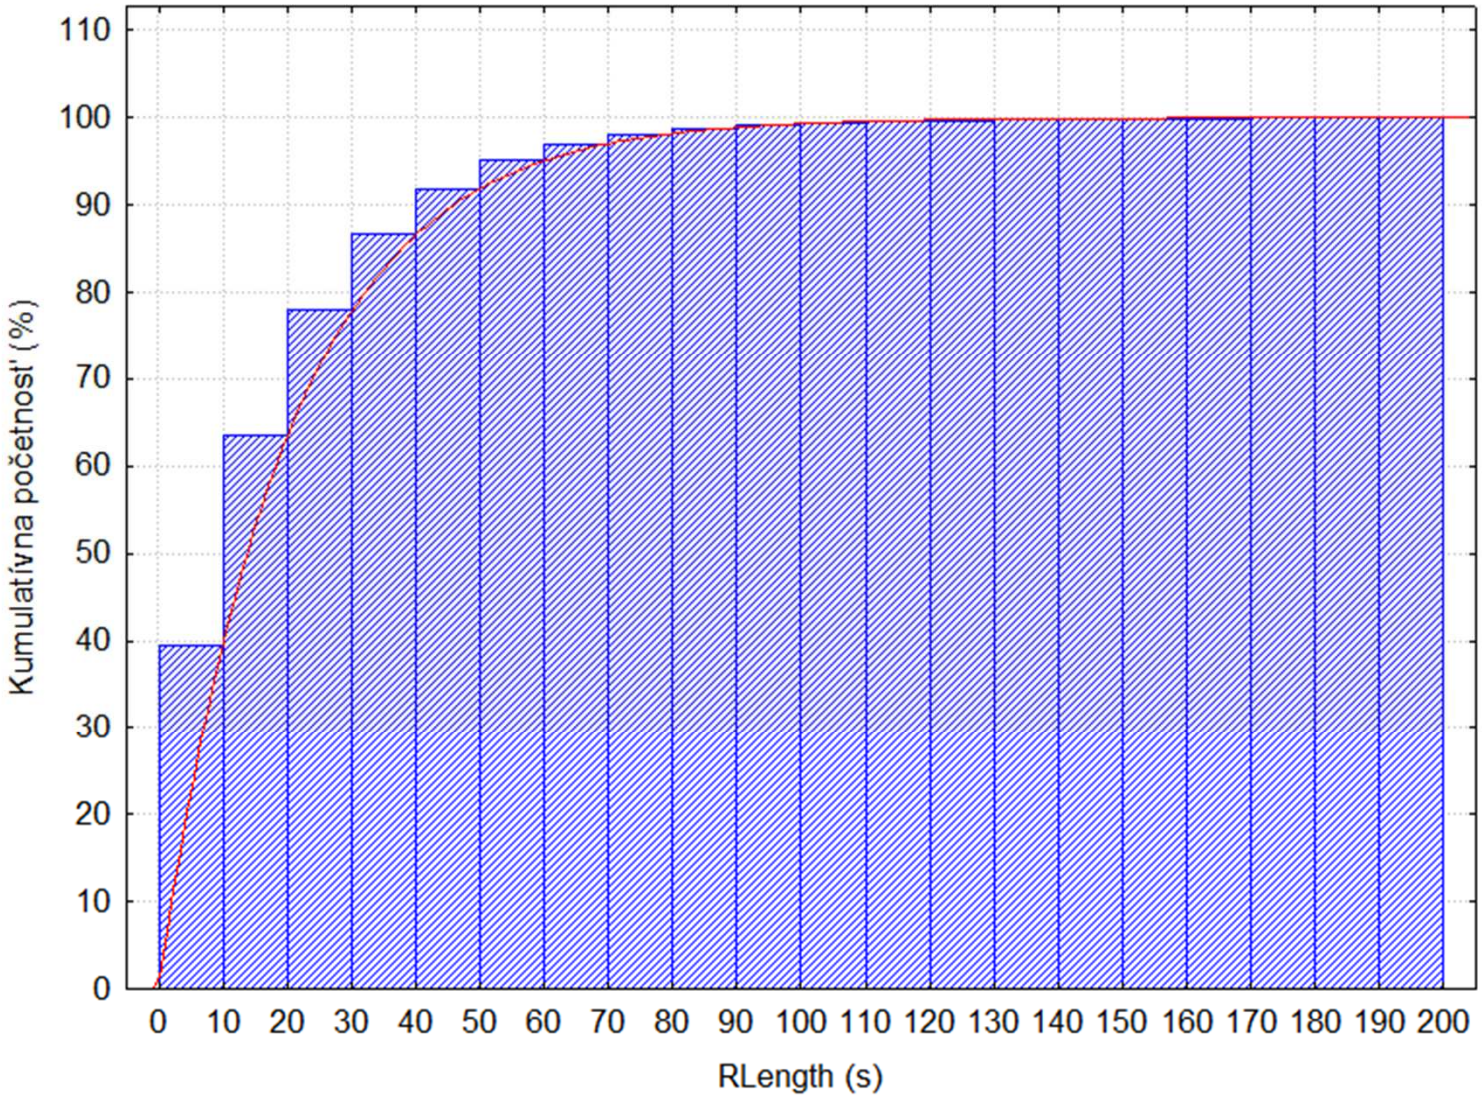
pre $0 \leq p < 1$.

Maximálne vierohodný odhad parametra λ (priemerná intenzita udalostí) je

$$\hat{\lambda} = \frac{1}{\overline{RLength}},$$

kde $\overline{RLength}$ je pozorovaný priemer dĺžky návštev.

Príprava dát: RLength heuristika



Príprava dát: RLength heuristika

Ak máme odhad hraničného času C, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \{\langle USID, \langle URL_1, DTime_1, RLength_1\rangle, \ldots, \langle URL_k, DTime_k, RLength_k\rangle\rangle\},$$

$$RLength_i \leq C, \qquad (1)$$

kde $1 \leq i < k$ a pre poslednú stránku sedenia platí:

$$RLength_k > C. \qquad (2)$$

Od stránky s vlastnosťou (2) je definované ďalšie sedenie.

Príprava dát: RLength heuristika

