Téma 5: Prieskum dát

📖 Čo sa tu naučím

- Robiť **deskriptívnu analýzu** (EDA) nad vyčisteným WUM datasetom — frekvencie, describe(), unikátne hodnoty
- Agregovať dáta **v čase** (mesiac/kvartál) cez `PeriodIndex` a `groupby`
- Skúmať **vzťahy DV × IV** pomocou `pivot_table` a heatmáp
- Robiť **štatistické testy** závislosti: chi² (Pearson) + **Cramerovo V** + ANOVA (`f_oneway`)
- Interpretovať **silu vs signifikanciu** (chi² je signifikantná pri n=2M aj triviálne, treba Cramerovo V)

🔑 Najdôležitejšie vzorce a koncepty

> **Z prednášky 4 (Metodiky procesu KD — CRISP-DM):** CRISP-DM definuje šesť fáz: *Business Understanding* → *Data Understanding* → *Data Preparation* → *Modeling* → *Evaluation* → *Deployment*. Fáza **Data Understanding** (porozumenie dátam) je práve to, čo robíme v prieskume — popisné štatistiky, frekvenčné rozdelenia, prvé hypotézy o vzťahoch. Z metodiky SEMMA tomu zodpovedá krok *Explore*, z 5A krok *Assess*.
>
> **Z prednášky 5 (Fázy procesu — Porozumenie problematike):** Typy úloh objavovania znalostí: *Deskripcia dát a sumarizácia*, *Segmentácia*, *Deskripcia konceptov*, *Klasifikácia*, *Predikcia*, **Analýza závislostí**. Prieskum dát pokrýva prvý a posledný typ — popisujeme rozdelenia jednotlivých premenných a hľadáme závislosti medzi nimi (chi², ANOVA).

```
Cramerovo V = sqrt( chi² / (n * (min(r,c) - 1)) )    ∈ [0, 1]
   r,c    = rozmery kontigenčnej tabuľky
   n      = súčet všetkých buniek (celkový počet pozorovaní)

Interpretácia V:    < 0.1 veľmi slabá | 0.1–0.3 slabá | 0.3–0.5 stredná | > 0.5 sil

ANOVA F-statistika = rozptyl MEDZI skupinami / rozptyl VNÚTRI skupín
   H0: μ₁ = μ₂ = ... = μₖ      H1: aspoň jeden priemer sa líši

Skupiny premenných:
   DV (obsah, vysvetľované):   category, webPart, urlExt
   IV (čas, vysvetľujúce):     year, quartal, yearQuartal, week, crisis
   User:                        anonIP, agent, userAgent
   Other:                       length, internal, frame
```

Úloha 01: popisne_statistiky.py

Teoretický základ: Prvá úloha pokrýva **Deskripciu dát a sumarizáciu** — jeden zo základných typov úloh KD podľa CRISP-DM. V tejto fáze (Data Understanding) sledujeme rozdelenie každej premennej zvlášť: frekvencie pre kategoriálne, miery polohy/variability pre spojité. Cieľom je získať intuíciu o dátach pred analytickými metódami *(viď prednáška 5 — Porozumenie problematike, typy úloh: Deskripcia dát a sumarizácia)*.

Čo robí: Univariate popisná analýza `logs5.csv` — frekvenčné tabuľky, describe() pre length, kardinalita userov/sedení, 2×2 grafy.

Vstup → výstup: - `in/logs5.csv` (sep=`;`, ~2 071 235 riadkov × 24 stĺpcov) - `out/popisne_statistiky.png` (4 subploty) + `out/sumar.txt`

Kľúčové kroky: 1. `pd.read_csv(..., sep=";", quotechar='"', low_memory=False)` 2. `df["category"].value_counts()` (desc), `df["year"].value_counts().sort_index()` (chrono) 3. `df[df["length"] > 0]["length"].describe()` → mean, median, std, Q1, Q3 4. `df["anonIP"].nunique()`, `df["frame"].nunique()` → 6 912 userov, 561 422 sedení 5. `plt.subplots(2,2)` — barh kategórií, bar rokov, bar kvartálov, histogram length

Dôležité parametre: - `sep=";"` — dataset banky používa bodkočiarku (čiarka koliduje s URL) - `quotechar='"'` — URL obsahuje čiarky → musia byť uvedzovkované - `low_memory=False` — vypne chunkované type inference, predchádza DtypeWarning - `length > 0` filter — odstráni posledné requesty v sedení (length nepoznáme)

Časté otázky pri obhajobe: - **Q:** Prečo mean (16.4s) != median (9s)? **A:** Pravostranne šikmé rozdelenie — väčšina prístupov je krátka (rýchle hľadanie), niektoré veľmi dlhé (čítanie dokumentácie) ťahajú priemer hore. - **Q:** Prečo `astype(str)` pre year? **A:** Aby matplotlib bral roky ako kategoriálne labely, nie spojitú os. - **Q:** Do ktorej fázy CRISP-DM patrí táto úloha? **A:** Data Understanding — porozumenie dátam, prvý pohľad na ich charakter pred prípravou a modelovaním *(viď prednáška 4 — CRISP-DM)*.

Úloha 02: navstevnost_v_case.py

Teoretický základ: Časová agregácia patrí stále do fázy **porozumenie dátam** (Data Understanding) — sledujeme, ako sa premenná (počet prístupov) vyvíja v čase. CRISP-DM zdôrazňuje, že táto fáza je úzko prepojená s prípravou dát a iteruje sa s ňou (*„<> medzi oblasťami KD"* — viď prednáška 4). Identifikácia sezónnosti a anomálií (napr. obdobie krízy) je východiskom pre neskoršiu segmentáciu *(viď prednáška 5 — typy úloh: Segmentácia)*.

Čo robí: Časová agregácia prístupov — mesačne, kvartálne, kríza vs po kríze + kategórie v čase.

Vstup → výstup: - `in/logs5.csv` - `out/mesacne_navstevy.csv`, `out/kategorie_v_case.csv`, `out/navstevnost.png`

Kľúčové kroky: 1. `pd.to_datetime(df["time"], format="%d.%m.%Y %H:%M:%S", errors="coerce")` → NaT pri chybe 2. `df["mesiac"] = df["datum"].dt.to_period("M")` → PeriodIndex(M) 3. `df.groupby("mesiac").size()` → Series mesiac → počet 4. Filter `crisis==1` / `crisis==0` → 2 oddelené Series → porovnanie priemerov 5. `df.groupby(["yearQuartal","category"]).size().unstack(fill_value=0)` → 2D matica 6. 2 subploty: mesačný časový rad + kvartálne kategórie

Dôležité parametre: - `errors="coerce"` — zlý formát → NaT (nie exception) - `format="%d.%m.%Y %H:%M:%S"` — explicitný, deterministický parse (vyhne sa dayfirst ambiguity) - `unstack(fill_value=0)` — chýbajúce (kategória, kvartál) kombinácie → 0 (nie NaN, aby sa line plot neprerušil) - `axvline(x=pd.Period("2010-12"))` — hardcoded hranica krízy

Vzorec / formula:

```
zmena_pct = (po_krize.mean() / kriza.mean() - 1) * 100    [v %]
```

Časté otázky pri obhajobe: - **Q:** Prečo PeriodIndex a nie Timestamp? **A:** Natívna agregácia „po mesiaci" cez groupby + čisté popisky na osi X („2010-Q3" namiesto presného timestamp-u). - **Q:** Prečo sú v grafe diery? **A:** Mesiace bez dát (2009-05/06/07, 2009-10) nie sú v PeriodIndex-e — skript ich nereindexuje na súvislý rozsah.

Úloha 03: cas_na_strankach.py

Teoretický základ: Skúmame vzťah medzi spojitou premennou (`length`) a kategoriálnymi premennými (`category` , `yearQuartal` , `crisis`). V terminológii prednášky ide o prienik **deskripcie konceptov** (charakterizácia tried podľa priemerného času) a **analýzy závislostí** *(viď prednáška 5 — typy úloh)*. Heatmapa je vizuálnym ekvivalentom kontigenčnej tabuľky pre spojitú odpoveď.

Čo robí: Vzťah **length × category × čas** — priemerné časy po kategóriách, heatmap kvartál × kategória, kríza vs po kríze.

Vstup → výstup: - `in/logs5.csv` (po filtri length > 0 → ~748 496 záznamov) - `out/priemerny_cas_kategorie.csv` , `out/heatmap_kategoria_kvartal.csv` , `out/cas_na_strankach.png`

Kľúčové kroky: 1. Filter `df[df["length"] > 0].copy()` — len reálne kladné časy 2. `df.groupby("category")["length"].agg(["mean","median","std","count"]).round(2)` 3. `df.pivot_table(index="category", columns="yearQuartal", values="length", aggfunc="mean")` → heatmap matica 4. `df.groupby(["crisis","category"])["length"].mean().unstack()` → 2 riadky × N kategórií 5. `imshow(cmap="YlOrRd")` + `boxplot(column="length", by="category")`

Dôležité parametre: - `aggfunc="mean"` — viac length-ov padá do bunky (kategória, kvartál), treba spriemerovať - `.round(2)` — čitateľnosť CSV a anotácií heatmapy - `df[df["length"] < 100]` pre boxplot — orežú outliery > 100s aby boxy boli čitateľné - `cmap="YlOrRd"` — sekvenčná Yellow→Orange→Red (intuitívna pre intenzitu)

Špeciálne hodnoty length: - `-1` = posledný v sedení (timeout > 30 min) - `-2` = zmena IP medzi 2 prístupmi - `0` = robot crawl alebo neznámy čas

Časté otázky pri obhajobe: - **Q:** Ktorá kategória má najdlhší čas a prečo? **A: Reputation** (25.1s) — výročné správy, regulačné Pillar3 materiály (komplexnejší obsah). - **Q:** Prečo filter length > 0 a nie length > 1? **A:** 0 je sentinel hodnota (nepoznáme čas), nie reálny 0-sekundový prístup. - **Q:** Prečo špeciálne hodnoty -1, -2 vôbec existujú? **A:** Pochádzajú z fázy prípravy dát — pri identifikácii sedení (timeout 30 min, zmena IP) sa pre hraničné záznamy nedá vypočítať reálne `length` *(viď prednáška 5 — Príprava dát, identifikácia sedení na základe času/štruktúry)*.

Úloha 04: vztahy_premennych.py

Teoretický základ: Toto je čistá **analýza závislostí** — posledný z typov úloh KD podľa CRISP-DM *(viď prednáška 5)*. Cieľom nie je len zistiť, či vzťah existuje (signifikancia, p-hodnota), ale aj **ako silný je** (efekt veľkosti — Cramerovo V pre nominálne, η^2 pre ANOVA). Pri veľkých datasetoch (n ≈ 2 milióny) je p-hodnota prakticky vždy < 0.001, takže sila efektu je jediná zmysluplná metrika.

Čo robí: Štatistické testy závislosti — 3× chi^2 + 1× ANOVA + Cramerovo V s interpretáciou.

Vstup → výstup: - `in/logs5.csv` - stdout (sumár testov), `out/sumar.txt` (písaný ručne!)

Kľúčové kroky: 1. `pd.crosstab(df[col1], df[col2])` → r × c kontigenčná tabuľka 2. `chi2_contingency(tabulka)` → `(chi2, p, dof, expected)` 3. `n = tabulka.sum().sum()` — celkový počet pozorovaní 4. `V = sqrt(chi2 / (n * (min(r,c)-1)))` → normalizovaná sila 5. `interpretuj_v(V)` → veľmi slabá / slabá / stredná / silná 6. ANOVA: `[df[df["category"]==k]["length"].values for k in df["category"].unique()]` → `f_oneway(*skupiny)`

Dôležité parametre: - `chi2_contingency` predpokladá expected freq ≥ 5 v ≥ 80 % buniek (skript NEverifikuje) - ANOVA predpoklady: normalita, homoskedasticita, nezávislosť — pri n=2M aj violation prejde cez CLT, ale F=5016 treba brať s rezervou - `*skupiny` — variadic args (`f_oneway` neprijíma list)

Vzorec / formula:

```
chi² test nezávislosti  (Pearson):
   H0: premenné sú nezávislé
   p < 0.05  →  zamietame H0  →  ZÁVISIA

Cramerovo V = sqrt( chi² / (n * (min(r,c) - 1)) )
   V < 0.1   veľmi slabá
```

```
   0.1 – 0.3 slabá
   0.3 – 0.5 stredná
   > 0.5     silná

ANOVA (jednosmerná):
   F = MS_between / MS_within
   H0: μ₁ = ... = μₖ
```

Výsledky na datasete banky: - kategória × kríza: V=0.330 (stredná) - kategória × internal: V=0.366 (stredná) — najsilnejší vzťah - kategória × rok: V=0.250 (slabá) - ANOVA length × kategória: F=5016, p<0.001

Časté otázky pri obhajobe: - **Q:** Prečo nestačí p-hodnota? **A:** Pri n=2M je p<0.001 aj pri triviálnej závislosti. Treba **silu** (Cramerovo V) — tá je škálovo nezávislá. - **Q:** Prečo `interpretuj_v` má hranice 0.1/0.3/0.5? **A:** Konvenčné prahy (Cohen / Rea & Parker) — slúžia na slovnú interpretáciu inak suchých čísiel. - **Q:** Aký je rozdiel medzi výskumným plánom a objavovaním znalostí pri testovaní závislostí? **A:** Vo výskumnom pláne sa dáta získavajú cielene s vopred určenými metódami (cenzus, experiment). V KD pracujeme s **existujúcimi dátovými zdrojmi a veľkými dátami**, použitie metód je formalizované, nie naplánované vopred *(viď prednáška 4 — VP vs. KD)*.

🎯 Vyhodnotenie / na čo si dať pozor pri obhajobe

1. **Rozlišuj signifikanciu vs silu závislosti** — p<0.05 hovorí len že vzťah existuje, Cramerovo V/eta² hovorí ako silný.
2. **Mean vs median pre length** — vždy spomenúť že pravostranne šikmé rozdelenie (median << mean ⇒ niekoľko extrémne dlhých prístupov).
3. **Skupiny premenných** — DV (obsah), IV (čas), User, Other. Zadanie chce **aspoň jednu z každej skupiny**.
4. **Špeciálne hodnoty length** (-1 timeout, -2 IP change, 0 robot) — preto sa filtruje na `length > 0`.
5. **chi² predpoklady** — expected freq ≥ 5 v ≥ 80 % buniek; pri vzácnych kategóriách to nemusí platiť.
6. **ANOVA predpoklady** — normalita v skupinách (length má problémový shape), homoskedasticita; pri n=2M CLT zachráni, ale F treba interpretovať s rezervou.
7. **Zaradenie do CRISP-DM** — prieskum dát je fáza *Data Understanding*, ktorá iteruje s *Data Preparation* (viď prednáška 4 — „<> medzi oblasťami KD"). V SEMMA tomu zodpovedá *Explore*, v 5A *Assess*.