Téma 6: Extrakcia vzorov a metaanalýza

📖 Čo sa tu naučím

- Ako z predspracovaných logov vytvoriť **transakcie (košíky kategórií)** pre každé obdobie
- Algoritmus **Apriori**: support, confidence, lift, anti-monotónia
- Ako spojiť pravidlá z rôznych období do **binárnej matice (pravidlo × obdobie)**
- **Cochranov Q test** + **Kendallovo W** na metaanalýzu zhody medzi obdobiami
- Interpretácia výsledkov: bohatosť vs. stabilita pravidiel

🔑 Najdôležitejšie vzorce a koncepty

> **Z prednášky 9 (Fáza Modelovanie — Analýza závislostí):** Pre úlohu *analýzy závislostí* metodika CRISP-DM odporúča metódy: **korelačná analýza, regresná analýza, asociačné pravidlá, Bayesovské siete, induktívne logické programovanie, vizualizácia dát**. V kontexte web log miningu sa najčastejšie používajú **asociačné pravidlá** (Apriori) na hľadanie spoluvýskytu kategórií v sedeniach.
>
> **Z prednášky 10 (Fáza Vyhodnotenie výsledkov):** Vo fáze vyhodnotenia výsledkov majú uplatnenie základné štatistické metódy za účelom **overenia predpokladov použitia** (testy rozdelenia, testy o rozptyle), **porovnania výsledkov** (porovnanie empirických a teoretických početností pre vybrané kategórie obsahu portálu) a **vizualizácie** rozdielov empirických a teoretických početností. Práve do tejto fázy patrí náš **Cochranov Q test** a **Kendallovo W** — neparametrická metaanalýza zhody medzi obdobiami.

```
support(X⇒Y)    = P(X ∪ Y)
confidence(X⇒Y) = P(Y|X) = support(X∪Y) / support(X)
lift(X⇒Y)       = confidence(X⇒Y) / P(Y)
                  > 1 = pozitívna korelácia
                  = 1 = nezávislosť
                  < 1 = negatívna korelácia
```

```
Cochranov Q: H0 = P(výskyt) je rovnaká vo všetkých k obdobiach
             Q ~ chi² s df = k-1
             p < 0.05 → zamietame H0

Kendallovo W = Q / (n · (k-1))   ∈ [0,1]
             0 = žiadna zhoda, 1 = perfektná zhoda
```

Anti-monotónia: ak itemset I nesplní min_support, žiadny jeho superset ho nemôže splniť → umožňuje prunning v Apriori bottom-up. *(viď prednáška 9 — Modelovanie/Analýza závislostí,*

asociačné pravidlá)

Úloha 01: priprava_transakcii.py

Teoretický základ: Podľa metodiky CRISP-DM patrí extrakcia asociačných pravidiel do fázy **Modelovanie** a typu úlohy **Analýza závislostí**. Pred samotným modelovaním je nutné vstupné dáta transformovať do formátu **transakcií (košíkov)** — každá transakcia je množina položiek, ktoré sa vyskytli spolu. V našom prípade jeden frame (sedenie) tvorí jeden košík kategórií. *(viď prednáška 9 — Modelovanie/Analýza závislostí: asociačné pravidlá)*

Čo robí: Z logs5.csv vytvorí pre každý rok 2009-2012 jeden CSV s košíkmi kategórií (transakcie pre Apriori).

Vstup → výstup: - `in/logs5.csv` (~2M záznamov) - `out/transakcie_{rok}.csv` (2 stĺpce: frame, category=";"-separated) - Počty: 2009=37734, 2010=18996, 2011=21473, 2012=24278

Kľúčové kroky: 1. `pd.read_csv` s `sep=";"`, `quotechar='"'`, `low_memory=False` 2. Projekcia stĺpcov `[frame, anonIP, category, year, yearQuartal]` 3. `dropna(subset=["category"])` → ~102481 záznamov 4. Pre každý rok: `groupby("frame")["category"].apply(lambda x: ";".join(sorted(set(x))))` 5. Filter `str.contains(";")` → len košíky s ≥2 kategóriami 6. Export `transakcie_{rok}.csv` s `index=False`

Dôležité parametre: - `low_memory=False` — jedno-prechodové načítanie, konzistentné dtype (inak DtypeWarning) - `quotechar='"'` — hodnoty s ';' vnútri musia byť v úvodzovkách - `dropna(subset=["category"])` — NaN nie je validná položka košíka - `sorted(set(x))` — deterministické poradie, 'A;B' = 'B;A' - `str.contains(";")` — košík musí mať aspoň 2 položky (inak nevznikne dvojica)

Vzorec / formula:

```
transakcia(frame) = sorted(set({ category : záznam ∈ frame }))
```

Časté otázky pri obhajobe: - **Q:** Prečo košík musí mať ≥2 položky? **A:** Pre pravidlo A⇒B treba minimum 2 rôzne itemy. - **Q:** Prečo sorted(set())? **A:** Set odstráni duplicity, sorted zaručí deterministický string → idempotentný vstup pre Apriori. - **Q:** Prečo low_memory=False? **A:** Inak pandas načíta po chunk-och a háda dtype z prvého chunku → DtypeWarning pri zmiešaných typoch.

Úloha 02: apriori_pravidla.py

Teoretický základ: Asociačné pravidlá sú jedna z odporúčaných metód pre úlohu **Analýza závislostí** v rámci fázy Modelovanie (CRISP-DM). Algoritmus **Apriori** je klasický bottom-up prístup, ktorý využíva princíp **anti-monotónie supportu** na efektívne orezávanie kandidátov.

Cieľom je objaviť netriviálne, doteraz neznáme a potenciálne užitočné vzory typu *"ak používateľ navštívil kategóriu X, navštívi aj Y"*. *(viď prednáška 9 — Modelovanie/Analýza závislostí)*

Čo robí: Pre každý rok extrahuje asociačné pravidlá pomocou Apriori (min_support=0.05) a association_rules (min_confidence=0.5).

Vstup → výstup: - `in/transakcie_{rok}.csv` - `out/pravidla_{rok}.csv` (antecedents, consequents, support, confidence, lift) - Počty pravidiel: 2009=341, 2010=405, 2011=205, 2012=17

Kľúčové kroky: 1. Načítanie CSV, `str.split(";").tolist()` → `list[list[str]]` 2. `TransactionEncoder().fit().transform()` → bool matica T×I 3. `apriori(df_te, min_support=0.05, use_colnames=True)` → frekventované itemsety 4. `association_rules(itemsets, metric="confidence", min_threshold=0.5)` → pravidlá 5. Konverzia frozenset → `";".join(sorted(...))` (stringový kľúč pre úlohu 03) 6. Export `pravidla_{rok}.csv`

Dôležité parametre: - `min_support=0.05` — itemset musí byť v ≥5% transakcií - `min_confidence=0.5` — pravidlo X⇒Y platí ak P(Y|X) ≥ 50% - `use_colnames=True` — itemsety s reálnymi názvami kategórií - `metric="confidence"` — filter pravidiel podľa P(Y|X)

Vzorec / formula:

```
support(X⇒Y)    = P(X ∪ Y)
confidence(X⇒Y) = support(X∪Y) / support(X)
lift(X⇒Y)       = confidence / P(Y)
```

Apriori algoritmus (bottom-up):

```
L1 = {item : support(item) >= min_support}
Lk = candidates(Lk-1 × Lk-1), pruned anti-monotónia
Stop ak Lk je prázdne
```

Časté otázky pri obhajobe: - **Q:** Čo je anti-monotónia? **A:** Ak I nesplní support, žiadny superset I ho nesplní → vetvy sa orežú. - **Q:** Prečo má 2012 len 17 pravidiel? **A:** Rovnaký min_support pri menšom počte transakcií = striktnejšia absolútna hranica. - **Q:** Čo znamená lift=1.5? **A:** X a Y sa vyskytujú spolu 1,5× častejšie ako keby boli nezávislé. - **Q:** Do ktorej fázy CRISP-DM patrí extrakcia pravidiel? **A:** Do fázy **Modelovanie**, konkrétne úloha **Analýza závislostí**. *(viď prednáška 9)*

Úloha 03: matica_pravidiel.py

Teoretický základ: Aby sme mohli porovnávať vzory naprieč obdobiami (rokmi), musíme pripraviť spoločnú **binárnu maticu výskytu** (pravidlo × obdobie). Toto je príprava dát pre fázu

Vyhodnotenie výsledkov — porovnanie rozdelenia pravdepodobnosti empirických relatívnych početností prístupov v čase. *(viď prednáška 10 — Vyhodnotenie výsledkov: porovnanie výsledkov)*

Čo robí: Spojí pravidlá zo všetkých 4 období do binárnej matice (pravidlo × obdobie) pre štatistický test.

Vstup → výstup: - `in/pravidla_{rok}.csv` × 4 - `out/matica_pravidiel.csv` — tvar (450, 6): `pravidlo, O1_2009, O2_2010, O3_2011, O4_2012, pocet_obdobi`

Kľúčové kroky: 1. Pre každý rok: načítanie CSV, vytvorenie string-key `"antecedents => consequents"` 2. Uloženie do `dict[int, set[str]]` — set kvôli O(1) membership testu 3. `set().union(*pravidla_po_obdobiach.values())` → ~450 unikátnych pravidiel 4. Pre každé obdobie stĺpec `O{i}_{rok}` s 1/0 (apply + lambda) 5. `pocet_obdobi = sum(axis=1)` cez stĺpce O1..O4 6. Export s `index=False`

Dôležité parametre: - `set()` — O(1) lookup, automatická deduplikácia - `enumerate(obdobia, 1)` — 1-based index pre O1, O2, ... - `axis=1` — sčítanie horizontálne po riadkoch (nie po stĺpcoch) - `sorted(vsetky_pravidla)` — deterministické poradie riadkov

Vzorec / formula:

```
pocet_obdobi(r) = Σ_i O_i(r)   ∈ {1, 2, 3, 4}
1 = epizodické pravidlo (len v 1 roku)
4 = stabilné pravidlo (vo všetkých 4 rokoch)
```

Časté otázky pri obhajobe: - **Q:** Prečo set namiesto list? **A:** O(1) membership test pre `p in pravidla_po_obdobiach[rok]`. - **Q:** Aké riziko má string-konkatenácia? **A:** Ak by úloha 02 zoradila položky rôzne medzi rokmi, brali by sme rovnaké pravidlá ako rôzne → nadhodnotenie počtu. - **Q:** Prečo `set().union(*sets)`? **A:** Zjednotenie všetkých množín → univerzálna množina vzorov, každé pravidlo presne raz.

Úloha 04: cochran_kendall_test.py

Teoretický základ: Toto je jadro fázy **Vyhodnotenie výsledkov** podľa CRISP-DM. Prednáška 10 explicitne uvádza, že vo fáze vyhodnotenia výsledkov sa **overujú predpoklady použitia** (rozdelenie premennej, rovnosť rozptylov, nezávislosť premenných) a **porovnávajú sa výsledky** medzi obdobiami pomocou testov o strednej hodnote a ich **neparametrických alternatív**. Cochranov Q test je presne takou neparametrickou alternatívou pre **k závislých binárnych vzoriek** — vhodný pre náš prípad (tie isté pravidlá merané v 4 obdobiach). Kendallovo W dopĺňa Q o silu efektu. Súčasťou výstupu je aj **vizualizácia rozdielov empirických a teoretických početností**, ktorú prednáška spomína ako súčasť popisnej štatistiky vo fáze vyhodnotenia. *(viď prednáška 10 — Vyhodnotenie výsledkov, vizualizácie)*

Čo robí: Štatistická metaanalýza — Cochranov Q test + Kendallovo W + popisné štatistiky + 2-panelový bar graf.

Vstup → výstup: - `in/matica_pravidiel.csv` (450 × 6) - `out/analyza.png` (2 panely: počty po obdobiach + distribúcia stability) - stdout: Q-štatistika, p-value, df, W, počty pravidiel na obdobie, unikátne pravidlá

Kľúčové kroky: 1. Načítanie matice, dynamický výber stĺpcov `[c for c in cols if c.startswith("O")]` 2. `binarna_matica = matica[obdobia_stlpce].values` (ndarray 450×4) 3. `cochrans_q(binarna_matica)` → `.statistic, .pvalue, .df` 4. Výpočet `W = Q / (n · (k-1))` 5. Popisné štatistiky: počty na obdobie, value_counts(pocet_obdobi), unikátne pre obdobie 6. `plt.subplots(1,2)` — 2-panelový bar graf

Dôležité parametre: - `cochrans_q` — z `statsmodels.stats.contingency_tables` - `α = 0.05` — typická hladina významnosti - `axis=1` — sum po riadkoch - `startswith("O")` — robustný selektor stĺpcov období

Vzorec / formula:

```
Cochranov Q test:
  H0: P(výskyt) rovnaká vo všetkých k obdobiach
  Q ~ chi² s df = k-1
  Zamietame H0 ak p < α

Kendallovo W (z Cochranovej Q pri binárnych dátach):
  W = Q / (n · (k - 1))
  W ∈ [0, 1]
  0 = žiadna zhoda, 1 = perfektná zhoda

Interpretácia W:
  W < 0.3   → slabá zhoda
  0.3-0.5   → stredná zhoda
  0.5-0.7   → silnejšia zhoda
  W ≥ 0.7   → silná/perfektná zhoda
```

Predpoklady Cochranovho Q: 1. **Závislé** vzorky (rovnaké subjekty merané k-krát) — splnené, tie isté pravidlá v 4 obdobiach 2. **Binárne** premenné (0/1) — splnené 3. **Dostatočné n** (≥ 4·k) — 450 >> 16

Časté otázky pri obhajobe: - **Q:** Prečo Cochran Q? **A:** Je to neparametrický test pre k≥2 závislých binárnych vzoriek; presne to máme (pravidlá × obdobia). Prednáška 10 explicitne uvádza neparametrické alternatívy testov o strednej hodnote ako nástroj fázy Vyhodnotenie výsledkov. *(viď prednáška 10)* - **Q:** Čo nepovie Cochran Q? **A:** Iba ČI rozdiely existujú, NIE KDE a AKO SILNÉ → preto dopĺňame Kendallovo W. - **Q:** Kedy je Cochran Q ekvivalentný McNemarovi? **A:** Pre k=2 (Cochran Q je zovšeobecnenie McNemara na k>2). - **Q:** Ako interpretovať p=0.0001? **A:** Zamietame H0 → pravdepodobnosť výskytu pravidiel sa medzi obdobiami signifikantne líši. -

Q: Do ktorej fázy CRISP-DM patrí tento test? **A:** Do fázy **Vyhodnotenie výsledkov** — porovnanie výsledkov medzi obdobiami. *(viď prednáška 10)*

🎯 Na čo si dať pozor pri obhajobe

1. **Vzorce naspamäť**: support = P(X∪Y), confidence = support(X∪Y)/support(X), lift = conf/P(Y), W = Q/(n·(k-1))
2. **Anti-monotónia** vysvetliť ako základ orezávania v Apriori bottom-up
3. **Cochran Q vs Kendall W** — Q hovorí ČI, W hovorí KOĽKO; dohromady dávajú celý obraz
4. **Edge cases**: prečo košík ≥2 položky, prečo sorted(set()), prečo set namiesto list, prečo low_memory=False
5. **Počty výstupov**: 102481 záznamov po dropna, 4 CSV transakcií (37734/18996/21473/24278), 4 CSV pravidiel (341/405/205/17), matica 450×6, df=3
6. **Kontext WUM pipeline**: kde sa úloha 06 napája na cv2 (sedenia) a kam smeruje (vyhodnotenie metaanalýzy)
7. **Mapovanie na CRISP-DM**: úlohy 01–02 = fáza **Modelovanie / Analýza závislostí** (prednáška 9), úlohy 03–04 = fáza **Vyhodnotenie výsledkov** (prednáška 10) — porovnanie výsledkov a vizualizácia
8. **Prečo neparametrický test?** Prednáška 10 zdôrazňuje, že vo fáze Vyhodnotenie sa **overujú predpoklady použitia** — pri binárnych dátach a malom počte období (k=4) sú parametrické testy nevhodné, preto **Cochranovo Q** ako neparametrická alternatíva.