ZDROJE DÁT I

Prednáška 2

Michal Munk

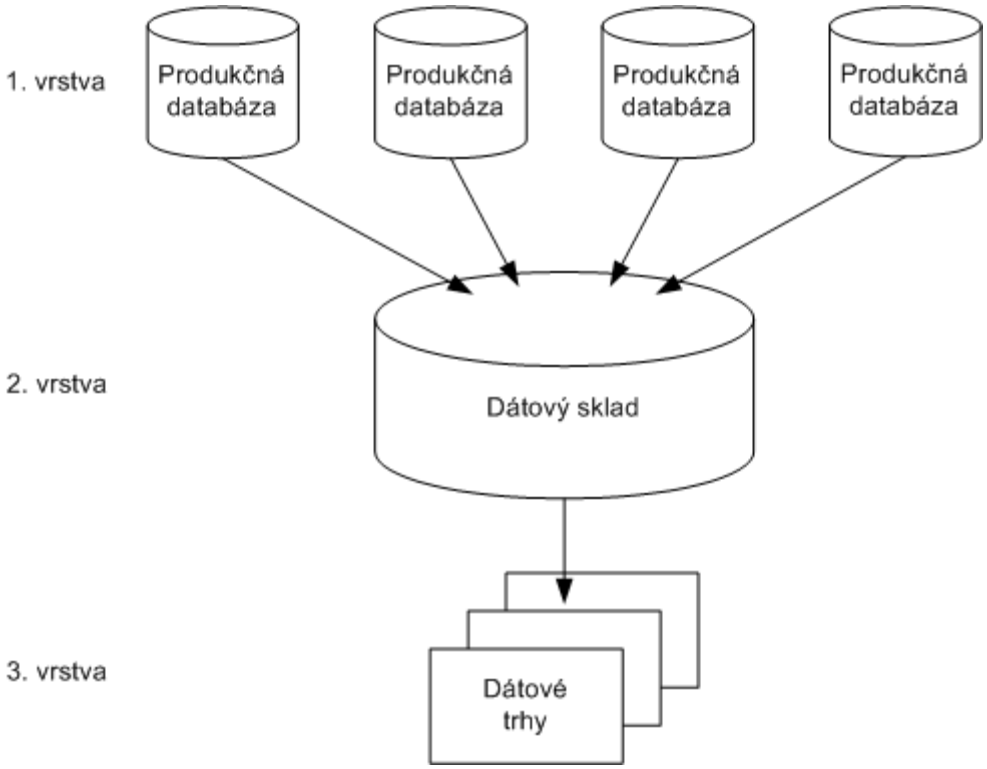
ZDROJE DÁT

- Databázy
  - Produkčné databázy
  - Dátové sklady
  - Verejné databázy
- Text
  - Kolekcie elektronických dokumentov
- Web
  - Obsah
  - Mapa webu
  - Logovacie súbory
- ..

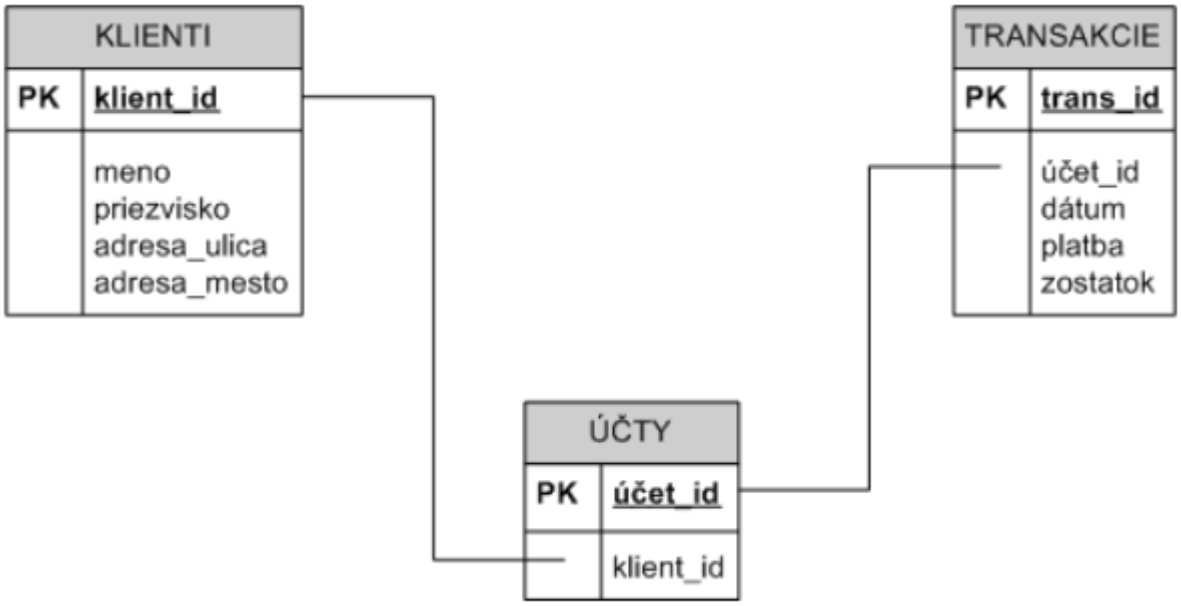
DATABÁZY

- Produkčné databázy
- Dátové sklady
  - Subjektovo orientovaný
  - Integrovaný
  - Časovo premenný
  - Nemenný
- Verejné databázy
  - Verejná databáza DATAcube - RegDat
  - Databáza STATdat
  - Databázy Eurostatu
  - ..

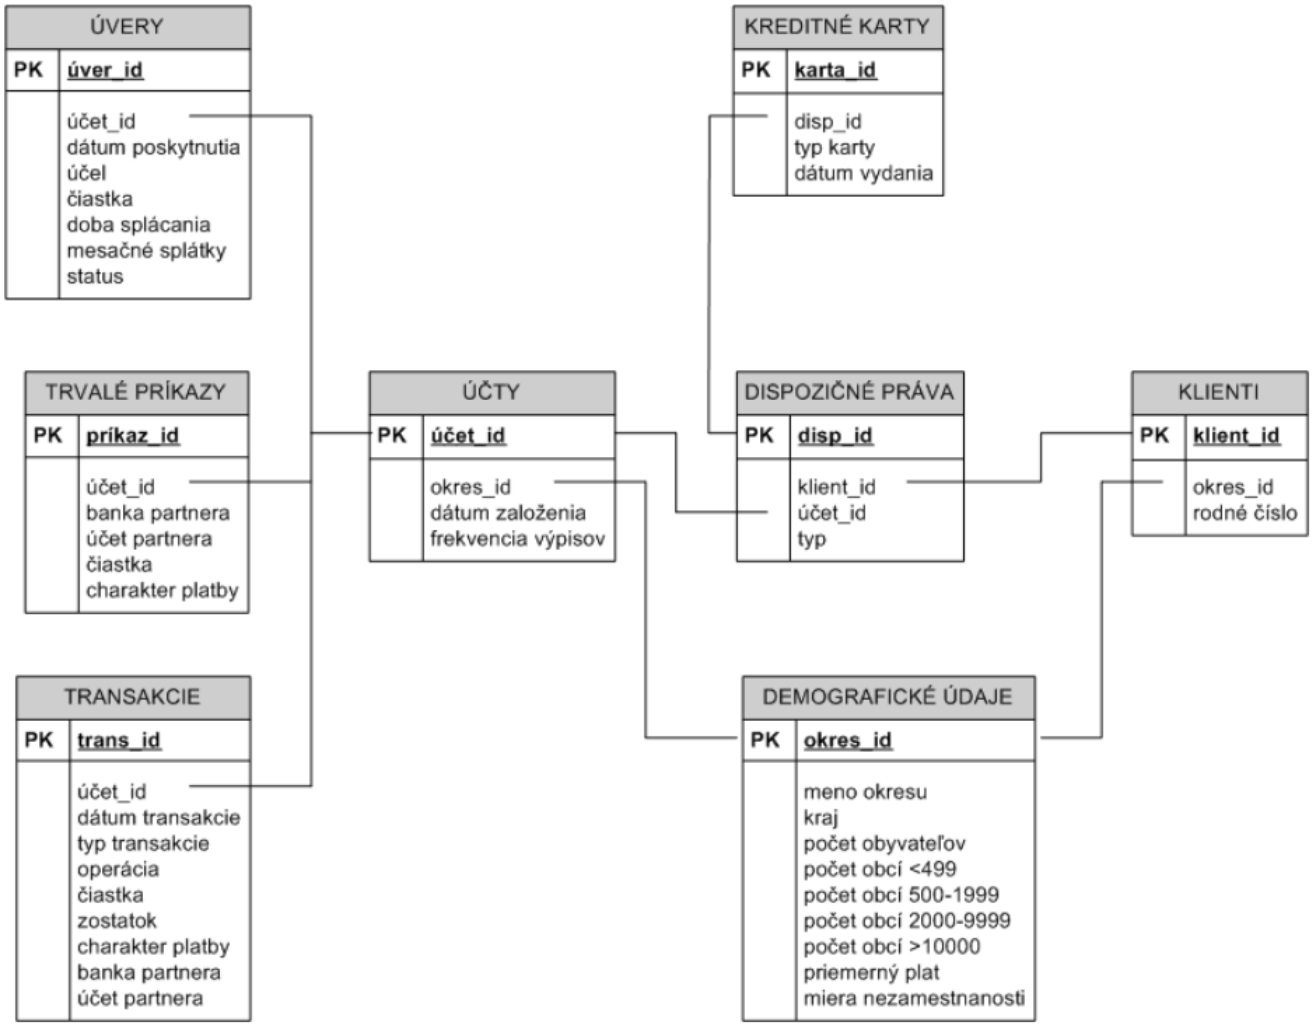
TROJVRSTVOVÁ ARCHITEKTÚRA DÁTOVÉHO SKLADU



DATABÁZA BANKY



DATABÁZA BANKY + RegDat



TEXT

- Kolekcie elektronických dokumentov
  - Kvalifikačné práce
  - Lekárske správy popisujúce symptómy
  - Otvorené odpovede v dotazníkoch
  - ..
- Obsah webu
  - Webové stránky
  - Textové príspevky – tweety, statusy, blogy
  - Diskusie
  - ..

VEKTOROVÁ REPREZENTÁCIA TEXTU

- world frequency

$$wf$$

- binary frequency

$$f(wf) = 1, \text{ pre } wf > 0$$

- log frequency

$$f(wf) = 1 + log(wf), \text{ pre } wf > 0$$

VEKTOROVÁ REPREZENTÁCIA TEXTU

- inverse document frequency

$$idf(i,j) = \begin{cases} 0, ak\ wf_{i,j} = 0 \\ \left(1 + \log\left(wf_{i,j}\right)\right) log\,\frac{N}{df_i}, ak\ wf_{i,j} \geq 1 \end{cases}'$$

kde $(1 + \log(wf_{i,j}))$ predstavuje počet výskytov kmeňového slova v dokumente, df_i je počet výskytov kmeňového slova v celej kolekcii dokumentov (počet dokumentov, ktoré obsahujú *i*-te slovo) a *N* udáva počet dokumentov v kolekcii

VEKTOROVÁ REPREZENTÁCIA TEXTU

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	36	91	72	3	4	71	18	60	19	1	58
dok2	36	68	85	50	81	80	36	64	83	61	74
dok3	36	98	8	0	78	25	70	0	83	87	32
dok4	24	82	64	10	2	64	61	43	98	41	51
dok5	84	17	39	59	64	0	93	49	33	49	29
dok6	0	0	48	0	32	80	72	0	41	44	67
dok7	29	77	65	51	47	33	63	89	87	92	0
dok8	87	79	69	70	7	68	96	72	45	14	47
dok9	27	47	75	8	47	69	59	43	31	26	82
dok10	52	4	85	0	85	59	43	89	65	59	9

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	1	1	1	1	1	1	1	1	1	1	1
dok2	1	1	1	1	1	1	1	1	1	1	1
dok3	1	1	1	0	1	1	1	0	1	1	1
dok4	1	1	1	1	1	1	1	1	1	1	1
dok5	1	1	1	1	1	0	1	1	1	1	1
dok6	0	0	1	0	1	1	1	0	1	1	1
dok7	1	1	1	1	1	1	1	1	1	1	0
dok8	1	1	1	1	1	1	1	1	1	1	1
dok9	1	1	1	1	1	1	1	1	1	1	1
dok10	1	1	1	0	1	1	1	1	1	1	1

VEKTOROVÁ REPREZENTÁCIA TEXTU

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	36	91	72	3	4	71	18	60	19	1	58
dok2	36	68	85	50	81	80	36	64	83	61	74
dok3	36	98	8	0	78	25	70	0	83	87	32
dok4	24	82	64	10	2	64	61	43	98	41	51
dok5	84	17	39	59	64	0	93	49	33	49	29
dok6	0	0	48	0	32	80	72	0	41	44	67
dok7	29	77	65	51	47	33	63	89	87	92	0
dok8	87	79	69	70	7	68	96	72	45	14	47
dok9	27	47	75	8	47	69	59	43	31	26	82
dok10	52	4	85	0	85	59	43	89	65	59	9

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	2.5563	2.95904	2.85733	1.47712	1.60206	2.85126	2.25527	2.77815	2.27875	1	2.76343
dok2	2.5563	2.83251	2.92942	2.69897	2.90849	2.90309	2.5563	2.80618	2.91908	2.78533	2.86923
dok3	2.5563	2.99123	1.90309	0	2.89209	2.39794	2.8451	0	2.91908	2.93952	2.50515
dok4	2.38021	2.91381	2.80618	2	1.30103	2.80618	2.78533	2.63347	2.99123	2.61278	2.70757
dok5	2.92428	2.23045	2.59106	2.77085	2.80618	0	2.96848	2.6902	2.51851	2.6902	2.4624
dok6	0	0	2.68124	0	2.50515	2.90309	2.85733	0	2.61278	2.64345	2.82607
dok7	2.4624	2.88649	2.81291	2.70757	2.6721	2.51851	2.79934	2.94939	2.93952	2.96379	0
dok8	2.93952	2.89763	2.83885	2.8451	1.8451	2.83251	2.98227	2.85733	2.65321	2.14613	2.6721
dok9	2.43136	2.6721	2.87506	1.90309	2.6721	2.83885	2.77085	2.63347	2.49136	2.41497	2.91381
dok10	2.716	1.60206	2.92942	0	2.92942	2.77085	2.63347	2.94939	2.81291	2.77085	1.95424

VEKTOROVÁ REPREZENTÁCIA TEXTU

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	36	91	72	3	4	71	18	60	19	1	58
dok2	36	68	85	50	81	80	36	64	83	61	74
dok3	36	98	8	0	78	25	70	0	83	87	32
dok4	24	82	64	10	2	64	61	43	98	41	51
dok5	84	17	39	59	64	0	93	49	33	49	29
dok6	0	0	48	0	32	80	72	0	41	44	67
dok7	29	77	65	51	47	33	63	89	87	92	0
dok8	87	79	69	70	7	68	96	72	45	14	47
dok9	27	47	75	8	47	69	59	43	31	26	82
dok10	52	4	85	0	85	59	43	89	65	59	9

	kmen1	kmen2	kmen3	kmen4	kmen5	kmen6	kmen7	kmen8	kmen9	kmen10	kmen11
dok1	0.11697	0.1354	0	0.22881	0	0.13047	0	0.26923	0	0	0.12645
dok2	0.11697	0.12961	0	0.41808	0	0.13284	0	0.27195	0	0	0.13129
dok3	0.11697	0.13687	0	0	0	0.10972	0	0	0	0	0.11463
dok4	0.10891	0.13333	0	0.3098	0	0.1284	0	0.25521	0	0	0.12389
dok5	0.13381	0.10206	0	0.42921	0	0	0	0.26071	0	0	0.11267
dok6	0	0	0	0	0	0.13284	0	0	0	0	0.12931
dok7	0.11267	0.13208	0	0.41941	0	0.11524	0	0.28583	0	0	0
dok8	0.13451	0.13259	0	0.44071	0	0.12961	0	0.2769	0	0	0.12227
dok9	0.11125	0.12227	0	0.29479	0	0.1299	0	0.25521	0	0	0.13333
dok10	0.12428	0.07331	0	0	0	0.12679	0	0.28583	0	0	0.08942