CRISP-DM I

Prednáška 5

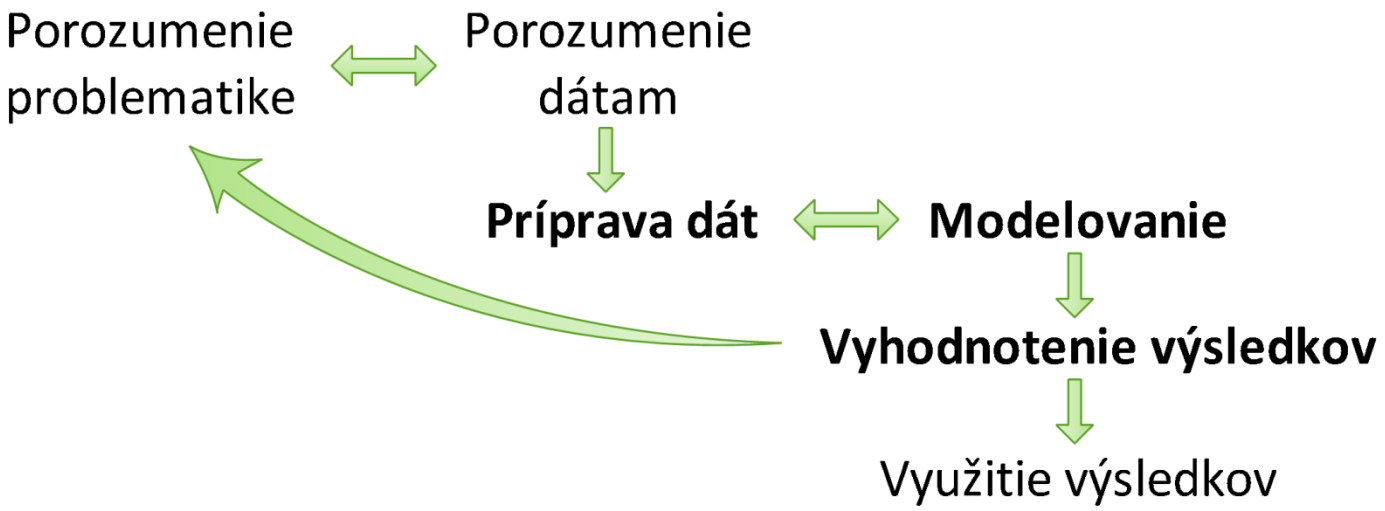
Michal Munk

FÁZY PROCESU WEB LOG MININGU

Proces objavovania znalostí na základe používania webu sa rozdeľuje do troch základných častí:

Predspracovanie ⇒ **Objavovanie vzorov** ⇒ **Analýza vzorov**

Metodika CRISP-DM, fázy procesu:



Porozumenie problematike

Typy problémov - úloh:

- Deskripcia dát a sumarizácia
- Segmentácia
- Deskripcia konceptov
- Klasifikácia
- Predikcia
- Analýza závislostí

Porozumenie dátam

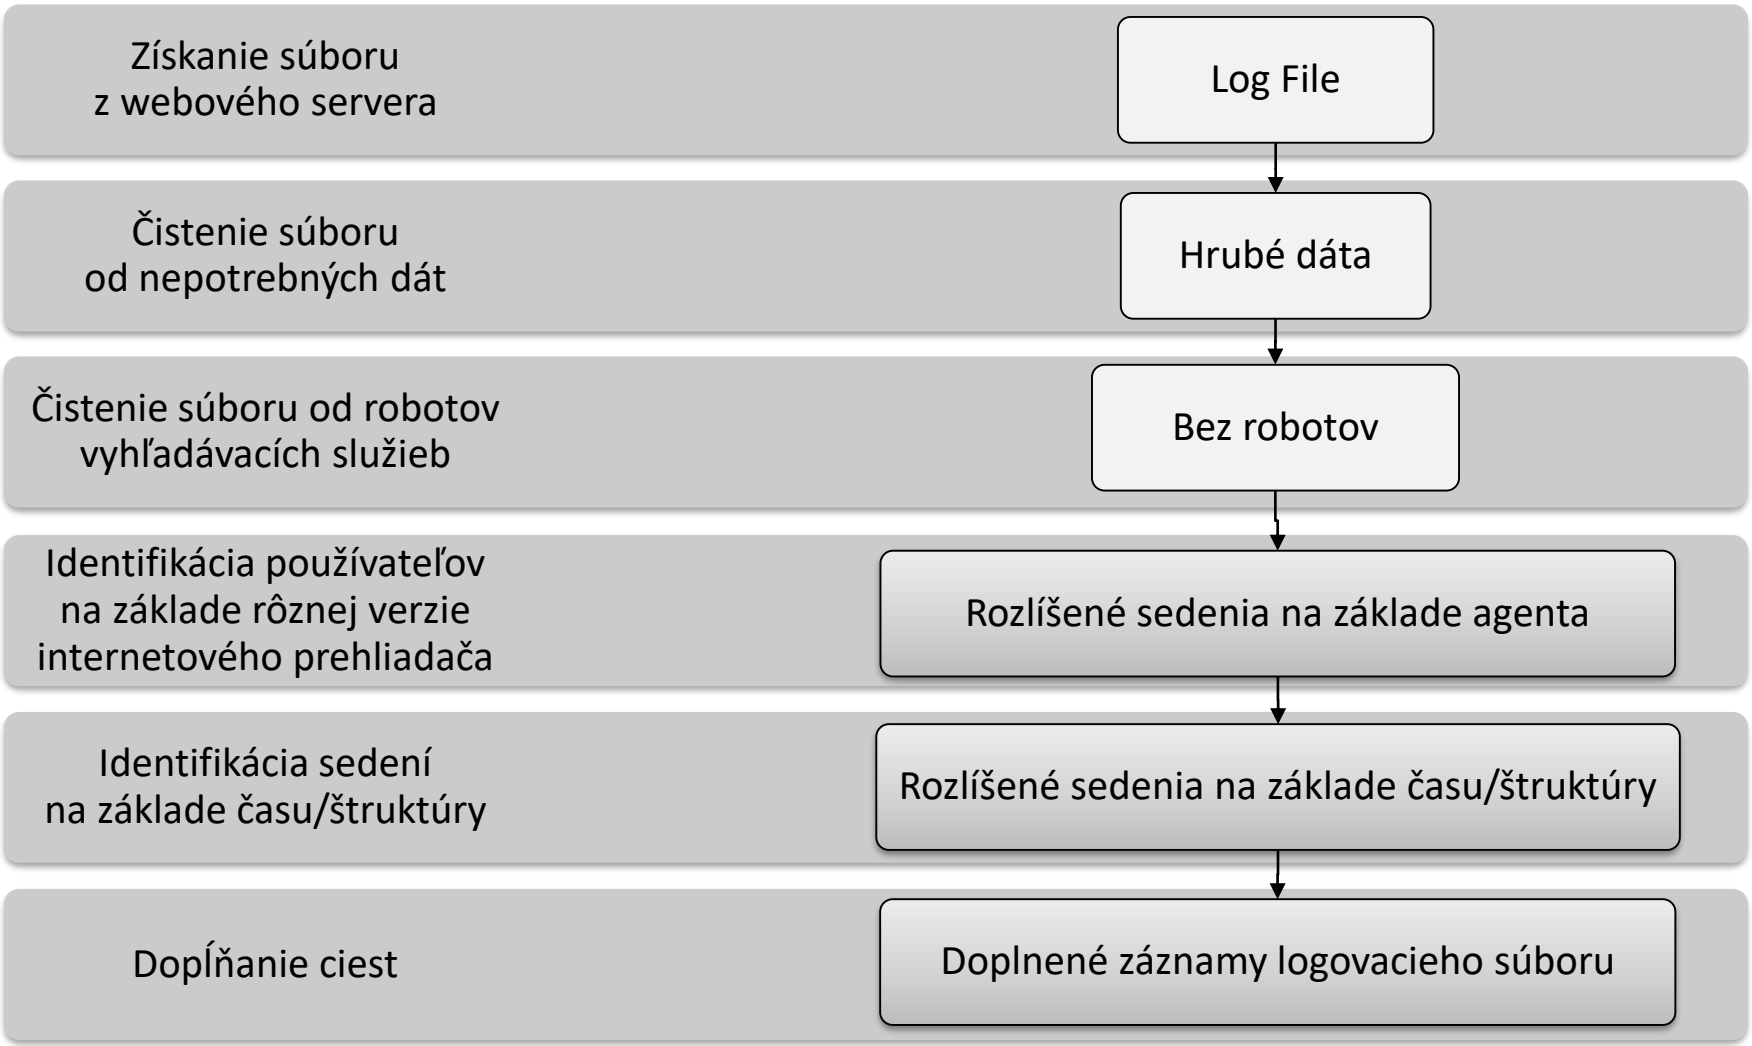
- Informačné systémy - dáta vo vlastnej štruktúre, organizované v databáze
- Web/proxy servery - dáta v spoločnej štandardnej štruktúre, v textovom formáte

178.41.1.187 - - [16/Dec/2019:18:16:26 +0100] "GET /studium/akreditovane-programy HTTP/1.1" 200 15364 "http://www.ukf.sk/studium" "Mozilla/5.0 (Windows; U; Windows NT 5.1; sk; rv:1.9.2.13) Gecko/20101203 Firefox/3.6.13 BLNGBAR"

...

FÁZY PROCESU:

Príprava dát



Príprava dát

GET / HTTP/1.1

GET /favicon.ico HTTP/1.1

GET /templates/system/css/system.css HTTP/1.1
GET /templates/system/css/general.css HTTP/1.1
GET /templates/newukf/js/hs.css HTTP/1.1
GET /templates/newukf/css/template.css HTTP/1.1
GET /templates/newukf/css/editor_content.css HTTP/1.1

GET /templates/newukf/js/ja.script.js HTTP/1.1
GET /media/system/js/mootools.js HTTP/1.1
GET /media/system/js/caption.js HTTP/1.1
GET /templates/newukf/js/highslide.js HTTP/1.1

GET /templates/newukf/images/user-increase.png HTTP/1.1
GET /templates/newukf/images/ukf_header_logo.png HTTP/1.1
GET /templates/newukf/images/en.gif HTTP/1.1
GET /dokumenty/images/reklama/e-prihlaska.gif HTTP/1.1
GET /templates/newukf/images/ukf_budova_jesen.jpg HTTP/1.1

Príprava dát

Identifikácia robotov:

- na základe poľa User-Agent, resp. IP adresy
- na základe prístupu k súboru robots.txt v adresári servera
- na základe prístupu k skrytému odkazu

Agent
msnbot/1.1 (+http://search.msn.com/msn**bot**.htm)
ia_archiver (+http://www.alexa.com/site/help/webmasters; **crawler**@alexa.com)
Mozilla/5.0 (compatible; Google**bot**/2.1; +http://www.google.com/bot.html)

IP adresa	Host
65.55.110.205	msn**bot**-65-55-110-205.search.msn.com
74.6.18.226	llf520148.**crawl**.yahoo.net
77.88.27.25	**spider**27.yandex.ru