CRISP-DM II

Prednáška 6

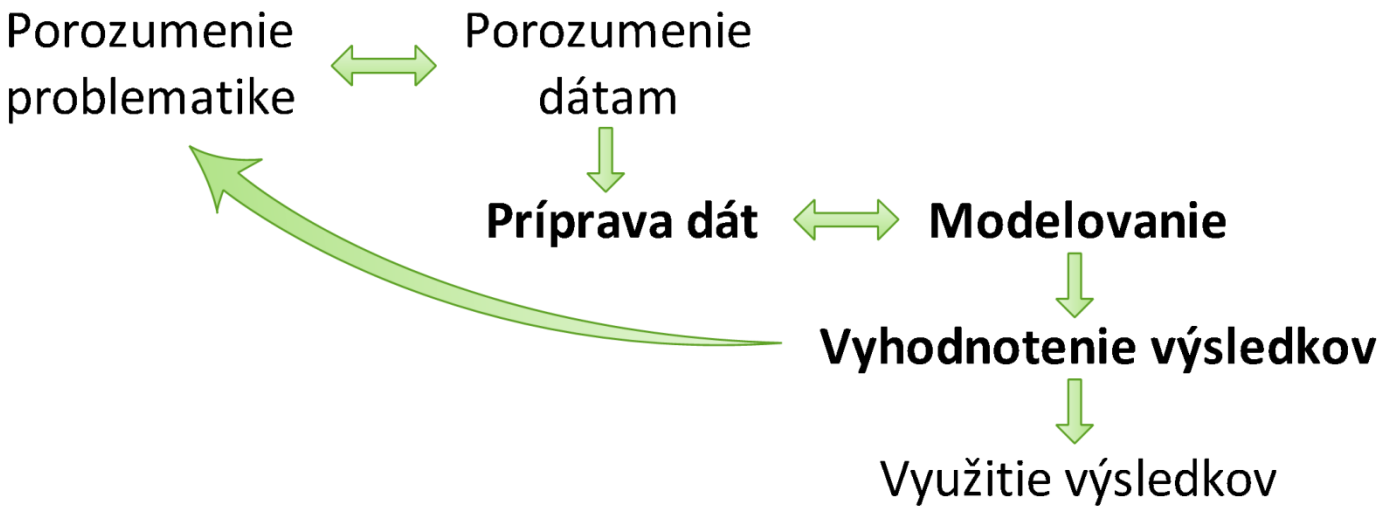
Michal Munk

FÁZY PROCESU WEB LOG MININGU

Proces objavovania znalostí na základe používania webu sa rozdeľuje do troch základných častí:

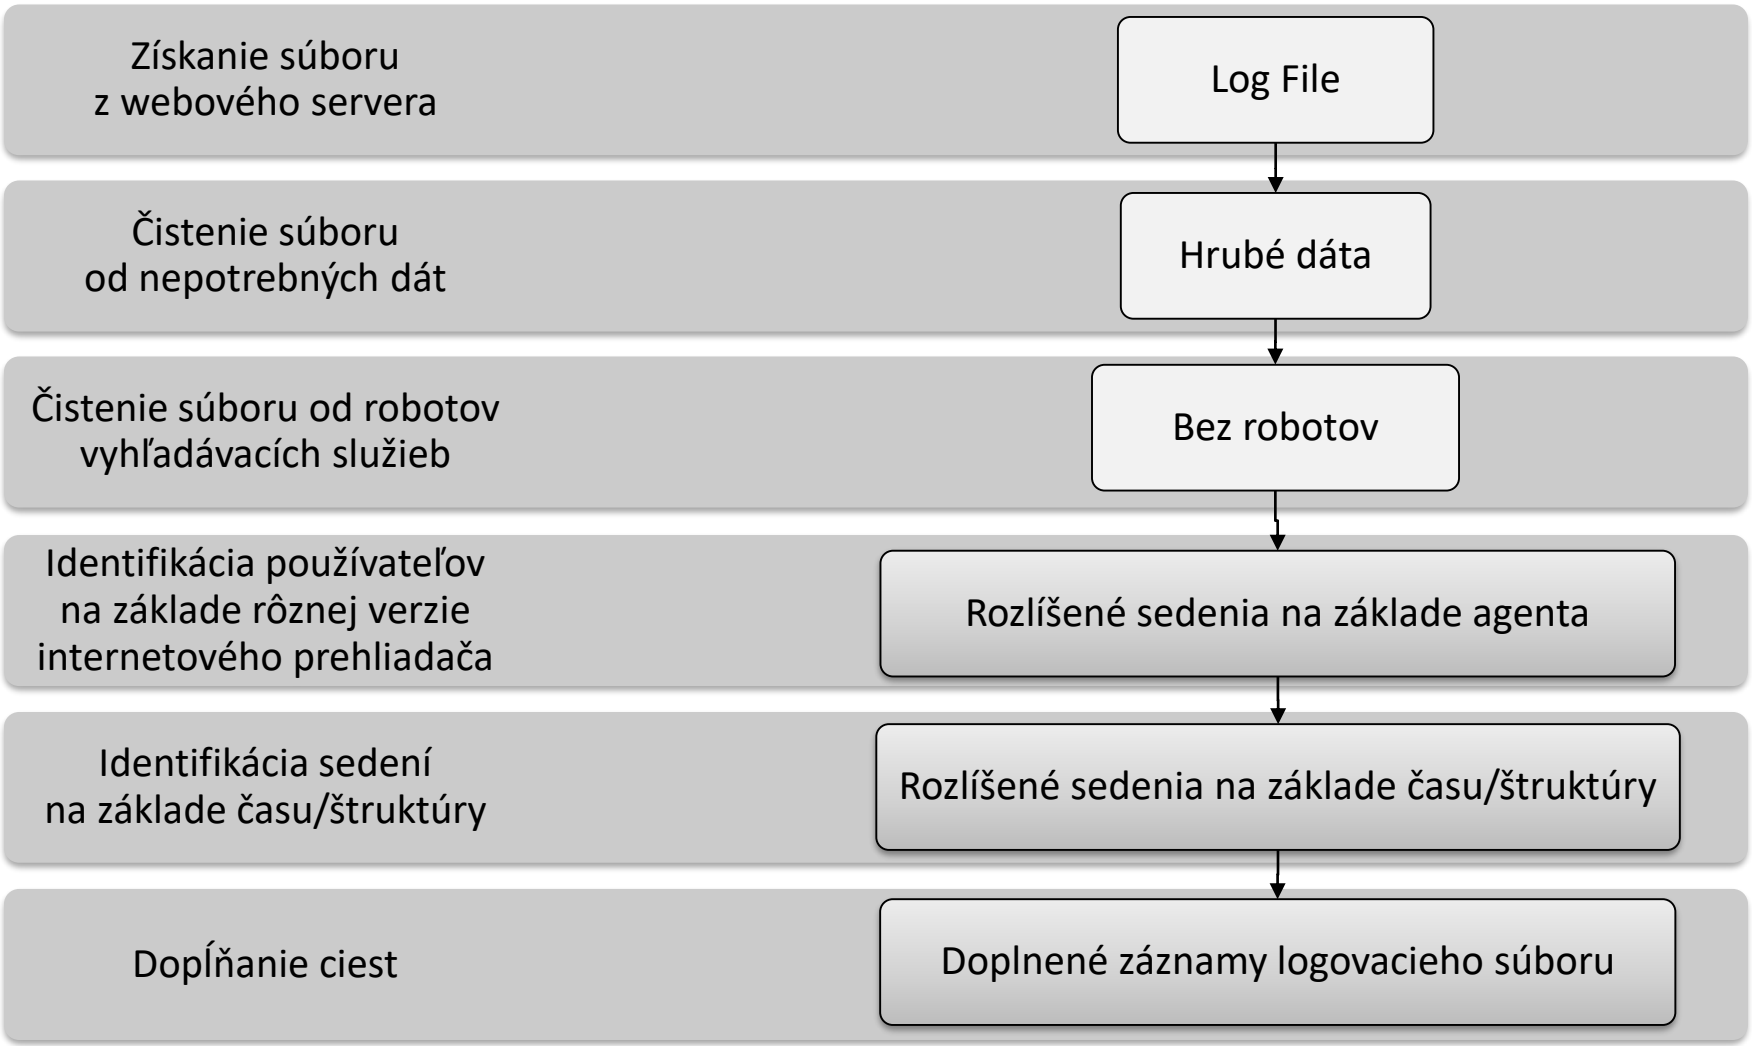
Predspracovanie ⇒ **Objavovanie vzorov** ⇒ **Analýza vzorov**

Metodika CRISP-DM, fázy procesu:



FÁZY PROCESU:

Príprava dát



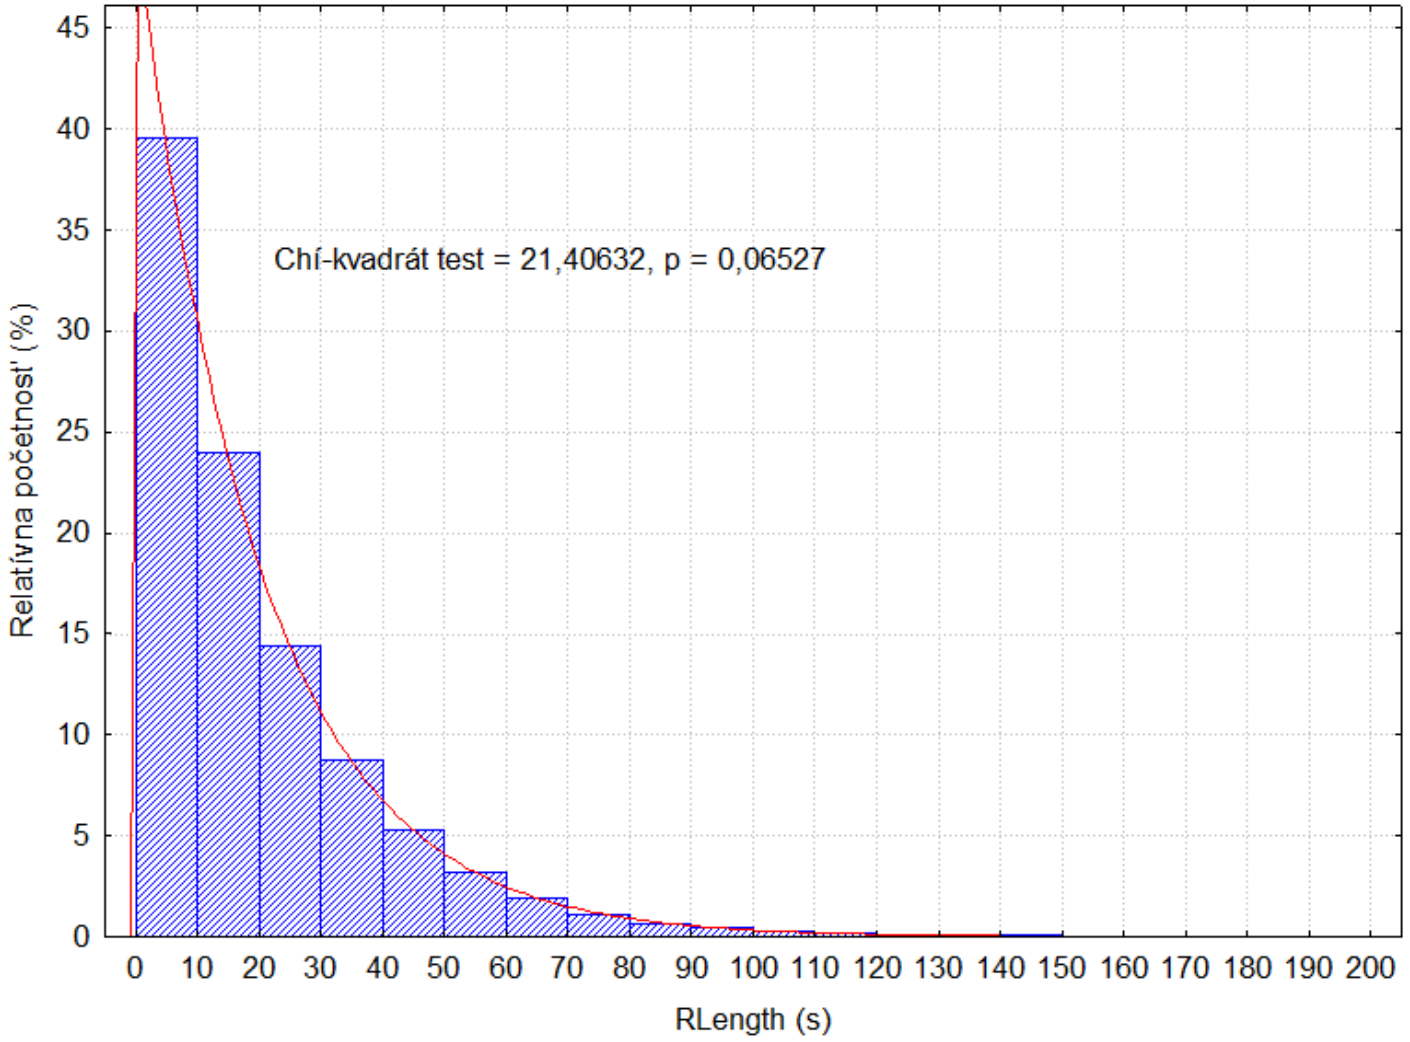
Príprava dát

Identifikácia používateľov/sedení:

- na základe rôznej verzie internetového prehliadača
- na základe štruktúry prehľadávaných stránok
- na základe času

```
178.41.1.187 - - [16/Dec/2019:18:16:26 +0100] "GET " ..
178.41.1.187 - - [16/Dec/2019:18:19:47 +0100] "GET /studium " ..
178.41.1.187 - - [16/Dec/2019:18:52:37 +0100] "GET /studium/akreditovane-programy "..
178.41.1.187 - - [16/Dec/2019:18:54:25 +0100] "GET /prijimaciekonanie " ..
178.41.1.187 - - [16/Dec/2019:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "..
```

Príprava dát



Príprava dát

Premenná $RLength$ má exponenciálne rozdelenie

$$f(RLength) = \lambda e^{-\lambda RLength},$$
$$F(RLength) = 1 - e^{-\lambda RLength},$$

kde $RLength \geq 0$

Ak je p relatívna početnosť navigačných stránok, na odhad hraničného času C môžeme použiť kvantilovú funkciu

$$F^{-1}(p, \lambda) = C = \frac{-\ln(1-p)}{\lambda}$$

pre $0 \leq p < 1$

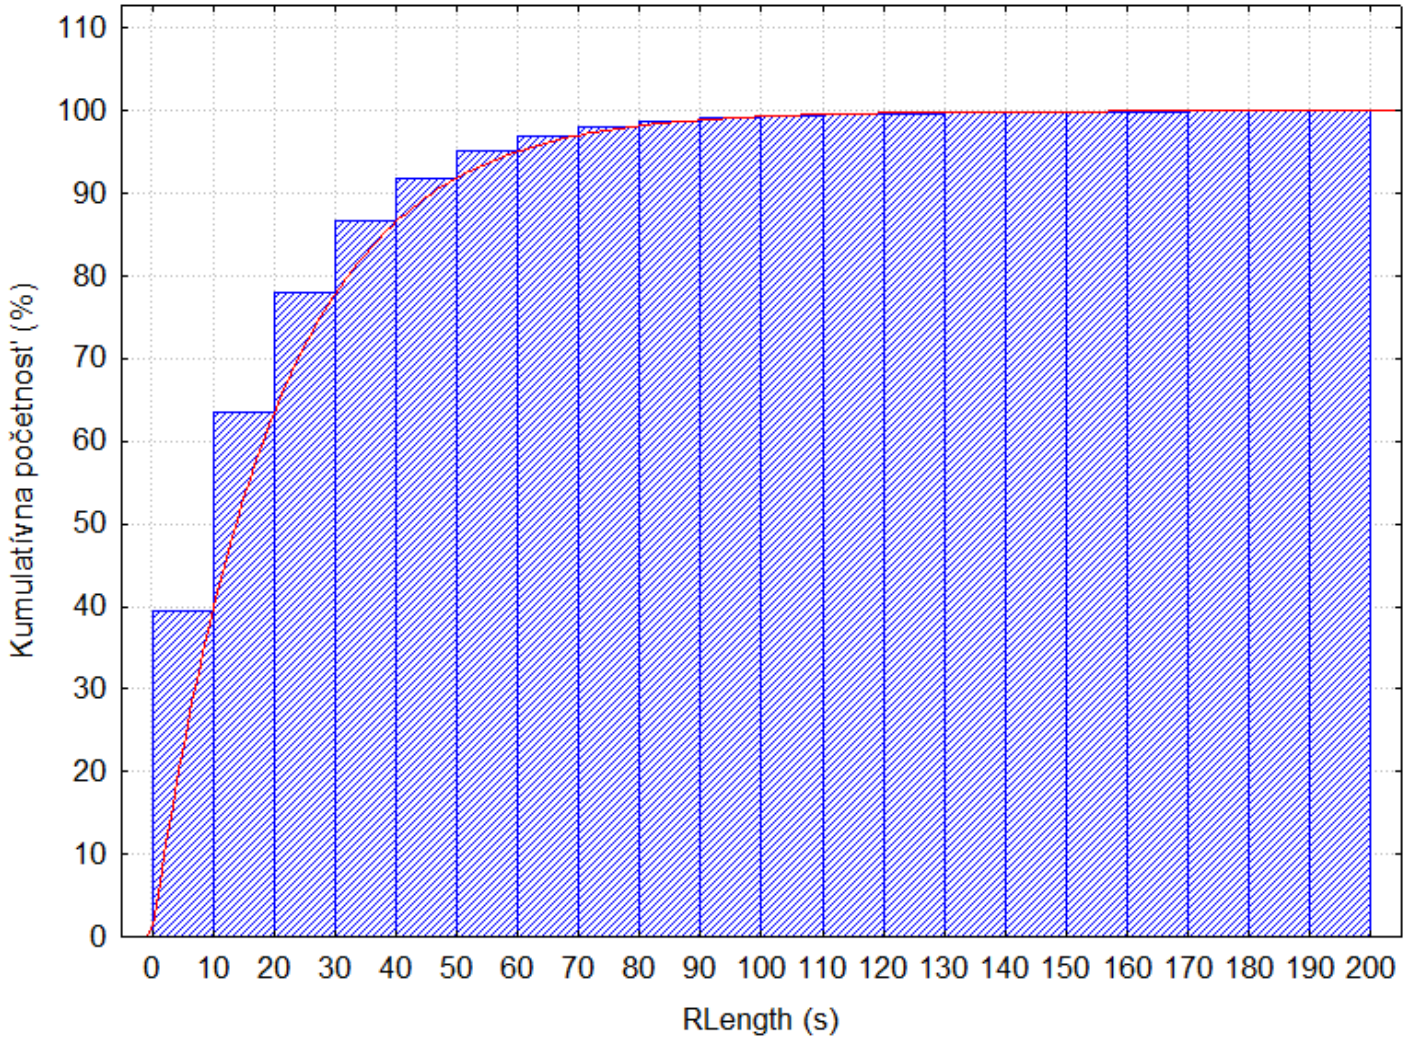
Maximálne vierohodný odhad parametra λ (priemerná intenzita udalostí) je

$$\hat{\lambda} = \frac{1}{\overline{RLength}},$$

kde $\overline{RLength}$ je pozorovaný priemer dĺžky návštev

FÁZY PROCESU:

Príprava dát



Príprava dát

Ak máme odhad hraničného času C, tak sedenie je sekvencia navštívených stránok s časovou známkou, pre ktorú platí:

$$\langle USID, \langle URL_1, DTime_1, RLength_1 \rangle, \dots, \langle URL_k, DTime_k, RLength_k \rangle \rangle,$$

$$RLength_i \leq C, \qquad (1)$$

kde $1 \leq i < k$ a pre poslednú stránku sedenia platí:

$$RLength_k > C \qquad (2)$$

Od stránky s vlastnosťou (2) je definované ďalšie sedenie

Príprava dát

