CRISP-DM III

Prednáška 7

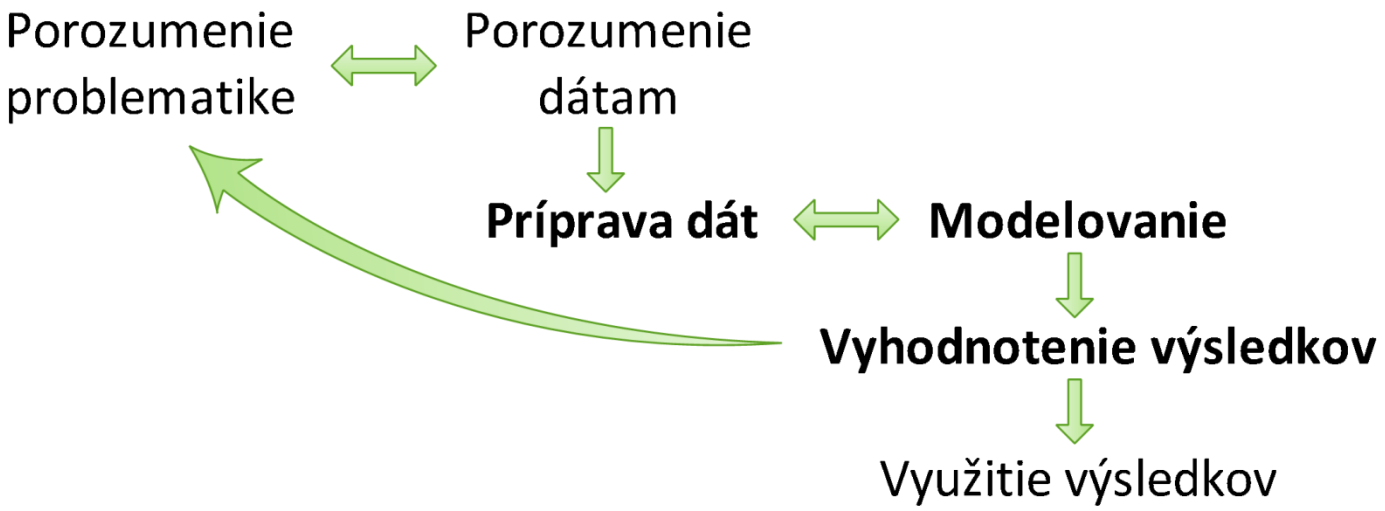
Michal Munk

FÁZY PROCESU WEB LOG MININGU

Proces objavovania znalostí na základe používania webu sa rozdeľuje do troch základných častí:

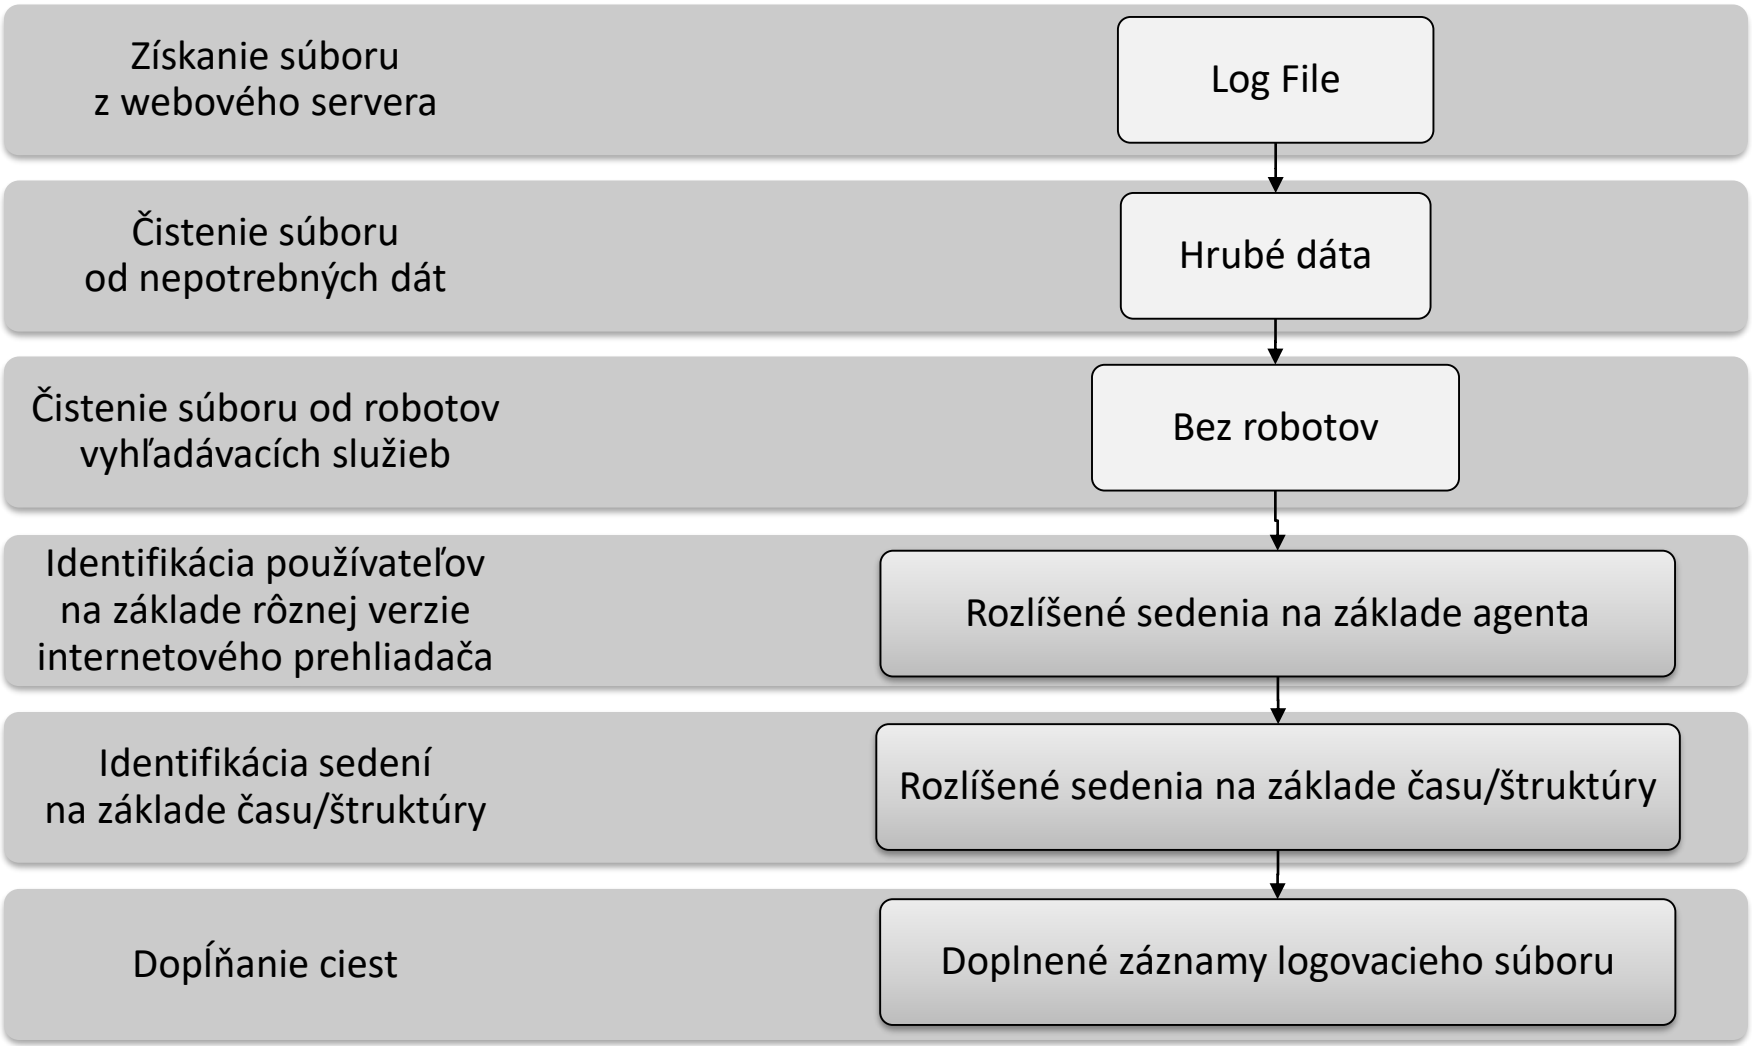
Predspracovanie ⇒ **Objavovanie vzorov** ⇒ **Analýza vzorov**

Metodika CRISP-DM, fázy procesu:



FÁZY PROCESU:

Príprava dát



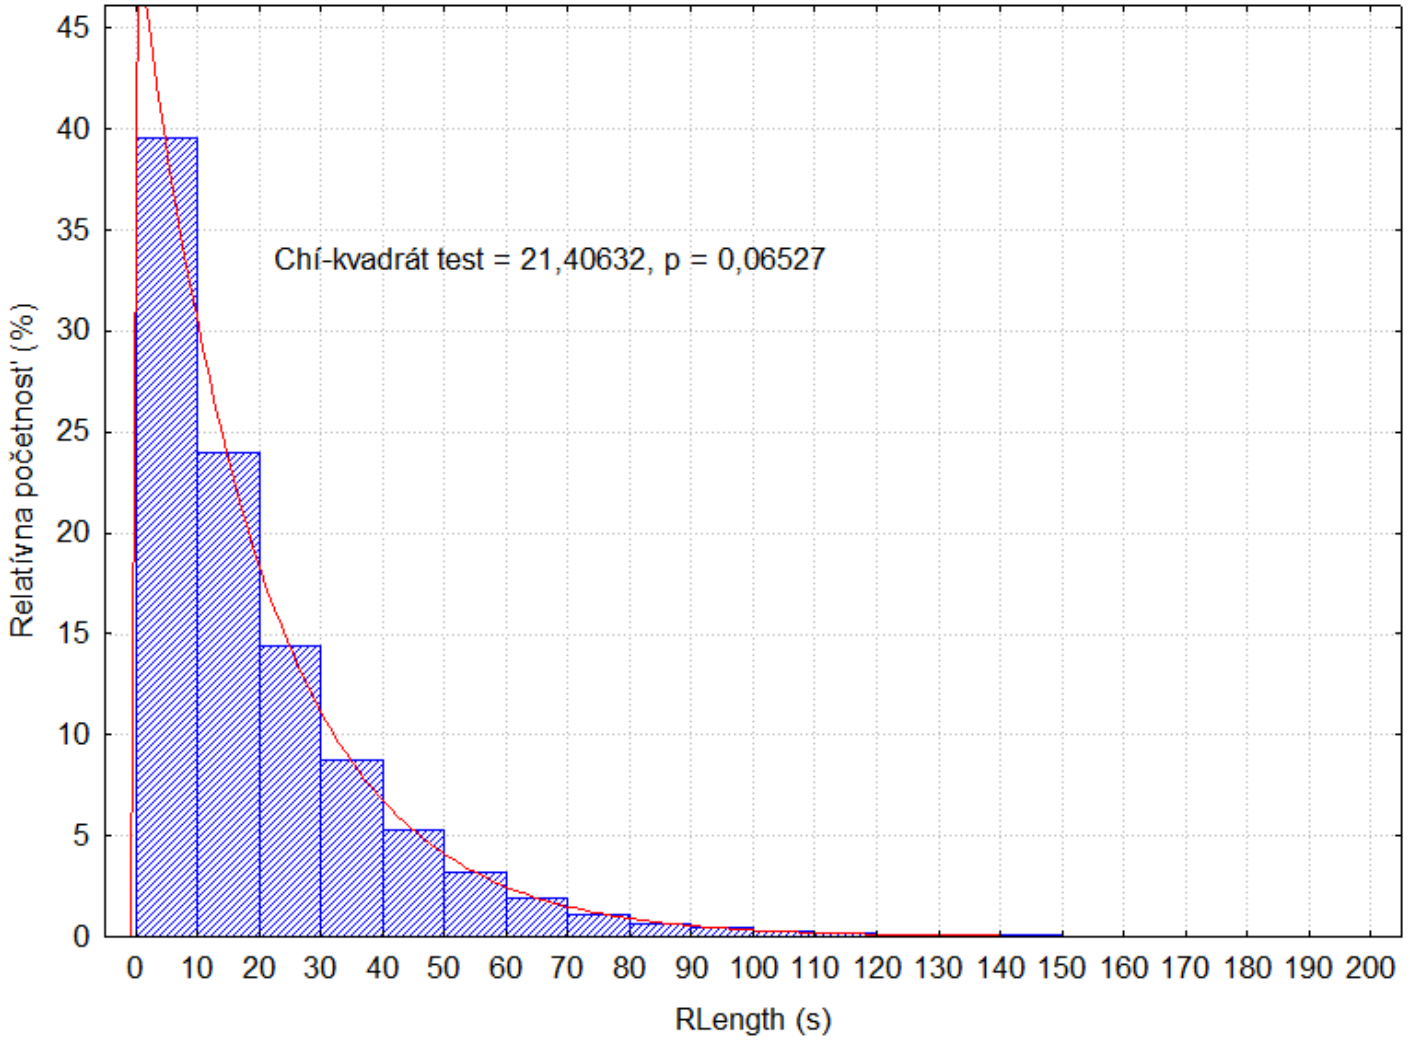
Príprava dát

Identifikácia používateľov/sedení:

- na základe rôznej verzie internetového prehliadača
- na základe štruktúry prehľadávaných stránok
- na základe času

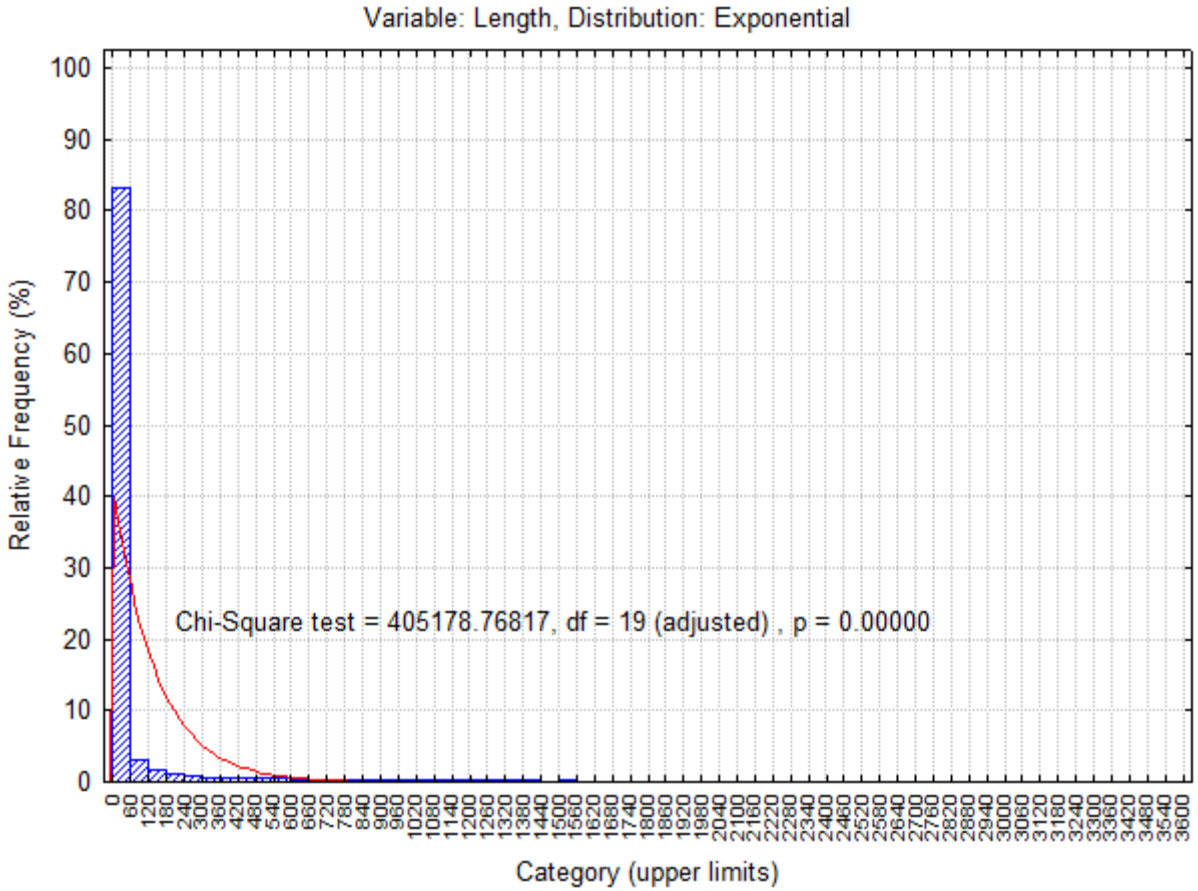
```
178.41.1.187 - - [16/Dec/2019:18:16:26 +0100] "GET " ..
178.41.1.187 - - [16/Dec/2019:18:19:47 +0100] "GET /studium " ..
178.41.1.187 - - [16/Dec/2019:18:52:37 +0100] "GET /studium/akreditovane-programy "..
178.41.1.187 - - [16/Dec/2019:18:54:25 +0100] "GET /prijimaciekonanie " ..
178.41.1.187 - - [16/Dec/2019:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "..
```

Príprava dát

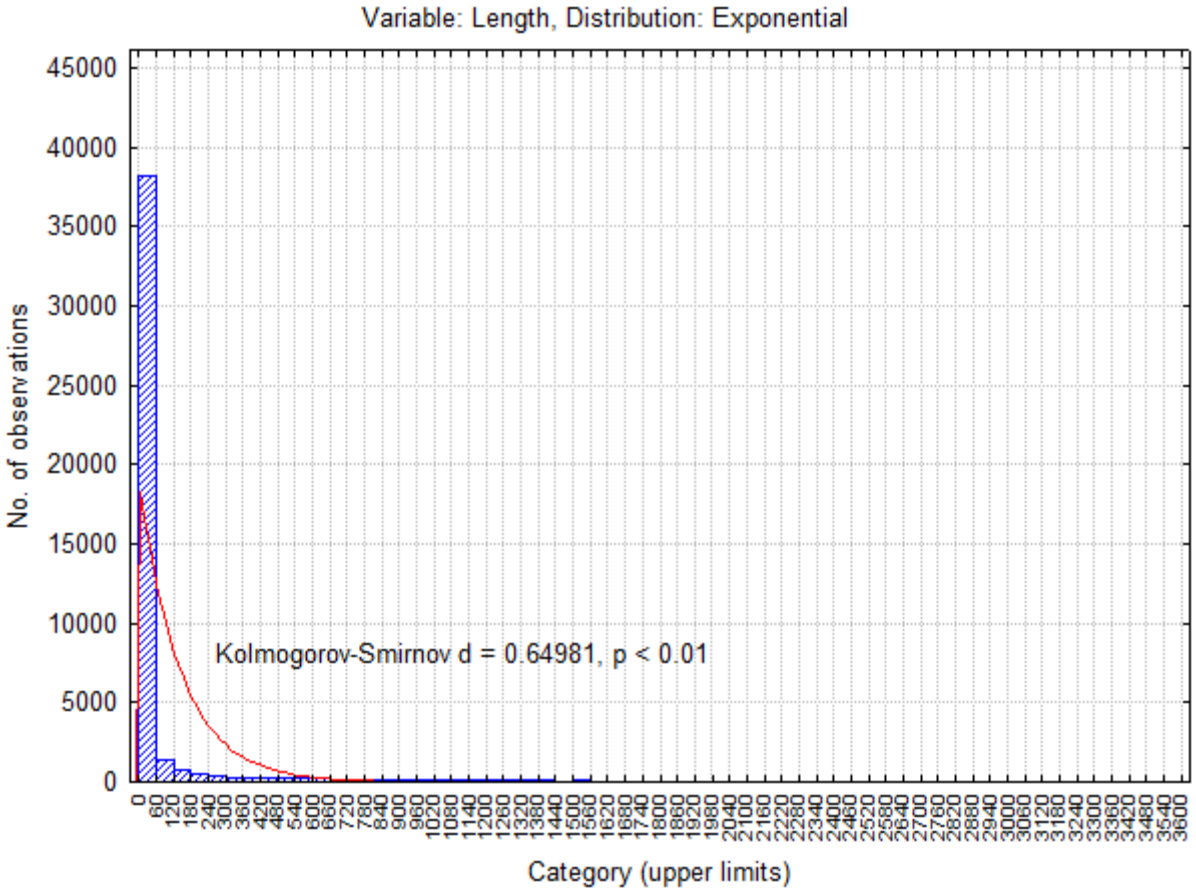


FÁZY PROCESU:

Príprava dát



Príprava dát



Príprava dát

Premenná $RLength$ má exponenciálne rozdelenie

$$f(RLength) = \lambda e^{-\lambda RLength},$$
$$F(RLength) = 1 - e^{-\lambda RLength},$$

kde $RLength \geq 0$

Ak je p relatívna početnosť navigačných stránok, na odhad hraničného času C môžeme použiť kvantilovú funkciu

$$F^{-1}(p, \lambda) = C = \frac{-\ln(1-p)}{\lambda}$$

pre $0 \leq p < 1$

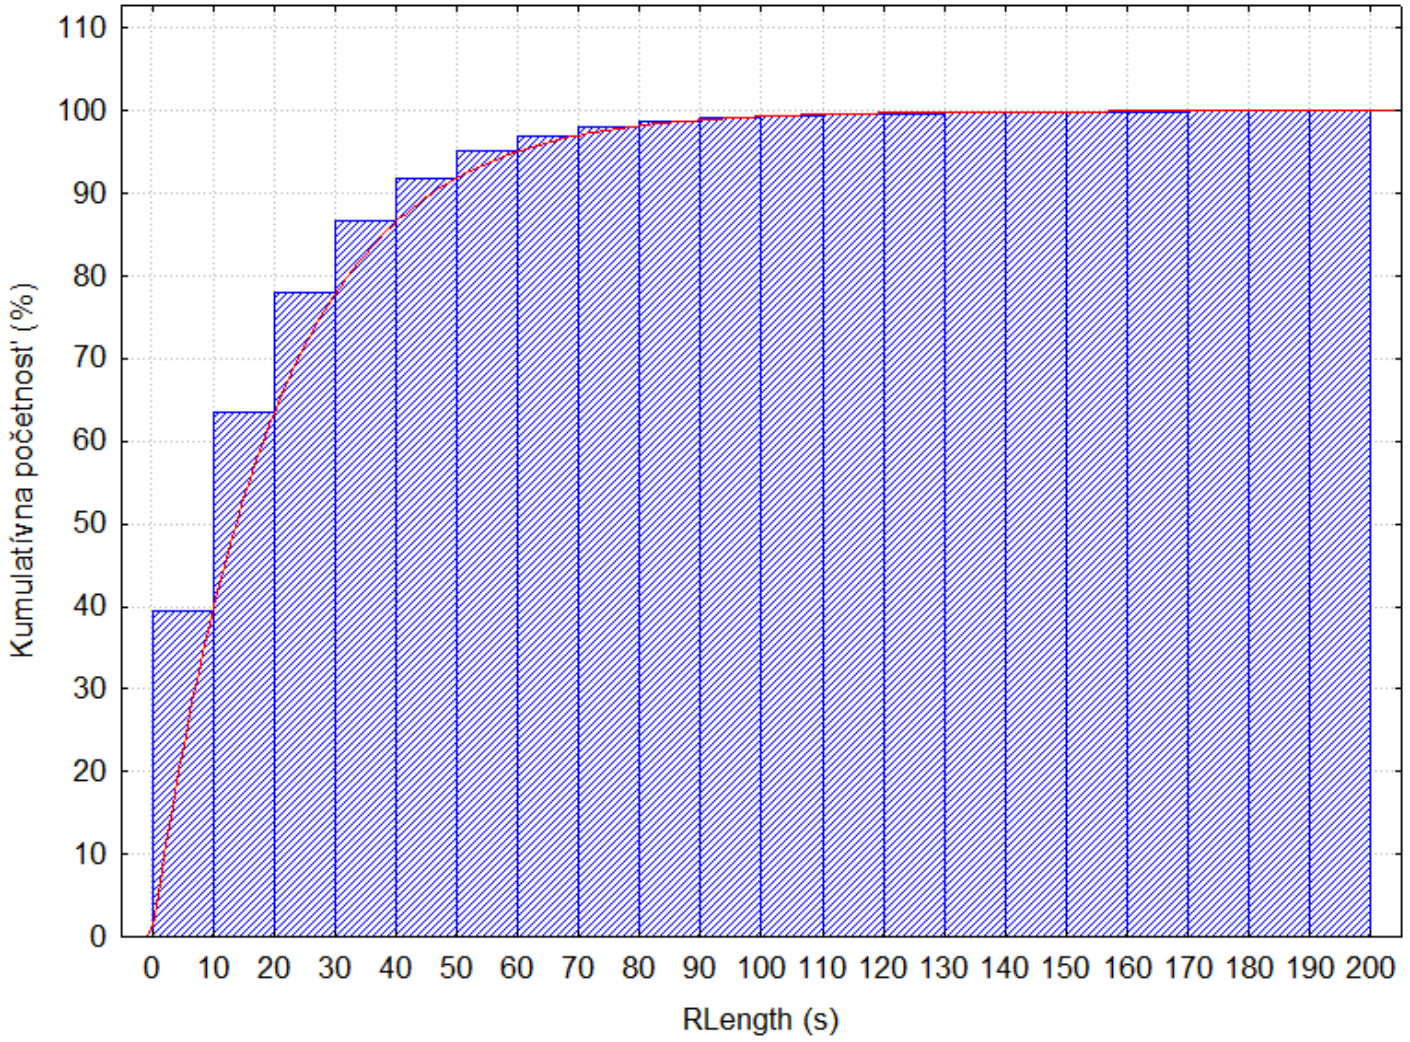
Maximálne vierohodný odhad parametra λ (priemerná intenzita udalostí) je

$$\hat{\lambda} = \frac{1}{\overline{RLength}},$$

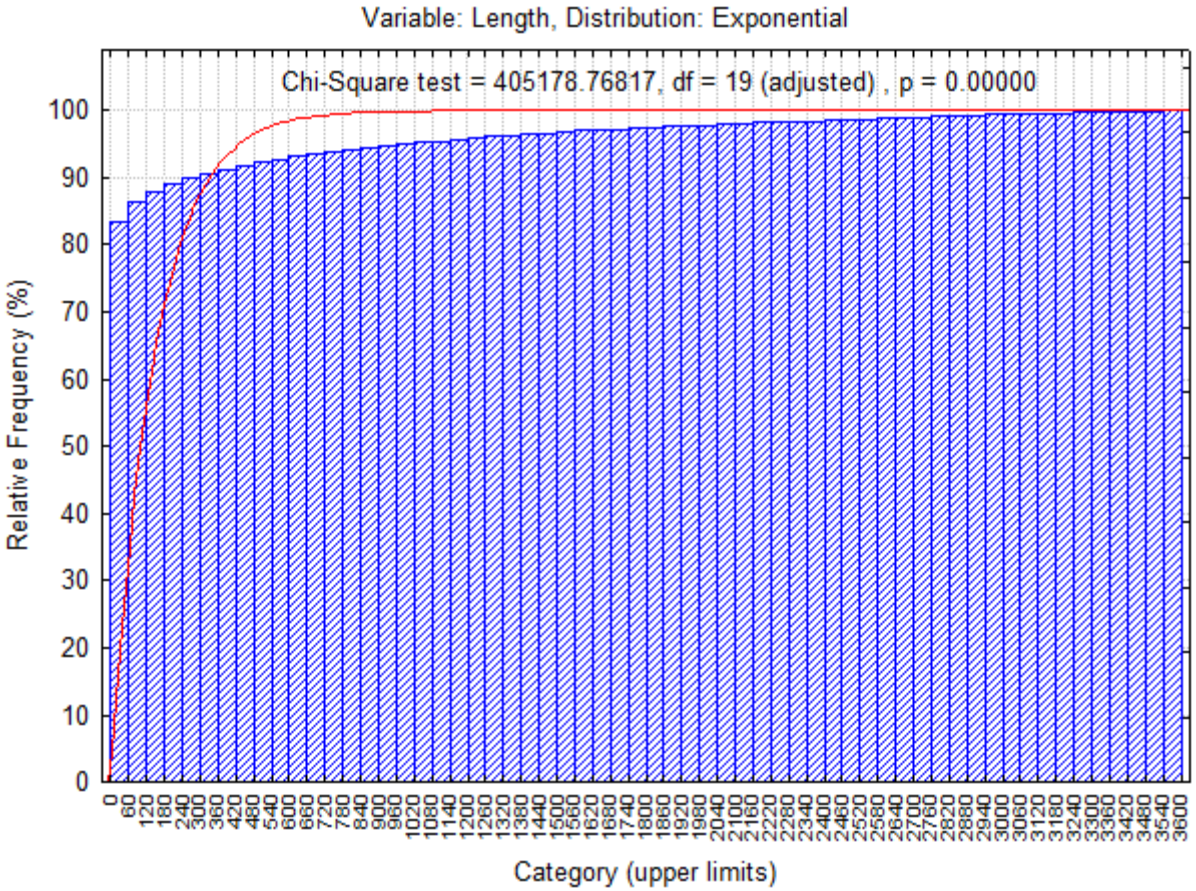
kde $\overline{RLength}$ je pozorovaný priemer dĺžky návštev

FÁZY PROCESU:

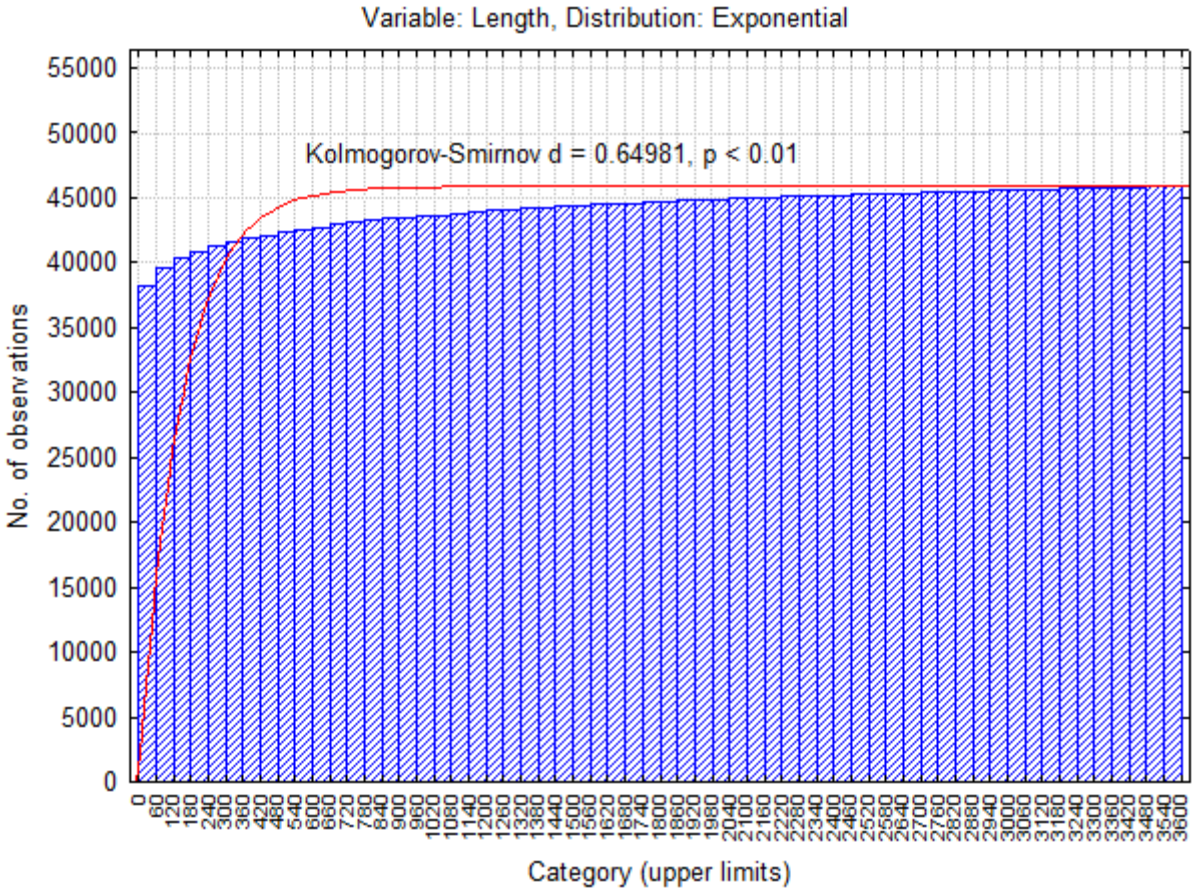
Príprava dát



Príprava dát



Príprava dát



Príprava dát

Upper Boundary	Variable: Length, Distribution: Exponential (user_unixtime_length_vstup) Chi-Square = 405178.76817, df = 19 (adjusted) , p = 0.00000						
	Observed Frequency	Cumulative Observed	Cumul. % Observed	Expected Frequency	Cumulative Expected	Cumul. % Expected	Observed-Expected
<= 60.00000	38221	38221	83.3301	15622.43	15622.43	34.0603	22598.57
120.00000	1388	39609	86.3562	10301.39	25923.81	56.5195	-8913.39
180.00000	755	40364	88.0023	6792.70	32716.52	71.3291	-6037.70
240.00000	512	40876	89.1185	4479.09	37195.61	81.0945	-3967.09
300.00000	395	41271	89.9797	2953.50	40149.11	87.5338	-2558.50
360.00000	305	41576	90.6447	1947.53	42096.64	91.7798	-1642.53
420.00000	298	41874	91.2944	1284.20	43380.83	94.5796	-986.20
480.00000	232	42106	91.8002	846.80	44227.63	96.4258	-614.80
540.00000	233	42339	92.3082	558.37	44786.00	97.6432	-325.37
600.00000	208	42547	92.7617	368.19	45154.19	98.4459	-160.19
660.00000	200	42747	93.1977	242.78	45396.98	98.9752	-42.78
720.00000	173	42920	93.5749	160.09	45557.07	99.3243	12.91
780.00000	166	43086	93.9368	105.56	45662.63	99.5544	60.44
840.00000	148	43234	94.2595	69.61	45732.24	99.7062	78.39
900.00000	138	43372	94.5604	45.90	45778.14	99.8063	92.10
960.00000	106	43478	94.7915	30.27	45808.41	99.8723	75.73
1020.00000	111	43589	95.0335	19.96	45828.36	99.9158	91.04

Príprava dát

Ak máme odhad hraničného času C, tak sedenie je sekvencia navštívených stránok s časovou známkou, pre ktorú platí:

$$\langle USID, \langle URL_1, DTime_1, RLength_1 \rangle, \dots, \langle URL_k, DTime_k, RLength_k \rangle \rangle,$$

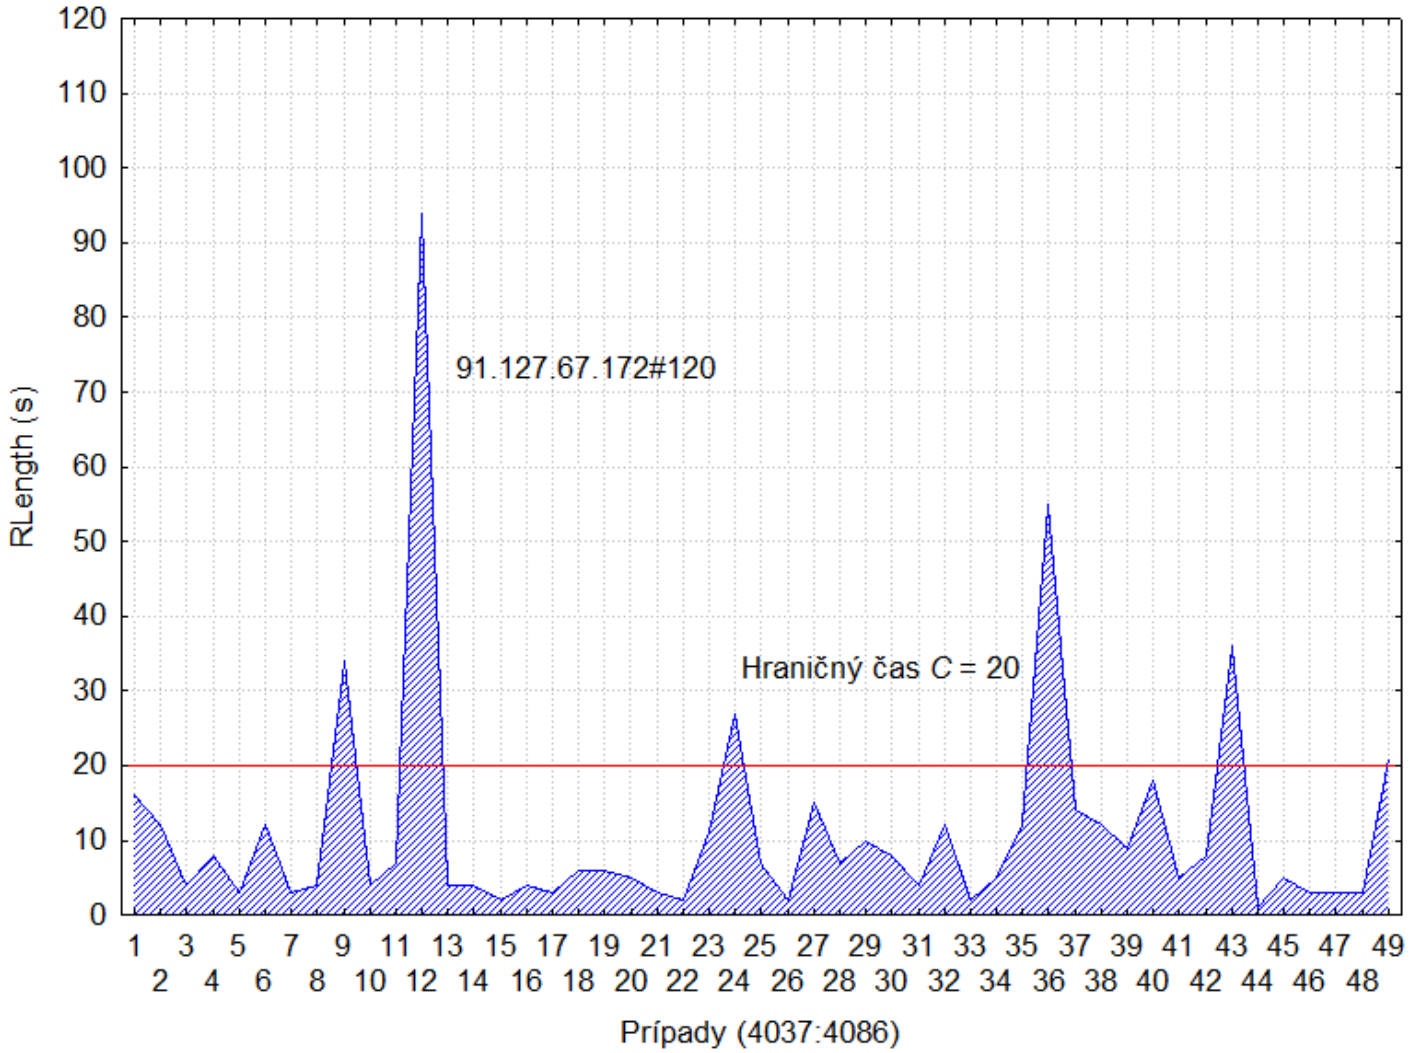
$$RLength_i \leq C, \qquad (1)$$

kde $1 \leq i < k$ a pre poslednú stránku sedenia platí:

$$RLength_k > C \qquad (2)$$

Od stránky s vlastnosťou (2) je definované ďalšie sedenie

Príprava dát

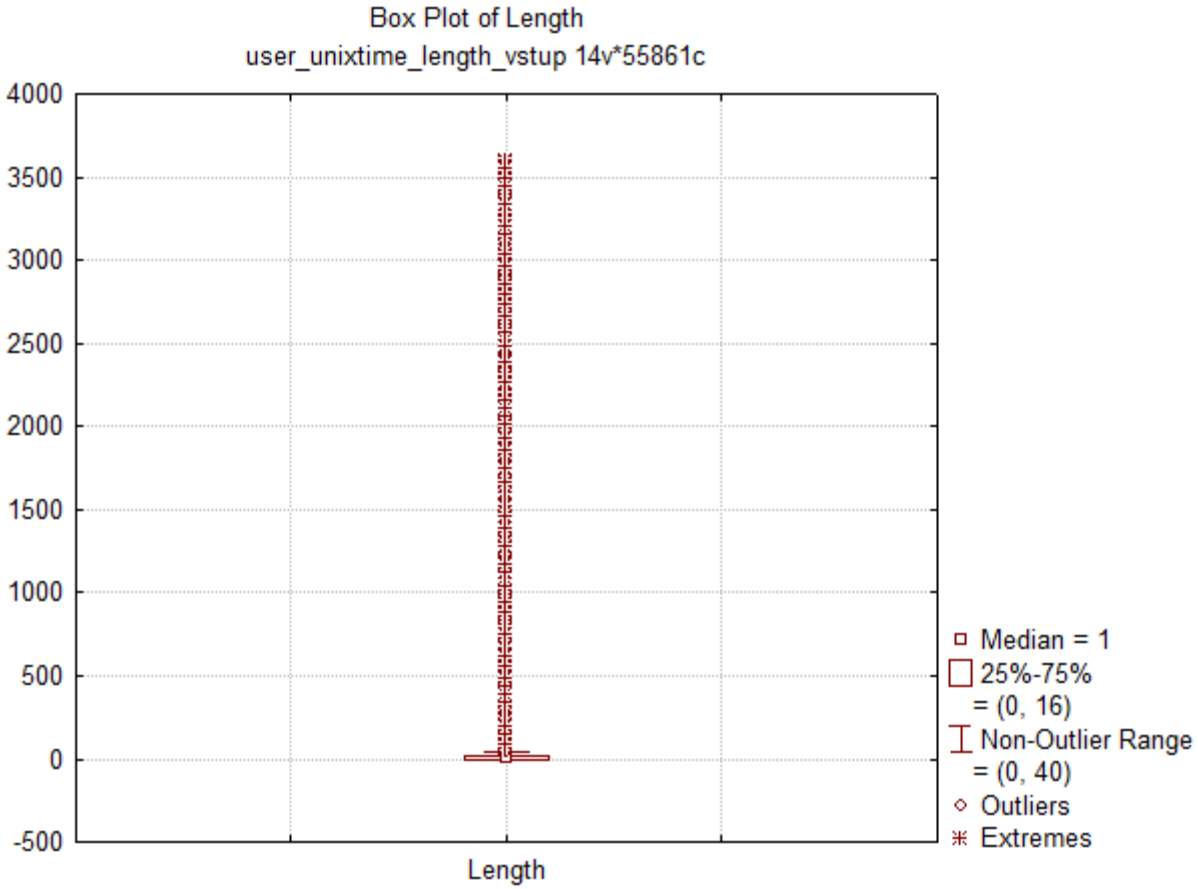


Príprava dát

Variable	Descriptive Statistics (user_unixtime_length_vstup)											
	Valid N	Mean	Median	Mode	Frequency of Mode	Minimum	Maximum	Lower Quartile	Upper Quartile	Range	Quartile Range	Coef.Var.
Length	45867	144.0821	1.000000	0.000000	17112	0.00	3600.000	0.00	16.00000	3600.000	16.00000	332.6482

Variable	Descriptive Statistics (user_unixtime_length_vstup)								
	Valid N	Median	Minimum	Maximum	Lower Quartile	Upper Quartile	Range	Quartile Range	**STT_Q =Upper+1.5*Quartile**
Length	45867	1.000000	0.00	3600.000	0.00	16.00000	3600.000	16.00000	40.0000

Príprava dát



Príprava dát

Ak máme odhad veľkosti časového okna δ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \langle USID, \langle URL_1, DTime_1 \rangle, \ldots, \langle URL_k, DTime_k \rangle \rangle,$$

$$DTime_i - DTime_{i-1} \leq \delta,$$

kde $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$.

Ak po dvoch po sebe nasledujúcich záznamov z $WALS$ nerovnosť neplatí, tak záznamy patria do dvoch rozdielnych sedení.