CRISP-DM IV

Prednáška 8

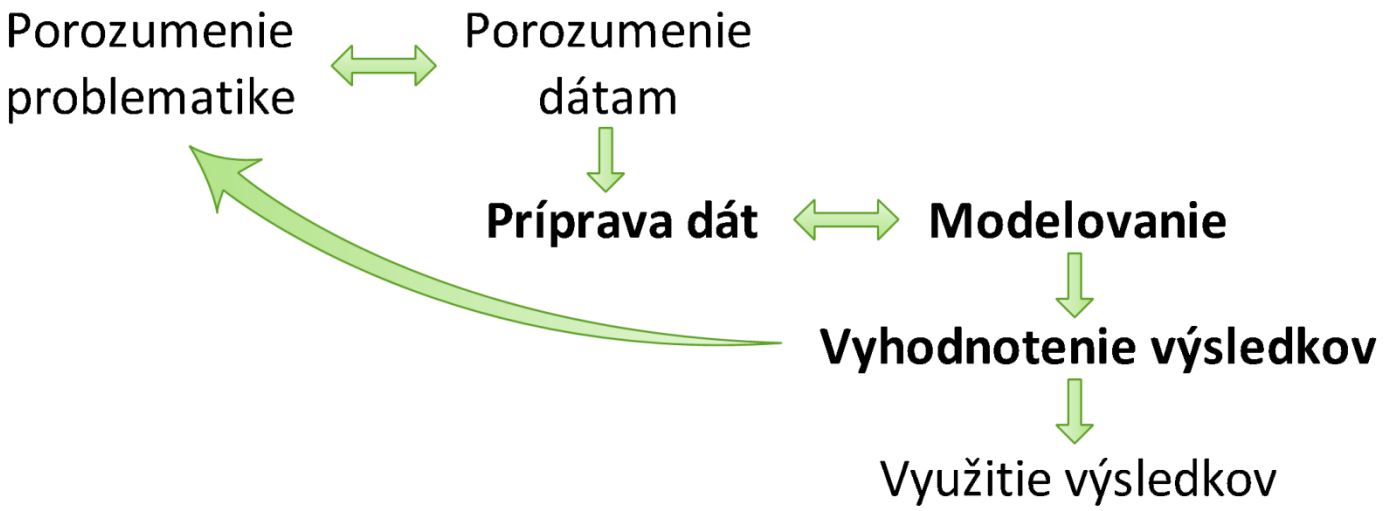
Michal Munk

FÁZY PROCESU WEB LOG MININGU

Proces objavovania znalostí na základe používania webu sa rozdeľuje do troch základných častí:

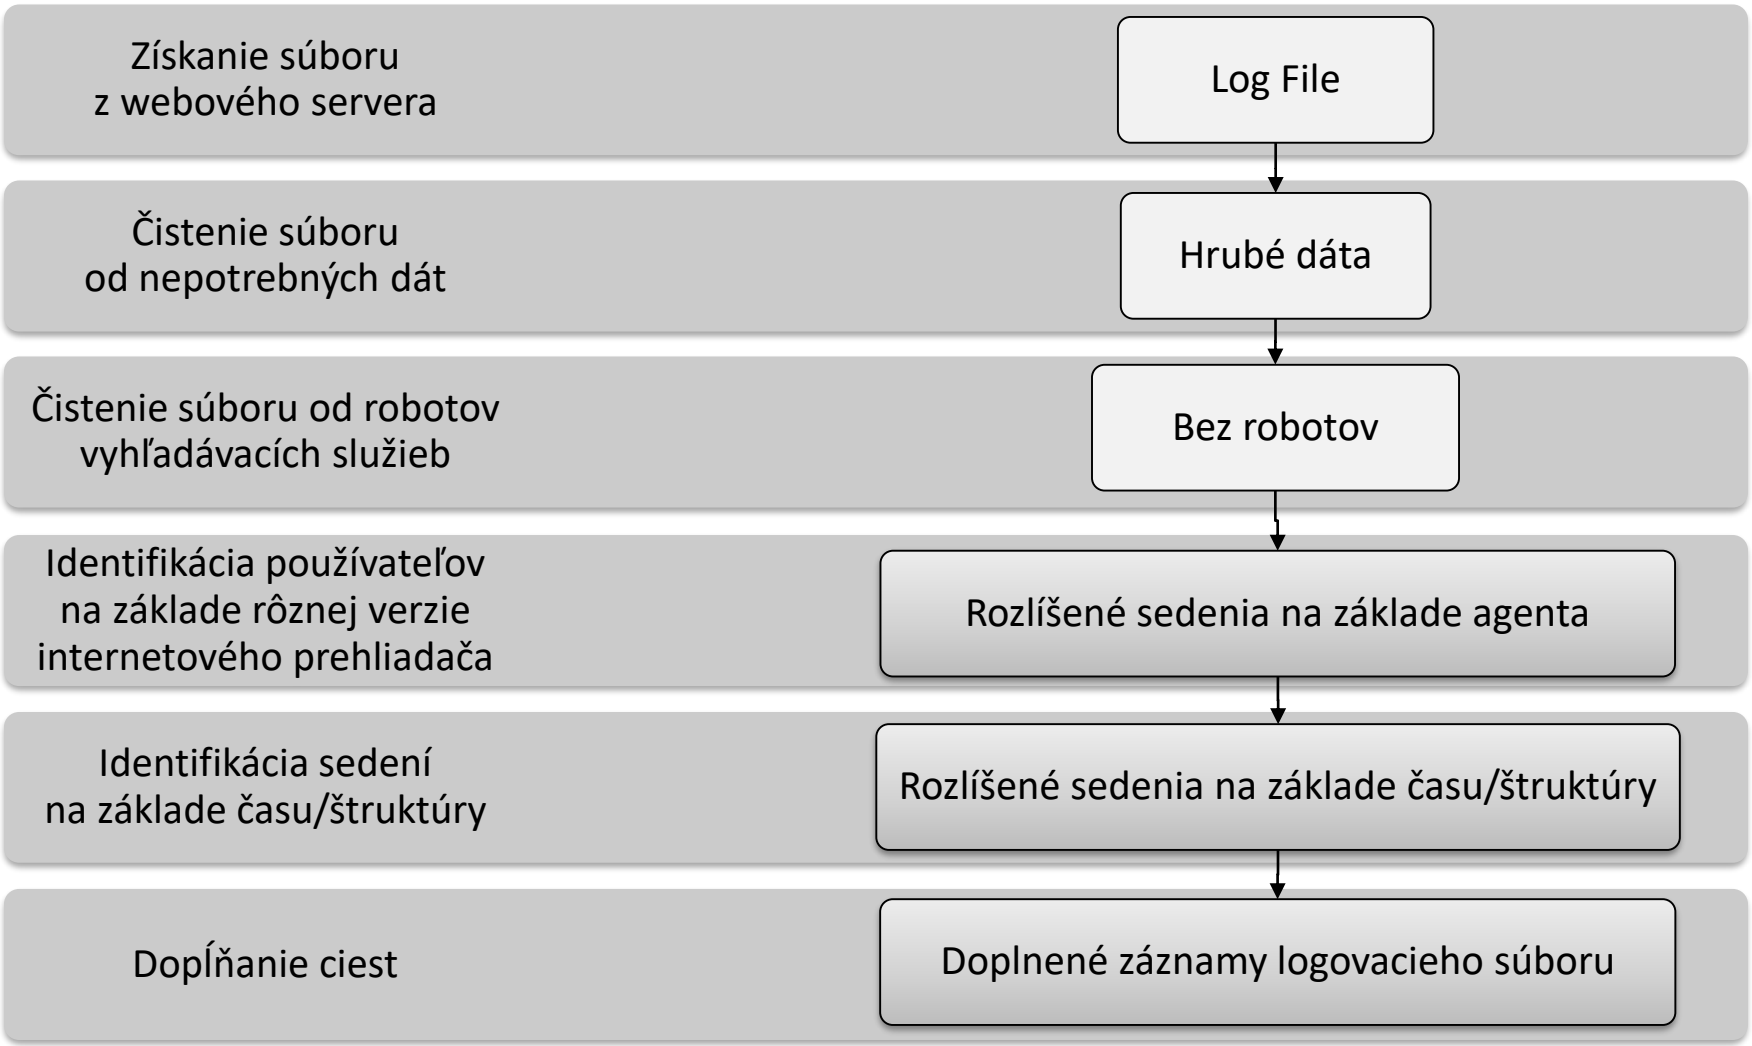
Predspracovanie ⇒ **Objavovanie vzorov** ⇒ **Analýza vzorov**

Metodika CRISP-DM, fázy procesu:



FÁZY PROCESU:

Príprava dát



Príprava dát

Identifikácia používateľov

- na základe rôznej verzie internetového prehliadača
- na základe HTTP/web/Internet/browser cookie

Identifikácia sedení

- na základe štruktúry prehľadávaných stránok
- na základe času
- na základe kombinácie času a štruktúry

IP	Cookie	..	Agent
91.226.112.32	**91.226.112.32.1379883231097502**	..	**Opera/9.80 (Windows NT 6.1) Presto/2.12.388 Version/12.16**
91.226.112.32	**91.226.112.32.1379883231097502**	..	**Opera/9.80 (Windows NT 6.1) Presto/2.12.388 Version/12.16**
91.226.112.32	**91.226.112.32.1379883231097502**	..	**Opera/9.80 (Windows NT 6.1) Presto/2.12.388 Version/12.16**
91.226.112.32	**91.226.112.32.1379883231097502**	..	**Opera/9.80 (Windows NT 6.1) Presto/2.12.388 Version/12.16**

$$WALS = \langle \boldsymbol{IP}, \boldsymbol{Cookie}, \boldsymbol{DTime}, Method, \boldsymbol{URL}, Version, Status, Bytes, \boldsymbol{Referrer}, \boldsymbol{Agent} \rangle,$$

kde $WALS$ (Web Access Log Set) je množina webových prístupov zachytená v logovacom súbore a zoradená podľa položky $DTime$
$WALS \subset U$, kde U je množina možných požiadaviek na webový server

Príprava dát

Ak sú odkazujúce stránky dostupné (Extended Log File, ELF), tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \langle USID, \langle URL_1, DTime_1, Referer_1 \rangle, \dots, \langle URL_k, DTime_k, Referer_k \rangle \rangle,$$

$$Referer_i = URL_{i-1},$$

kde USS (User Session Set) je množina sedení, $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$

Dva po sebe nasledujúce záznamy z $WALS$ nepatria do jedného sedenia, ak rovnosť neplatí

Príprava dát

Ak máme odhad dĺžky času sedenia θ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \langle USID, \langle URL_1, DTime_1 \rangle, \dots, \langle URL_k, DTime_k \rangle \rangle,$$

$$DTime_k - DTime_1 \leq \theta,$$

kde $DTime_k$ je časová známka posledného záznamu sedenia, $1 \leq k \leq n$ a n je počet záznamov vo $WALS$

Všetky ďalšie záznamy logovacieho súboru, ktorých časová známka je väčšia ako $DTime_1 + \theta$ už patria do ďalšieho sedenia

Príprava dát

Ak máme odhad veľkosti časového okna (Session Timeout Threshold, STT) δ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \langle USID, \langle URL_1, DTime_1 \rangle, \dots, \langle URL_k, DTime_k \rangle \rangle,$$

$$DTime_i - DTime_{i-1} \leq \delta,$$

kde $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$

Ak po dvoch po sebe nasledujúcich záznamov z $WALS$ nerovnosť neplatí, tak záznamy patria do dvoch rozdielnych sedení

Príprava dát

178.41.1.187 - - [16/Dec/2019:18:16:26 +0100] "GET " ...
178.41.1.187 - - [16/Dec/2019:18:19:47 +0100] "GET /studium " ...
178.41.1.187 - - [16/Dec/2019:18:52:37 +0100] "GET /studium/akreditovane-programy "...
178.41.1.187 - - [16/Dec/2019:18:54:25 +0100] "GET /prijimaciekonanie " ...
178.41.1.187 - - [16/Dec/2019:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "...

Sedenie 1

178.41.1.187 - - [16/Dec/2019:18:16:26 +0100] "GET " ...
178.41.1.187 - - [16/Dec/2019:**18:19:47** +0100] "GET /studium " ...

Sedenie 2

178.41.1.187 - - [16/Dec/2019:**18:52:37** +0100] "GET /studium/akreditovane-programy "...
178.41.1.187 - - [16/Dec/2019:18:54:25 +0100] "GET /prijimaciekonanie " ...
178.41.1.187 - - [16/Dec/2019:18:59:58 +0100] "GET /prijimaciekonanie/podmienky "...

Príprava dát

Ak premenná $RLength$ nemá exponenciálne rozdelenie

Na odhad časového okna δ môžeme použiť kvartilový odhad

$$STT = \delta = Q_{III} + 1{,}5QR,$$

kde Q_{III} je horný kvartil (75. percentil) a QR je kvartilové rozpätie (stredných 50% hodnôt)

Odhady strednej hodnoty sa síce používajú, ale ich použitie nie je vhodné

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad \bar{x}_G = \sqrt[n]{\prod_{i=1}^{n} x_i} \qquad \tilde{x} = x_m \qquad \tilde{x} = \frac{x_m + x_{m+1}}{2}$$

Príprava dát

Ak premenná $RLength$ má exponenciálne rozdelenie

$$f(RLength) = \lambda e^{-\lambda RLength},$$
$$F(RLength) = 1 - e^{-\lambda RLength},$$

kde $RLength \geq 0$

Na odhad časového okna δ môžeme použiť kvantilovú funkciu

$$F^{-1}(p, \lambda) = STT = \delta = \frac{-\ln(1-p)}{\lambda},$$

kde p relatívna početnosť navigačných stránok $0 \leq p < 1$

Maximálne vierohodný odhad parametra λ (priemerná intenzita udalostí) je

$$\hat{\lambda} = \frac{1}{\overline{RLength}},$$

kde $\overline{RLength}$ je pozorovaný priemer dĺžky návštev

Príprava dát

Ak máme odhad veľkosti časového okna δ, tak sedenie je sekvencia navštívených stránok s časovou známkou pre ktorú platí:

$$USS = \langle USID, \langle URL_1, DTime_1, Referer_1 \rangle, \ldots, \langle URL_k, DTime_k, Referer_k \rangle \rangle,$$

$$Referer_i = URL_{i-1} \quad (1)$$

alebo rovnosť neplatí, resp. $Referer_i$ nie je definovaný, ale:

$$DTime_i - DTime_{i-1} \leq \delta, \quad (2)$$

kde $DTime_k$ je časová známka posledného záznamu sedenia a $1 < i \leq k$

Dva po sebe nasledujúce záznamy z $WALS$ nepatria do jedného sedenia, ak neplatí (1) a zároveň (2)

Príprava dát

IP adresa	Čas požiadavky	URL adresa	Odkazujúca (referer)
194.160.10.10	12:00	stránka A	-
194.160.10.10	12:01	stránka B	stránka A
194.160.10.10	12:04	stránka C	stránka B
194.160.10.10	12:08	stránka D	stránka C
194.160.10.10	13:00	stránka A	-
194.160.10.10	**13:04**	**stránka E**	**stránka D**
194.160.10.10	13:09	stránka B	stránka A
194.160.10.10	13:12	stránka C	stránka B

Sedenie 1

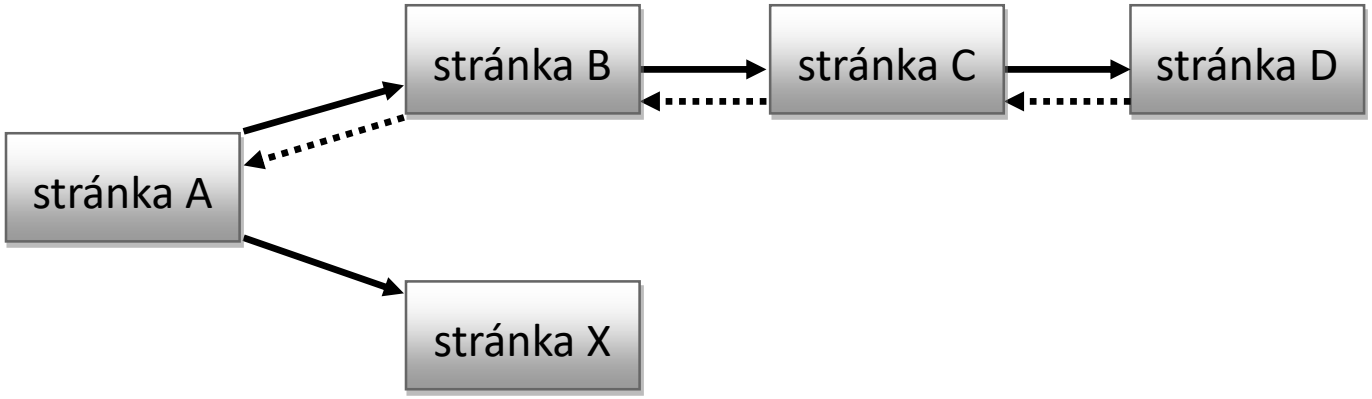
194.160.10.10	12:00	stránka A	-
194.160.10.10	12:01	stránka B	stránka A
194.160.10.10	12:04	stránka C	stránka B
194.160.10.10	12:08	stránka D	stránka C
194.160.10.10	13:04	stránka E	stránka D

Sedenie 2

194.160.10.10	13:00	stránka A	-
194.160.10.10	13:09	stránka B	stránka A
194.160.10.10	13:12	stránka C	stránka B

Príprava dát

Aktuálna navigácia



Mapa webu

URL adresa	Odkazujúca stránka
B	A
X	A
C	B
D	C

Záznamy logovacieho súboru

194.160.10.10#5#2	12:00	stránka A
194.160.10.10#5#2	12:01	stránka B
194.160.10.10#5#2	12:04	stránka C
194.160.10.10#5#2	12:08	stránka D
194.160.10.10#5#2	12:15	stránka X

Dopĺňanie ciest

A→B→C→D→X
A→B→C→D→**C**→X
A→B→C→D→**C**→**B**→X
A→B→C→D→**C**→**B**→**A**→X