FAKULTA PRÍRODNÝCH VIED
UNIVERZITA KONŠTANTÍNA FILOZOVA V NITRE

CRISP-DM VI

Prednáška 10

Michal Munk

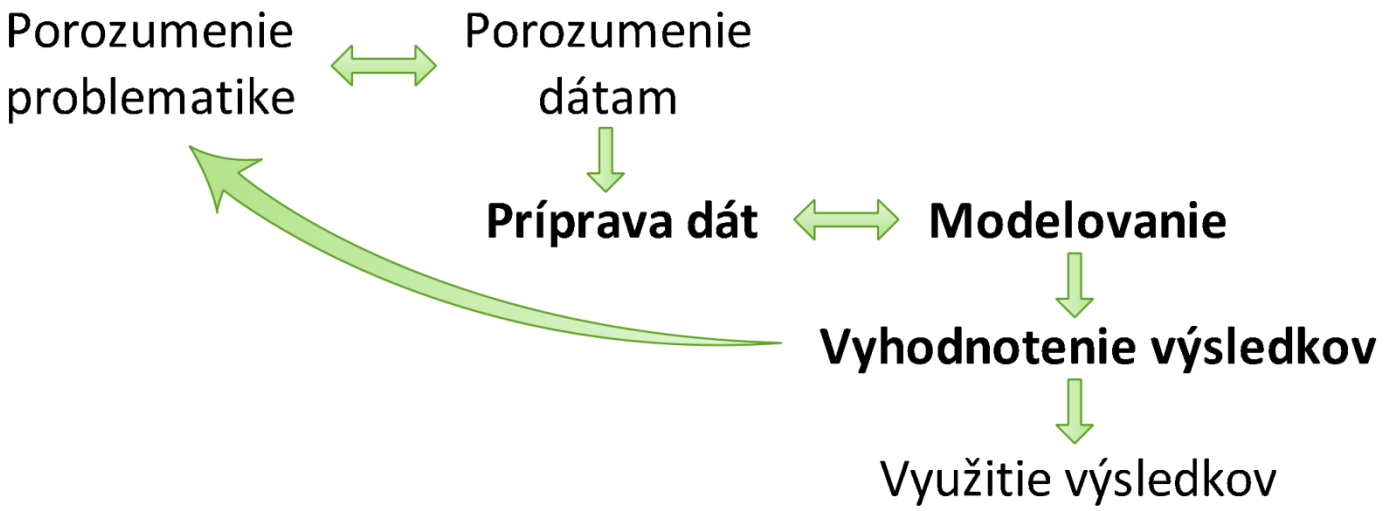
Katedra informatiky
FPV UKF v Nitre

FÁZY PROCESU WEB LOG MININGU

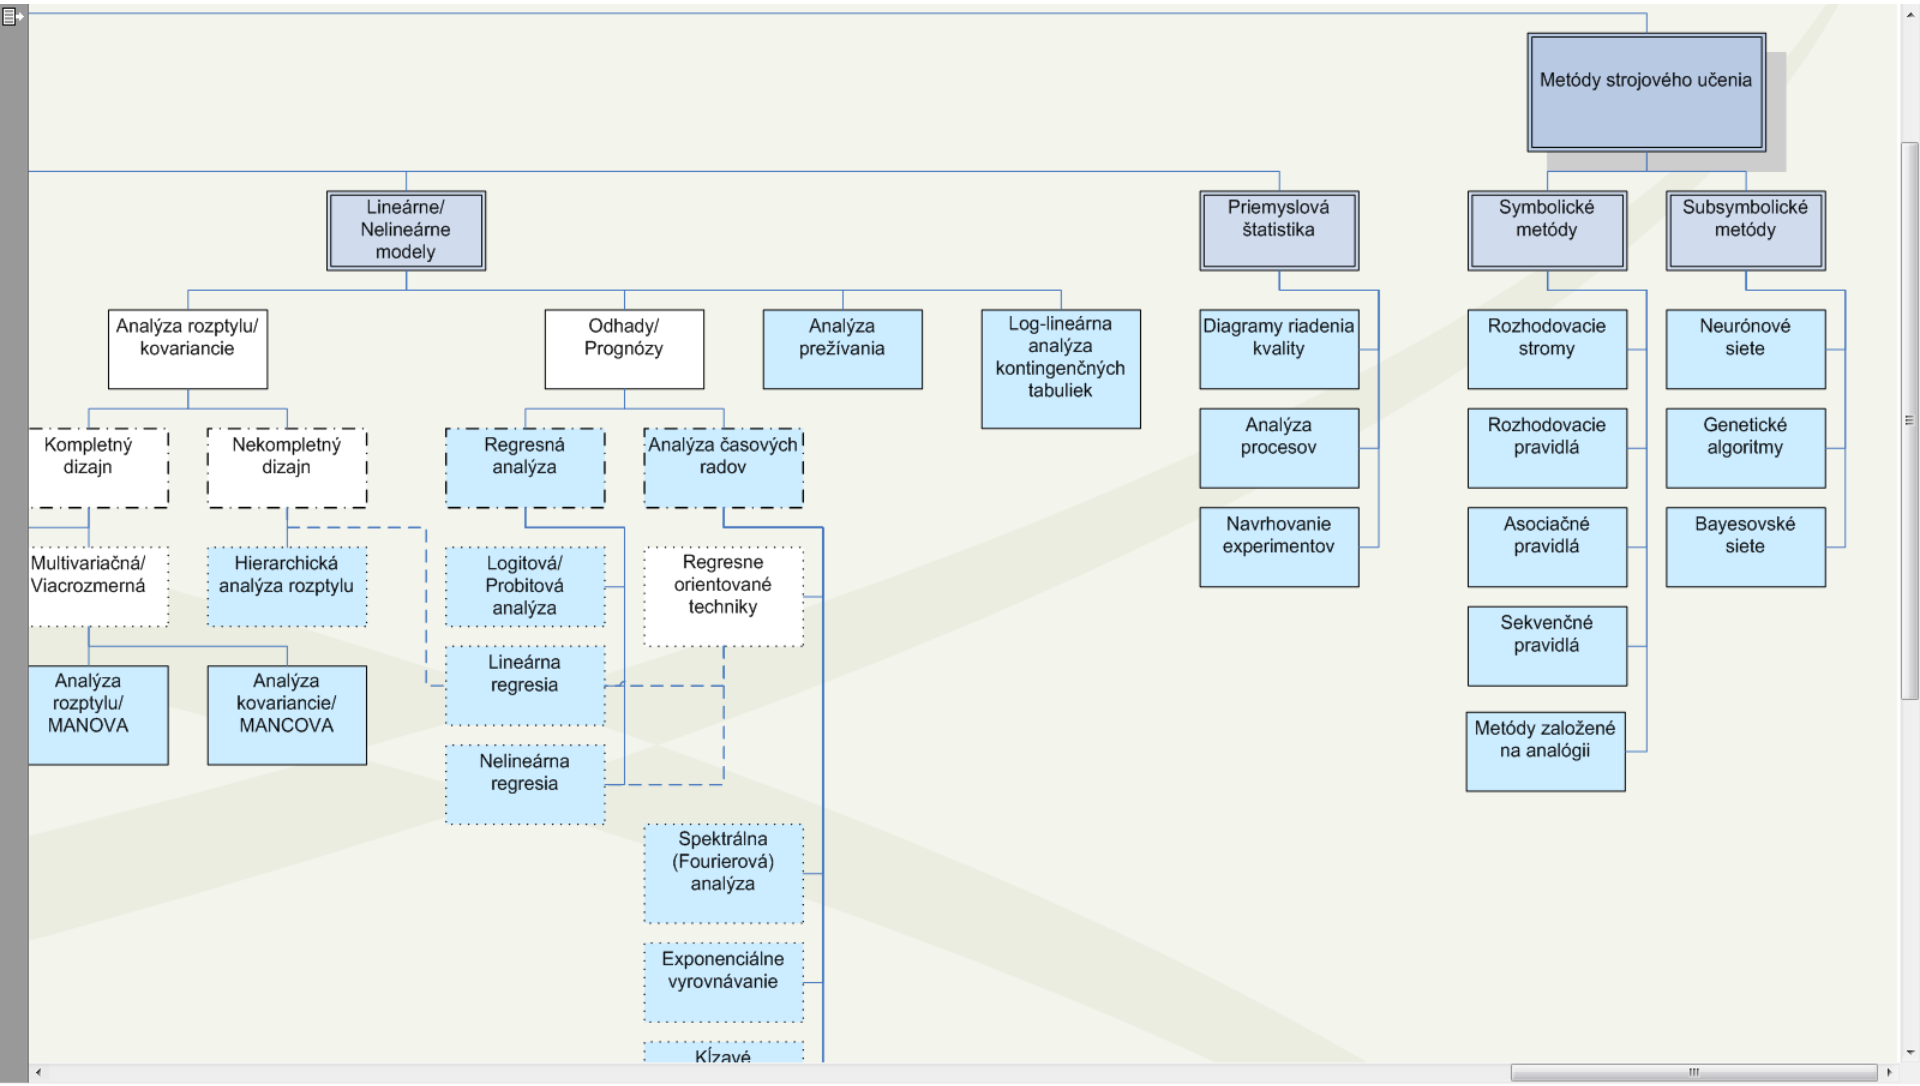
Proces objavovania znalostí na základe používania webu sa rozdeľuje do troch základných častí:

Predspracovanie ⇒ **Objavovanie vzorov** ⇒ **Analýza vzorov**

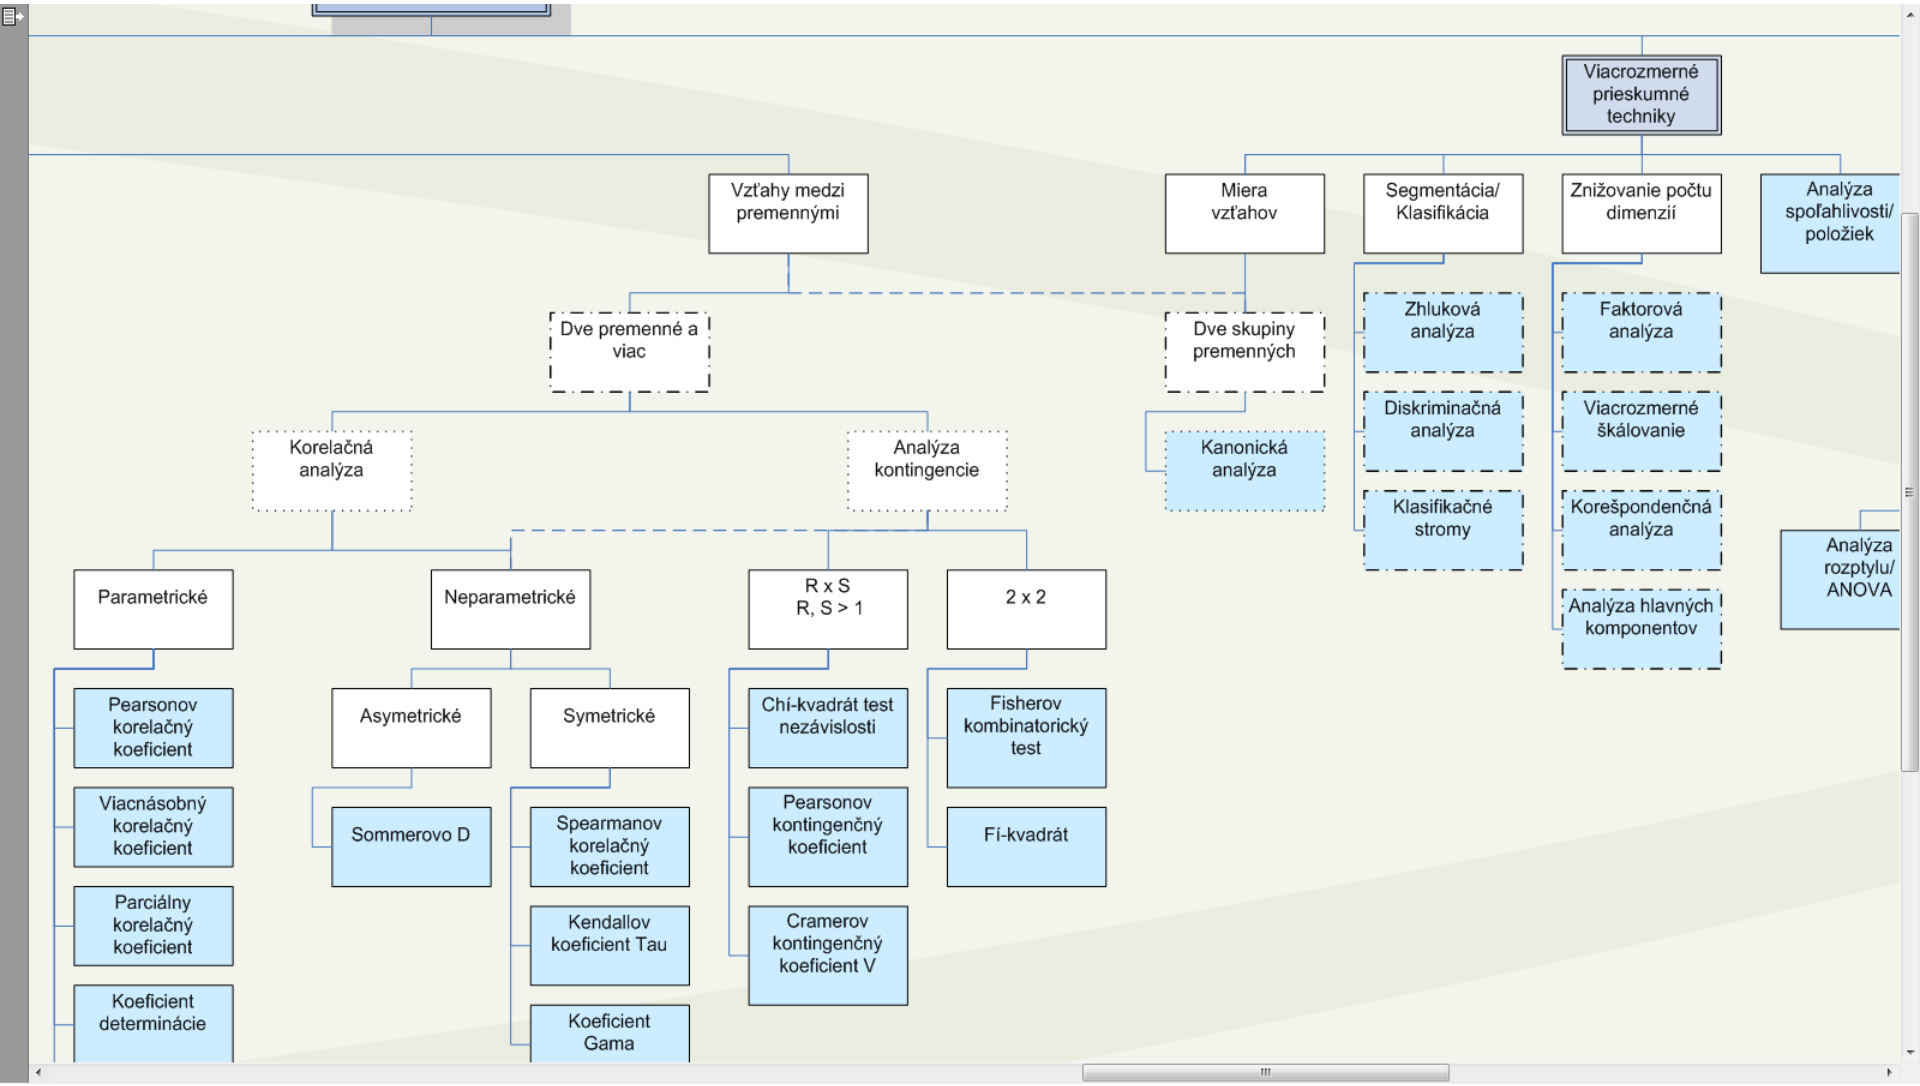
Metodika CRISP-DM, fázy procesu:



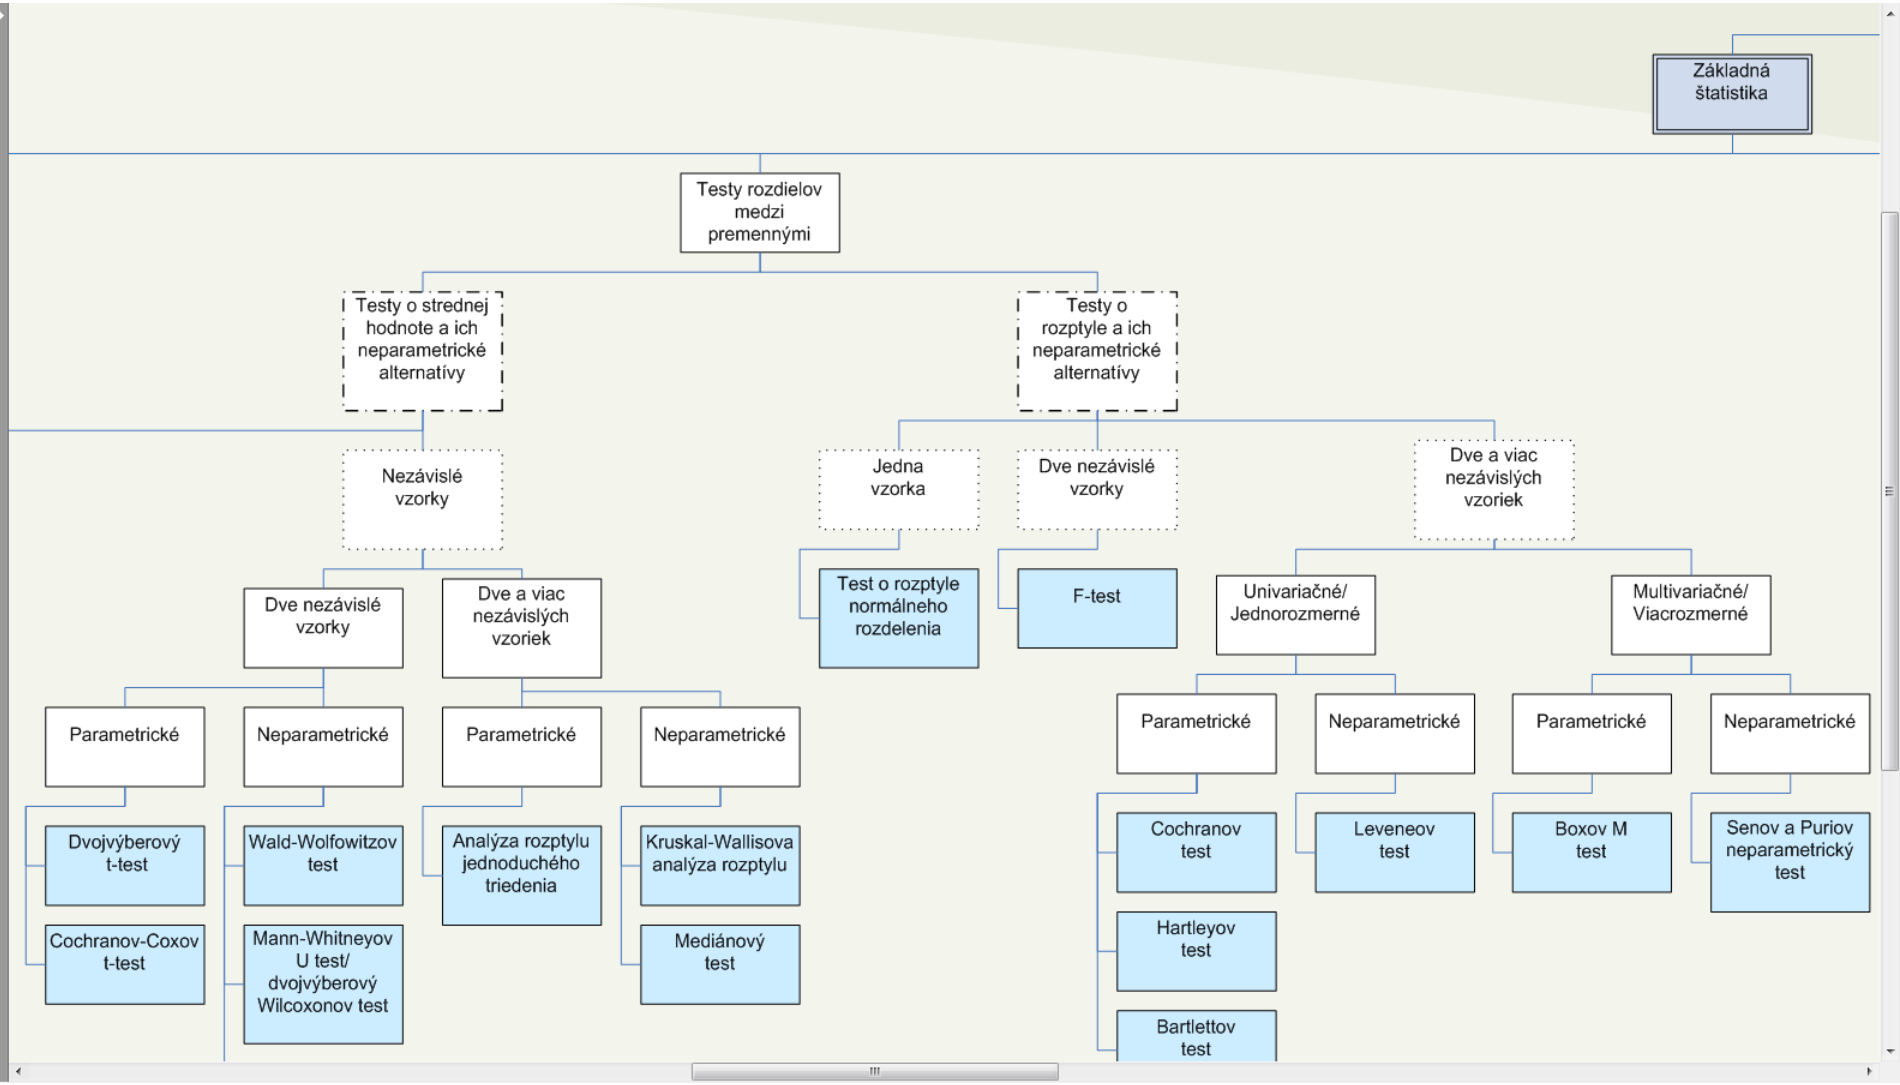
Modelovanie a vyhodnotenie výsledkov



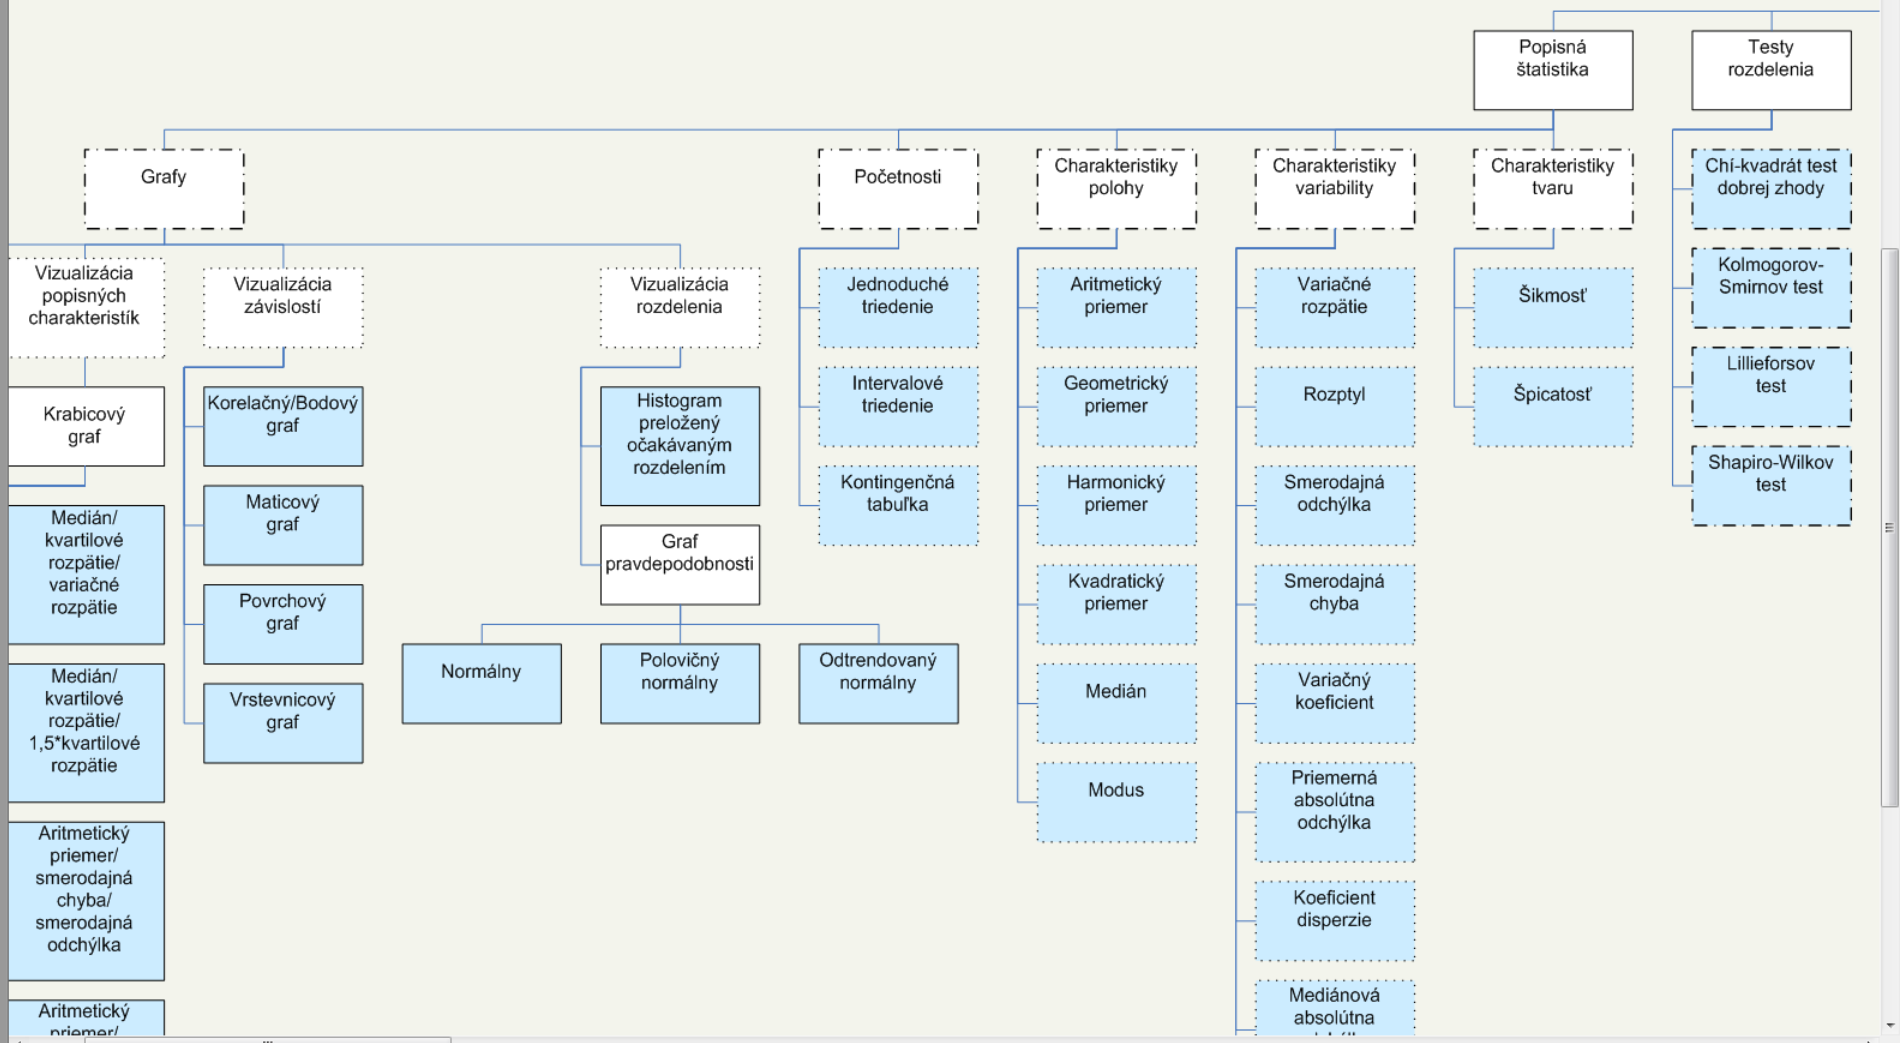
Modelovanie a vyhodnotenie výsledkov



Modelovanie a vyhodnotenie výsledkov



Modelovanie a vyhodnotenie výsledkov



Vyhodnotenie výsledkov

Vo fáze vyhodnotenia výsledkov majú svoje uplatnenie hlavne základné štatistické metódy, a to za účelom:

Overenia predpokladov použitia

- Rozdelenie premennej - testy rozdelenia
- Rovnosť rozptylov - testy o rozptyle a ich neparametrické alternatívy/univariačné testy
- Homogenita variančno-kovariančných matíc - testy o rozptyle a ich neparametrické alternatívy/multivariačné testy
- Nezávislosť premenných - vzťahy medzi premennými

Vyhodnotenie výsledkov

Vo fáze vyhodnotenia výsledkov majú svoje uplatnenie hlavne základné štatistické metódy, a to za účelom:

Porovnania výsledkov

- Porovnanie rozdelenia pravdepodobnosti empirických relatívnych početností prístupov a odhadnutých pravdepodobností výberu webovej časti *j* v čase i - testy o strednej hodnote a ich neparametrické alternatívy
- Porovnanie teoretických a empirických početností prístupov pre vybrané kategórie obsahu portálu - testy rozdelenia

Vyhodnotenie výsledkov

Vo fáze vyhodnotenia výsledkov majú svoje uplatnenie hlavne základné štatistické metódy, a to za účelom:

Vizualizácie

- Vizualizácia rozdielov empirických a teoretických početností prístupov a identifikácia extrémnych hodnôt - popisná štatistika
- Vizualizácia empirických a teoretických logitov pre jednotlivé webové časti, okrem referenčnej - popisná štatistika

Využitie výsledkov

Všeobecne môžeme aplikácie web log miningu rozdeliť do piatich kategórií: personalizácia, zlepšovanie systémov, modifikácia webových stránok, bussines intelligence a charakteristika používania

Analýza návštevnosti - Analýza závislostí

Plánovanie údržby - Predikcia

Reštrukturalizácia - Analýza závislostí

Personalizácia - Segmentácia, Klasifikácia, Analýza závislostí

SÚHRN

- Cieľom prednášky bolo prezentovať fázy procesu získavania znalostí
- Zamerali sme sa na zdroje dát o používaní webu
- Podobne by sme postupovali aj pri riadení procesu objavovania znalostí z databáz, či textov
- Najväčšie rozdiely medzi oblasťami objavovania znalostí pri riadení procesu metodikou CRISP-DM sú vo fáze prípravy dát
- Príprava dát predstavuje časovo najnáročnejšiu fázu v rámci celého procesu objavovania znalostí
- Zložitosť prípravy dát závisí od použitého zdroja dát